第06回　(2026.05.07)

データマイニング概論

いつもどおり、アンケートを行い、その後、出席登録を行って下さい。

授業への出欠に関わらず、課題の提出は必要です。
期限までに必ず提出しましょう。

熊本高等専門学校
生物化学システム工学科
木原　　久美子 (専攻科棟3階)
kihara@kumamoto-nct.ac.jp

※すべての授業資料について著作権を放棄していません。そのため、科目受講者が、自己の授業受講以外の目的で資料を電子的もしくは紙媒体等によって他者へ有償無償のいずれによらず譲渡することは禁止されています。授業受講者はこのことを理解したうえで受講しているとみなします。

0-1. もくじ

0-1. 目次
0-2. 準備
2-6. 最低限のコマンド一覧（復習）
4-3. データへのアクセス（復習）
7-1. データへのアクセス（復習）

11-1. 回帰分析
11-2. 近似直線の挿入（単回帰）
11-3. 具体的な式を求める
11-4. 近似式とデータの要約
11-5. 図に近似式を記す
11-6. 特定データの抜き出し解析

9-17. 特定の条件のデータを抜き出して解析
10-1. オブジェクトの取り扱いとデータ型・データ構造
10-2. オブジェクトの取り扱い・消去
10-3. オブジェクトの取り扱い・存在確認
10-4. オブジェクトの取り扱い・オブジェクト名

シラバス ←第01回
Rのインストール・準備・起動・使用練習 ←第02回
ディレクトリ階層構造, 最低限のコマンド, ヘルプ, 四則演算,
代入, 行と列, 系列名,CSVファイル, データの読み込み,
ヒストグラムの描画, 相対度数, 密度関数, 図の保存 ←第03-04回
ソースファイルから複数の図をプロット ←第04回
散布図, マーカーの色種類, プロット重合わせ ←第05回

0-2. 準備

特定のフォルダを作りそこに授業に関係するファイルを保存するようにしましょう。各自でいつも準備を進めておいて下さい。

□ 自分で決めた場所にData_miningフォルダを作成
　授業名がデータマイニング概論 (Data mining)なので。

□ そのフォルダの中にclassXXフォルダを作成。
　XXに01とか02とか、授業の回数を入れておけば見分けが付きやすい。
　毎回、授業中に行う作業はこのフォルダの中に保存するようにせよ。

2-6. 最低限のコマンド・一覧（前回まで）

□Rを立ち上げる　windowsのスタート→プログラム→R

□コマンドで居場所を確認＆今日の場所に移動

getwd()　今自分がどこにいるか居場所を確認
setwd(“..”)　ひとつうえの階層のディレクトリにいく
getwd()　居場所を確認！

dir()　今いるディレクトリ内に何があるか見る
setwd(“./class6”)　ディレクトリ内のclass4に移動
getwd()　うまく移動できたかgetwdで確認

help(dir)　dirの使い方見たい時。helpで何でも分かる
q()　Rを終わりにしたいとき
スペースを保存するか聞かれたら保存しないを選択

4-3. データへのアクセス(前回まで)

行列

データへのアクセス

X[行,列]と思うと分かりやすいかも。

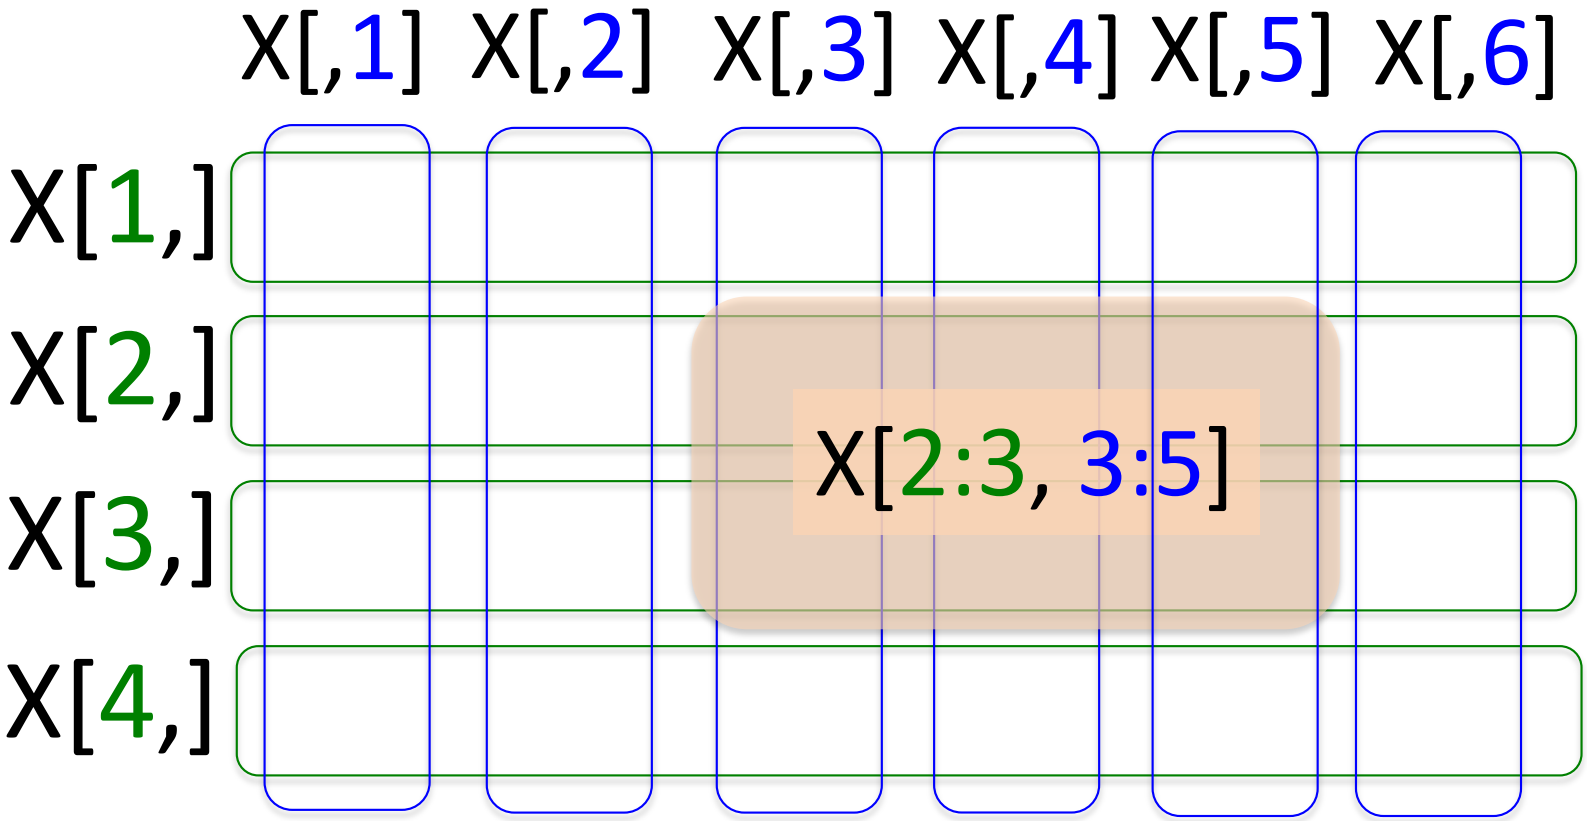

7-1. データへのアクセス(前回まで)

Rで扱うための、CSVファイルの準備

SampleData03_forR2.csvなどをフォルダー内に保存せよ。

CSVファイルが置いてあるディレクトリに移動しdir()で.csvファイルがある事を確認してから

CSVファイルの読み込み

Body <- read.table("読み込むcsvファイル名", header=T, sep=",")

読み込めたかどうか各自確認せよ

```
> help(read.table)
> Body <- read.table("SampleData03_forR 2.csv, header=T, sep=",")
```

データへのアクセス

Body[3,]
Body[,4]
Body[3,4]

Body [,2:5]
Body [3:7,]
Body [3:7,2:5]

Body[,c(2,4,5)]
Body [c(1,2,4),]
Body [c(1,2,3),c(2,4,6)]

それぞれ、どのような値を指している事になるか、再確認せよ。(下記は例)

> Body [1:5, 1:8]

```
   NO   ID Sex Birth_year Measurement_date  Age X1_Weight X2_Height
1   1 F001   F       1969        2003/11/6 33.9      50.4      1573
2   2 F002   F       1968        2003/11/6 35.0      39.6      1501
3   3 F003   F       1975        2003/11/6 28.3      53.6      1648
4   4 F004   F       1972        2003/11/6 31.2      50.4      1547
```

9-17. 特定の条件のデータを抜き出して解析

条件を決めて（例えば今回は性別ごと）該当部分のデータを抽出→プロットの流れ

```
> Body$Sex
[1] F F F F F F F F F F F F F M M F F F F F M F F F M M M M M M M F F F M M F F M M M M M M M M M F M F F M M
[55] M M M F F M M M M M M F F M M M F M M M M F F F M F F M M M M F F F M M F F F F F M M
Levels: F M
```

まずは状況の確認、ドルマークを使ってもいいね、FとMがまざっていることがわかる

```
> Body[,3]
[1] F F F F F F F F F F F F F M M F F F F F M F F F M M M M M M M F F F M M F F M M M M M M M M M F M F F M M
[55] M M M F F M M M M M M F F M M M F M M M M F F F M F F M M M M F F F M M F F F F F M M
Levels: F M
```

まずは状況の確認、列番号を指定してもいいね、FとMがまざっていることがわかる

どうかな？どっちでもいい?どっちで出来る？

Sex=F

```
> Body_F <- subset(Body, Sex=="F")
> Body_F[,3]
[1] F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F F
Levels: F M
```

表示して確認、確かにFばかりが抽出されている

条件に合う行のみを抽出
ここでは女性のデータを抽出してオブジェクトに入れた
subset(データフレーム , 条件)

どうかな？どっちでもいい?どっちで出来る？

Sex=M

```
> Body_M <- subset(Body, Sex=="M")
> Body_M[,3]
[1] M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M M
Levels: F M
```

表示して確認、確かにMばかりが抽出されている

条件に合う行のみを抽出
ここでは男性のデータを抽出してオブジェクトに入れた
subset(データフレーム , 条件)

```
> length(Body [,3])
[1] 97
> length(Body_F[,3])
[1] 48
> length(Body_M[,3])
[1] 49
```

length()でベクトルの長さを確認
たしかに、FとMを合計すると全数と合っている。
うまく性別ごとのデータを抽出できているようだ。

9-17. 特定の条件のデータを抜き出して解析

条件を決めて（例えば今回は性別ごと）該当部分のデータを抽出→プロットの流れ

> Body_F[,8]

性別の列だけでなく、他のデータの列も、抽出できているか確認、例えば8列目のデータ
元データと見比べてみて抽出できているか確認（初めてだし一応確認してみてね）

```
[1] 1573.0 1501.0 1648.0 1547.0 1514.0 1624.0 1570.0 1545.0 1626.5 1585.0 1602.0 1470.0 1612.0 1613.0 1598.0
[16] 1630.0 1570.5 1526.0 1550.0 1589.0 1603.0 1538.0 1606.0 1543.5 1581.0 1567.0 1611.5 1648.5 1563.0 1576.0
[31] 1476.0 1613.0 1610.0 1579.0 1577.0 1540.0 1571.0 1495.0 1617.0 1587.0 1607.0 1536.5 1640.0 1545.0 1595.0
[46] 1595.0 1642.0 1599.5
```

性別の列だけでなく、他のデータの列も、抽出できているか確認、例えば8列目のデータ
元データと見比べてみて抽出できているか確認（初めてだし一応確認してみてね）

> Body_M[,8]

```
[1] 1680.0 1681.0 1609.0 1687.0 1695.0 1732.0 1754.0 1717.0 1773.0 1714.0 1672.0 1620.0 1744.0 1728.5 1656.0
[16] 1639.0 1588.0 1860.0 1696.0 1715.0 1607.5 1710.0 1570.0 1781.0 1600.0 1789.0 1690.0 1650.0 1567.0 1751.0
[31] 1676.0 1728.0 1696.0 1659.0 1747.0 1736.0 1612.0 1766.0 1678.0 1725.0 1674.0 1652.0 1673.0 1665.0 1795.0
[46] 1706.0 1784.0 1832.0 1658.0
```

上手くデータの抽出もできていそうですね。

9-17. 特定の条件のデータを抜き出して解析

条件を決めて（例えば今回は性別ごと）該当部分のデータを抽出→プロットの流れ

体重と身長の関係をプロット；ただし性別ごとに色をかえて重ね合わせて示そう

```
> plot(Body_F[,7], Body_F[,8], xlab="Weight", ylab="Height", col="red", xlim=c(30,100), ylim=c(1400,2000), pch=21)
> par(new=T)
> plot(Body_M[,7], Body_M[,8], xlab="Weight", ylab="Height", col="blue", xlim=c(30,100), ylim=c(1400,2000), pch=21)
```

軸の表示範囲、プロットマーカーの色や形、軸のラベルは、使用するデータに合わせて、
各自で適切に変更したり好みに応じて選択すれば良い

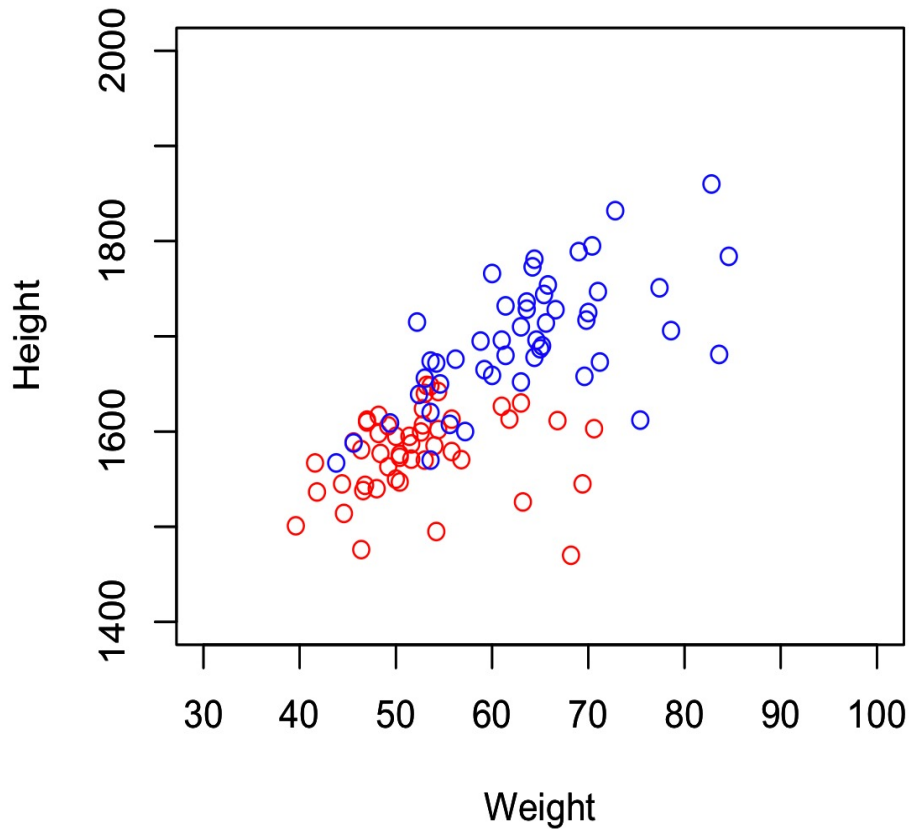

9-17. 特定の条件のデータを抜き出して解析

【課題 9-17A】
ここで作成したグラフのPDFファイルを提出せよ。

◎ ファイル名
ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事
※YYには自分の番号をふた桁の数字で入れる事
※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。
◎ 提出締切；次回の授業の前日の18:00まで

10-1. オブジェクトの取り扱いとデータ型・データ構造

オブジェクトに数値を入れたい

Rで以下を入力

```
> x1 <- c(19,23,27,35,44,51,59,66)
```

オブジェクトx1に数値データを入れた

```
> x1
[1] 19 23 27 35 44 51 59 66
```

オブジェクトx1の中身を表示させる、
ちゃんと中身があるね。

Rでは、データは、ひとまとまりの「ベクトル」として、取り扱われる。
確認してみよう。

データ構造の確認

```
> is.vector(x1)
[1] TRUE
```

オブジェクトx1の型は、ベクトルですか？
ええそうでっせ。

10-1. オブジェクトの取り扱いとデータ型・データ構造

オブジェクトに文字列を入れたい

```
> x2 <- c(“a”, “b”, “c”, “d”, “e”, “f”)
```

オブジェクトx2に文字列データを入れた

```
> x2
[1] ”a" ”b" ”c" ”d" ”e" ”f”
```

オブジェクトx2の中身を表示させる、
ちゃんと中身があるね。

Rでは、データは、ひとまとまりの「ベクトル」として、取り扱われる。
確認してみよう。

データ構造の確認

前のページのようにやってみてね。

10-1. オブジェクトの取り扱いとデータ型・データ構造

オブジェクトの状況確認

```
> x1
[1] 19 23 27 35 44 51 59 66
```
人間としては、x1は数値（数字）データと認識している。

```
> x2
[1] ”a" ”b" ”c" ”d" ”e" ”f”
```
人間としては、x2は文字データと認識している。

Rでは、どう認識しているのかを確認してみよう。

データ型の確認

x1やx2をつかって自分で色々試してみてね

```
> is.character(x2)
[1] TRUE
```
オブジェクトx2のデータ型は、「文字列」ですか？
ええそうでっせ。

```
> is.character(x1)
[1] FALSE
```
オブジェクトx2のデータ型は、「文字列」ですか？
ちがいまっせ。

```
> mode(x1)
[1] "numeric"
```
オブジェクトx1のデータ型は、なんですか？
数値（実数）でっせ。

```
> is.numeric(x1)
[1] TRUE
```
オブジェクトx1のデータ型は、「数値（実数）」ですか？
ええそうでっせ。

10-1. オブジェクトの取り扱いとデータ型・データ構造

データの型の確認

x1やx2をつかって自分で色々試してみてね

データの型には他にもいろいろなものがある

```
> is.integer(x1)
```
オブジェクトx1の型は、「整数」ですか？

```
> is.complex(x1)
```
オブジェクトx1の型は、「複素数」ですか？

```
> is.logical(x1)
```
オブジェクトx1の型は、「論理値」ですか？

データ構造の確認

データ構造には他にもいろいろなものがある

```
> is.matrix(x1)
```
オブジェクトx1は、「行列」ですか？

```
> is.array(x1)
```
オブジェクトx1は、「配列」ですか？

```
> is.list(x1)
```
オブジェクトx1は、「リスト」ですか？

```
> is.data.frame(Bocy)
```
オブジェクトBodyは、「データフレーム」ですか？

10-2. オブジェクトの取り扱い・消去

オブジェクトを消去（例えばオブジェクトXの定義やXに入っている値を消したい場合)

```
> x1 <- c(19,23,27,35,44,51,59,66)
```
オブジェクトx1に数値データを入れた

```
> rm(x1)
```
オブジェクトx1を消去する

```
> x1
エラー: オブジェクト 'x' がありません
```
オブジェクトx1は消去されているので
当然存在しないはず

```
> x1 <- c(19,23,27,35,44,51,59,66)
```
オブジェクトx1をもう一回入力

```
> x1
[1] 19 23 27 35 44 51 59 66
```
オブジェクトx1の中身を表示させる、
ちゃんと中身があるね。

＊自分の好きなオブジェクト名を使ってデータを取り扱っていくと思うが、
やっぱりこの名前を変えたいとか、
このオブジェクトに入れたデータが大きくて邪魔だし、その後もう使わないな、
というときにはオブジェクトを消去してしまえば良い。

10-3. オブジェクトの取り扱い・存在確認

今あるオブジェクトの存在確認をしたい時

```
> objects()
```

オブジェクト何が今あるっけ？

```
[1] "Body" "x1"   "y1"
```

例えばこんな感じ。（今ここには3つのオブジェクトがある様子です）
皆さんは今はもっとオブジェクトがあるかなと思います。

＊自分の好きなオブジェクト名を使ってデータを取り扱っていくと思うが、
オブジェクトが増えていくと、どんなオブジェクトが存在しているか
わからなくなってしまうこともあるでしょう。その時に一覧を眺めましょう。

10-4. オブジェクトの取り扱い・オブジェクト名

オブジェクト名はだいたい何でもいいけど以下には注意

＊Rのコマンドや内部処理で紛らわしい物は使わない
例えば以下はオブジェクト名としては使えない（そりゃそうだって感じもするね）

break　else　for　function　if　TRUE　in　next　repeat　return　while　FALSE

＊R は大文字と小文字を区別する
従って x と X は異なるものとして R は認識する
やってみてね。

10-4. オブジェクトの取り扱い・オブジェクト名

【課題 10-4A】
ここまでに行ったオブジェクトの取り扱い・オブジェクト名に関する実行画面（Rのコマンドを打っている画面）のスクリーンショットを提出せよ。主に、10-1からここまでの内容が行われていることが確認できればそれで良い。

◎ ファイル名
ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事
※YYには自分の番号をふた桁の数字で入れる事
※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。
◎ 提出締切；次回の授業の前日の18:00まで

11-1. 回帰分析

ここまででは、みなさんがこれまでの実験レポートなどで馴染み深い、
散布図にプロットされたデータに近似直線を入れる、という流れで練習をします。
これはもう少しちゃんと説明すると、回帰分析の中のひとつの方法です。

回帰分析というのは、量で表現される値（数字のデータが主ですね；量的変数と呼んだりします）を組みにして一方でもう一方を説明しようとする式を求めるものです。

XとYという変数の間の関係として、片方の変数Xからもう片方の変数Yを説明する式を求めるということですね。この関係式のことを回帰式と呼びます。
（いくつかの点のまとまりをひとつの線で代表することを回帰と言います。）

これまでの実験で何度もやっているのでイメージしやすいのではないかと思いますが、
Y=aX+bという数式を求めましたよね。変数Xで変数Yを説明するという感じですね。

この、説明されるYという変数のことを応答変数（従属変数）と呼び、
説明する変数Xを説明変数（または独立変数）と呼びます。

描いた散布図において最も適合した（フィットした）式を求めることが回帰です。
この回帰の関係を直線で表すのを線形回帰（直線回帰）と呼びます。
しかも、説明変数がひとつの場合を単回帰と呼びます。

11-2. 近似直線の挿入（単回帰）

散布図を描いて、その上に近似直線を描きたい

```
> x1 <- c(19,23,27,35,44,51,59,66)
> y1 <- c(124,117,120,132,128,142,143,135)
```

オブジェクトx1とy1にデータを代入

```
> x1
[1] 19 23 27 35 44 51 59 66
> y1
[1] 124 117 120 132 128 142 143 135
```

オブジェクトx1とy1を確認

```
> plot(y1 ~ x1)
```

この「ニョロ」は「チルダ」と呼ばれる文字です。打てますか？

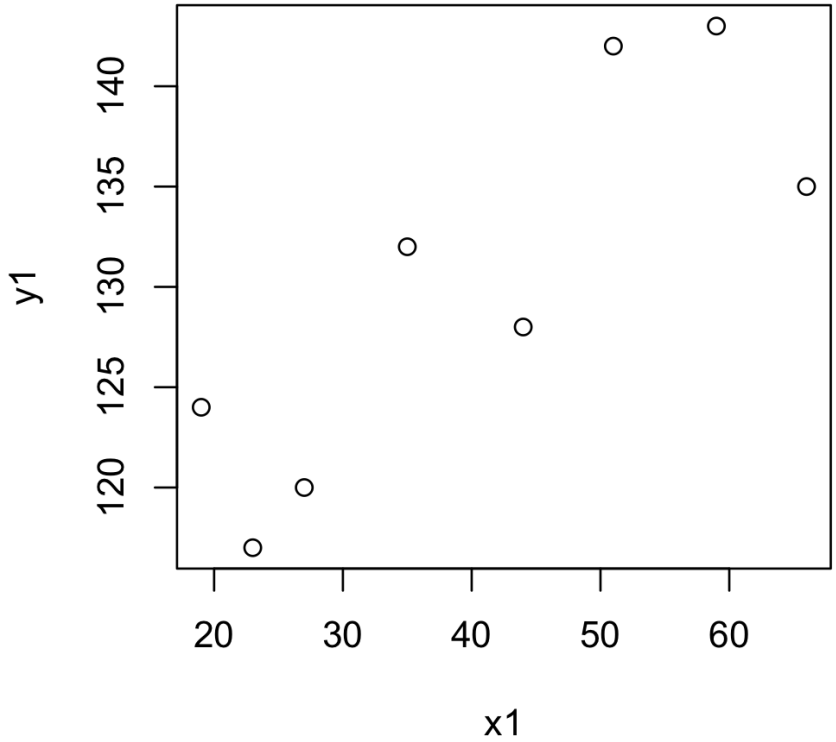

11-2. 近似直線の挿入（単回帰）

散布図を描いて近似直線を描きたい

```
> x1 <- c(19,23,27,35,44,51,59,66)
> y1 <- c(124,117,120,132,128,142,143,135)
```

オブジェクトx1とy1にデータを代入
（このデータは年齢と血圧のデータでした）
ちなみに血圧が基準よりも低くても心不全などのリスクがあるらしいよ

```
> x1
[1] 19 23 27 35 44 51 59 66
> y1
[1] 124 117 120 132 128 142 143 135
```

オブジェクトx1とy1を確認

```
> plot(y1 ~ x1)
```

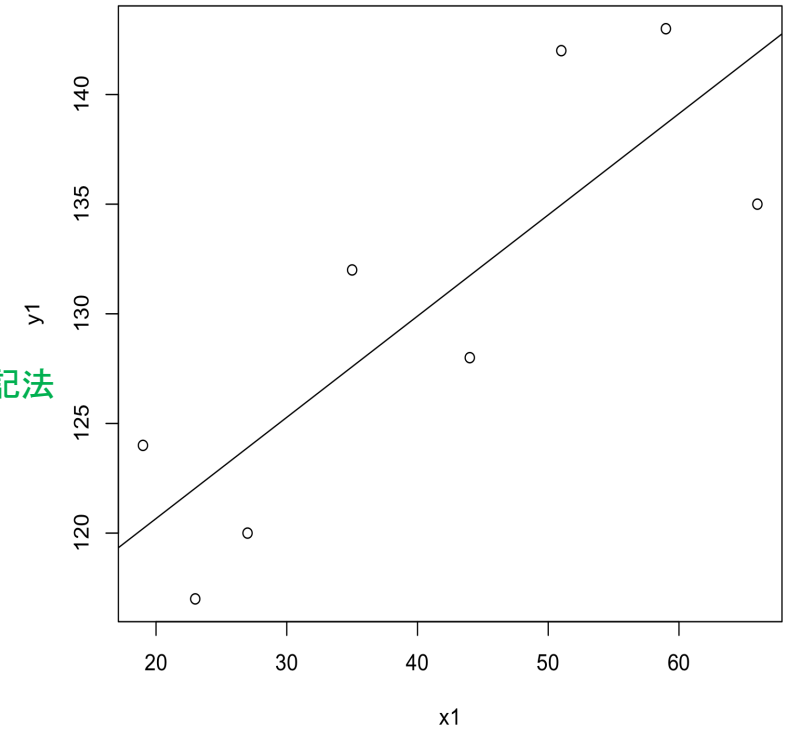


```
> result <- lm(y1~x1)
```

y ~ x は formula とよばれるオブジェクト。
y = a + b x の形の線形回帰直線を表現する記法

このlmはlinear modelの意味。直線回帰を行うよということ。その結果をここではresultという名前のオブジェクトに代入しました。オブジェクトの名前は何でもいいですよ。

```
> abline(result, ylim=c(110,150))
```

前に求めたresultの値を用いて、ablineで線を引きます
グラフ上に回帰直線が引けたでしょうか？

11-2. 近似直線の挿入（単回帰）

【課題 11-2A】
ここで描いたグラフをPDFファイルとして保存し提出せよ。

◎ ファイル名
ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事
※YYには自分の番号をふた桁の数字で入れる事
※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。
◎ 提出締切；次回の授業の前日の18:00まで

11-3. 近似直線の挿入（単回帰）、具体的な式を求める

回帰直線を確認しよう

```
> plot(y1 ~ x1)
```
←前にもやったけどニョロはチルダと呼ばれる記号でキーボード右上の方にあるやつ

```
> result <- lm (y1~x1)
```
←lm()で直線回帰

```
> abline(result, ylim=c(110,150))
```
←abline()で線を引く

```
> result
```
←オブジェクトresultのなかに回帰直線の情報が入っている

```
Call:
lm(formula = y1 ~ x1)

Coefficients:
(Intercept)        x1
  111.4305    0.4616
```

切片　　傾き

Y = 0.4616 x + 111.4305　ということですね。

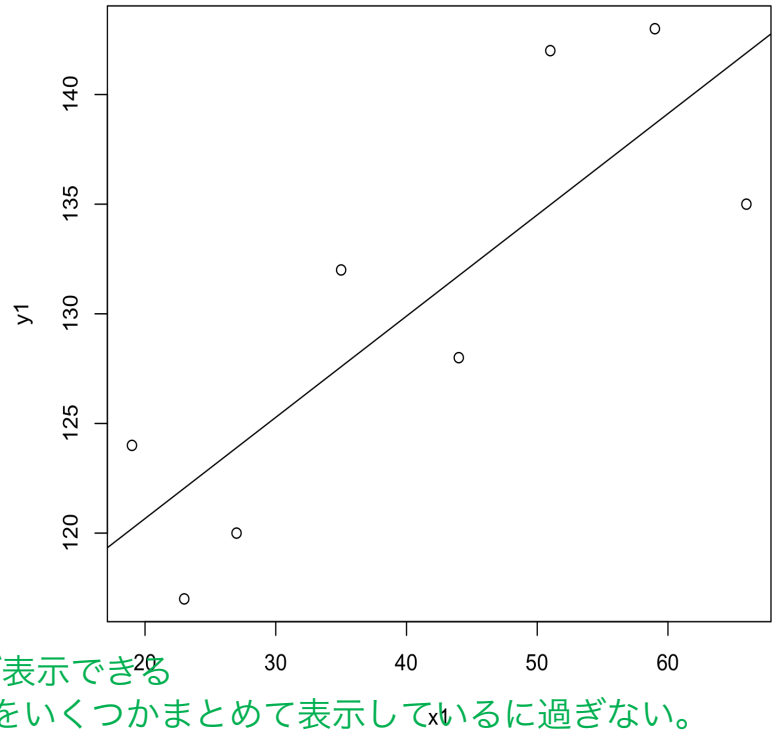


```
> names(result)
```
オブジェクトすべての成分はnames()を使えば表示できる
ちなみに、summaryではこれらのうちの結果をいくつかまとめて表示しているに過ぎない。

```
[1] "coefficients" "residuals" "effects" "rank" "fitted.values" "assign" "qr" "df.residual" "xlevels" "call" "terms" "model"
```

11-3. 近似直線の挿入（単回帰）、具体的な式を求める

ちなみに、
オブジェクトの内容を情報付きで表示する
場合は関数 str() を用いて確認する事もできる

```
> str(result)
```

なに書いてあるんだかわからねー！
ってならないで落ち着いて。
12項目があるんだね。

```
List of 12
① $ coefficients : Named num [1:2] 111.43 0.462
  ..- attr(*, "names")= chr [1:2] "(Intercept)" "x1"
② $ residuals    : Named num [1:8] 3.8 -5.05 -3.89 4.41 -3.74 ...
  ..- attr(*, "names")= chr [1:8] "1" "2" "3" "4" ...
③ $ effects      : Named num [1:8] -368.05 21.13 -4.06 3.41 -5.69 ...
  ..- attr(*, "names")= chr [1:8] "(Intercept)" "x1" "" "" ...
④ $ rank         : int 2
⑤ $ fitted.values: Named num [1:8] 120 122 124 128 132 ...
  ..- attr(*, "names")= chr [1:8] "1" "2" "3" "4" ...
⑥ $ assign       : int [1:2] 0 1
⑦ $ qr           :List of 5
  ..$ qr   : num [1:8, 1:2] -2.828 0.354 0.354 0.354 0.354 ...
  .. ..- attr(*, "dimnames")=List of 2
  .. .. ..$ : chr [1:8] "1" "2" "3" "4" ...
  .. .. ..$ : chr [1:2] "(Intercept)" "x1"
  .. ..- attr(*, "assign")= int [1:2] 0 1
  ..$ qraux: num [1:2] 1.35 1.26
  ..$ pivot: int [1:2] 1 2
  ..$ tol  : num 1e-07
  ..$ rank : int 2
  ..- attr(*, "class")= chr "qr"
⑧ $ df.residual  : int 6
⑨ $ xlevels      : Named list()
⑩ $ call         : language lm(formula = y1 ~ x1)
⑪ $ terms        :Classes 'terms', 'formula'  language y1 ~ x1
  .. ..- attr(*, "variables")= language list(y1, x1)
  .. ..- attr(*, "factors")= int [1:2, 1] 0 1
  .. .. ..- attr(*, "dimnames")=List of 2
  .. .. .. ..$ : chr [1:2] "y1" "x1"
  .. .. .. ..$ : chr "x1"
  .. ..- attr(*, "term.labels")= chr "x1"
  .. ..- attr(*, "order")= int 1
  .. ..- attr(*, "intercept")= int 1
  .. ..- attr(*, "response")= int 1
  .. ..- attr(*, ".Environment")=<environment: R_GlobalEnv>
  .. ..- attr(*, "predvars")= language list(y1, x1)
  .. ..- attr(*, "dataClasses")= Named chr [1:2] "numeric" "numeric"
  .. .. ..- attr(*, "names")= chr [1:2] "y1" "x1"
⑫ $ model        :'data.frame':      8 obs. of  2 variables:
  ..$ y1: num [1:8] 124 117 120 132 128 142 143 135
  ..$ x1: num [1:8] 19 23 27 35 44 51 59
  ..- attr(*, "terms")=Classes 'terms', 'for
  .. .. ..- attr(*, "variables")= language list
  .. .. ..- attr(*, "factors")= int [1:2, 1] 0 1
  .. .. .. ..- attr(*, "dimnames")=List of 2
  .. .. .. .. ..$ : chr [1:2] "y1" "x1"
  .. .. .. .. ..$ : chr "x1"
  .. .. ..- attr(*, "term.labels")= chr "x1"
  .. .. ..- attr(*, "order")= int 1
  .. .. ..- attr(*, "intercept")= int 1
  .. .. ..- attr(*, "response")= int 1
  .. .. ..- attr(*, ".Environment")=<enviro
  .. .. ..- attr(*, "predvars")= language list
  .. .. ..- attr(*, "dataClasses")= Named ch
  .. .. .. ..- attr(*, "names")= chr [1:2] "y1
 - attr(*, "class")= chr "lm"
```

①$ coefficients　係数
②$ residuals　残差
③$ effects
④$ rank
⑤$ fitted.values　予測値
⑥$ assign
⑦$ qr
⑧$ df.residual
⑨$ xlevels
⑩$ call
⑪$ terms
⑫$ model

11-3. 近似直線の挿入（単回帰）、具体的な式を求める

ちなみに、
オブジェクトの内容を情報付きで表示する
場合は関数 str() を用いて確認する事もできる

```
> str(result)
```

なに書いてあるんだかわからねー！
ってならないで落ち着いて。
12項目があるんだね。

```
List of 12
① $ coefficients : Named num [1:2] 111.43 0.462
  ..- attr(*, "names")= chr [1:2] "(Intercept)" "x1"
② $ residuals    : Named num [1:8] 3.8 -5.05 -3.89 4.41 -3.74 ...
  ..- attr(*, "names")= chr [1:8] "1" "2" "3" "4" ...
③ $ effects      : Named num [1:8] -368.05 21.13 -4.06 3.41 -5.69 ...
  ..- attr(*, "names")= chr [1:8] "(Intercept)" "x1" "" "" ...
④ $ rank         : int 2
⑤ $ fitted.values: Named num [1:8] 120 122 124 128 132 ...
  ..- attr(*, "names")= chr [1:8] "1" "2" "3" "4" ...
⑥ $ assign       : int [1:2] 0 1
⑦ $ qr           :List of 5
  ..$ qr   : num [1:8, 1:2] -2.828 0.354 0.354 0.354 0.354 ...
  .. ..- attr(*, "dimnames")=List of 2
  .. .. ..$ : chr [1:8] "1" "2" "3" "4" ...
  .. .. ..$ : chr [1:2] "(Intercept)" "x1"
  .. ..- attr(*, "assign")= int [1:2] 0 1
  ..$ qraux: num [1:2] 1.35 1.26
  ..$ pivot: int [1:2] 1 2
  ..$ tol  : num 1e-07
  ..$ rank : int 2
  ..- attr(*, "class")= chr "qr"
⑧ $ df.residual  : int 6
⑨ $ xlevels      : Named list()
⑩ $ call         : language lm(formula = y1 ~ x1)
```

つまりここで求めたresultというオブジェクトには、こんなに沢山の、回帰直線に関する成分の情報が入っているということ。

この中から一部のデータ項目を取り出すときは、ドルマーク＄を使ったらいいね。
（Bodyのデータで性別の列のデータを取り出した時にBody$Sexとやったのと同じような感じ）

だから、今注目したい項目、coefficients（切片と傾き）の情報だけを見るためには、result$coefficientsとすればいいことになるね。

このようにresultの中身を全部表示するといっぱい情報が出てきて（全ては今回は説明できないが時間があればおいおい説明する）しまうけれど、目下のところ必要な情報は限られている。単純に、オブジェクト名だけを打てば(ここではresult)、よく使う情報をすぐ見ることはできる。情報を要約して見るためにはsummary()という方法で表示させたら見やすい。

```
  .. .. .. ..- attr(*, "names")= chr [1:2] "y1" "x1"
  - attr(*, "class")= chr "lm"
```

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
```
データの要約が欲しい場合は関数 summary() を用いる

```
Call:
lm(formula = y1 ~ x1)

Residuals:
 Min       1Q      Median     3Q      Max
-6.8956  -4.1819  0.0293    4.3551   7.0283

Coefficients:
                Estimate    Std. Error   t value    Pr(>|t|)
(Intercept) 111.4305    5.5588      20.046    1e-06 ***
x1                0.4616     0.1275       3.622     0.0111 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,      Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

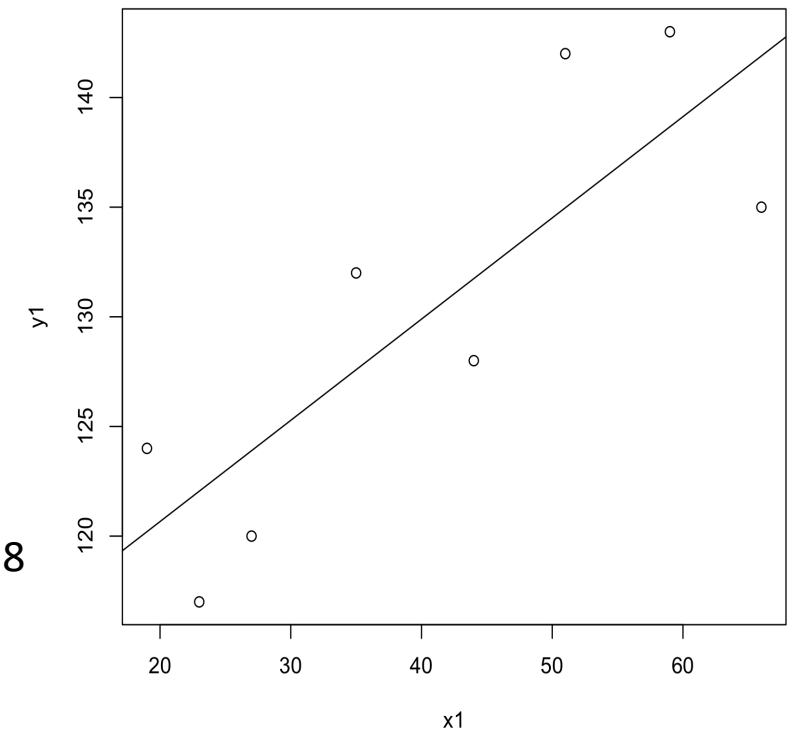

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
     Min      1Q  Median      3Q     Max
-6.8956 -4.1819  0.0293  4.3551  7.0283

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 111.4305     5.5588  20.046  1e-06 ***
x1            0.4616     0.1275   3.622   0.0111 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,	Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

最小値　第1四分位　中央値　第3四分位　最大値

Residualsは残差という意味です。図の矢印の部分の、測定データと、回帰直線上の予測値の、差を意味してます。この残差のばらつきがどんな感じかを記してくれています。Minは最小値、Medianは中央値、Maxは最大値
1Qや3Qは第１第３四分位点でしたね
（箱ひげ図を思い出して）

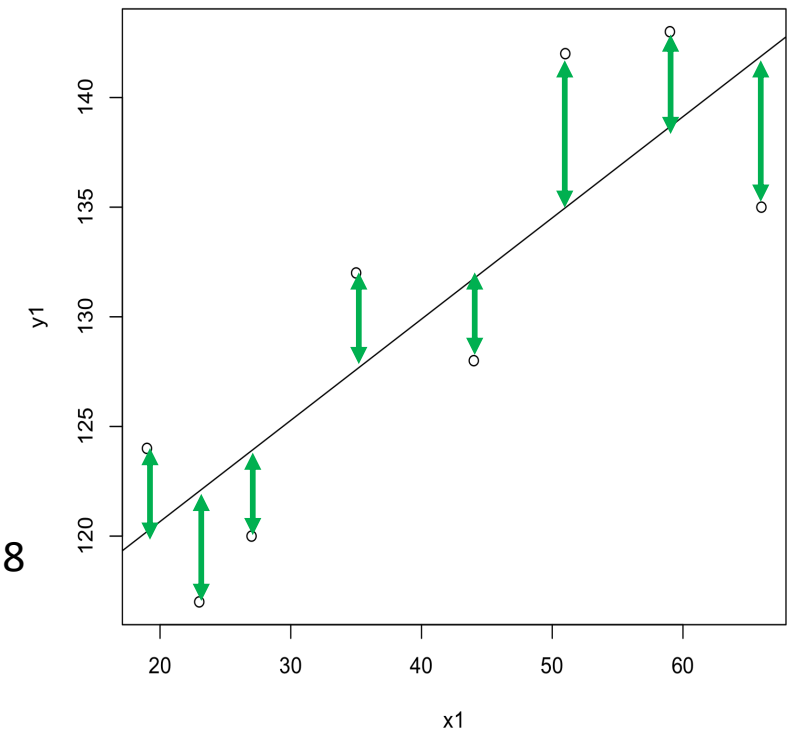

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
     Min      1Q  Median      3Q     Max
-6.8956 -4.1819  0.0293  4.3551  7.0283
```

最小値　第1四分位　中央値　第3四分位　最大値

Residualsは残差という意味です。図の矢印の部分の、測定データと、回帰直線上の予測値の、差を意味してます。この残差のばらつきがどんな感じかを記してくれています。Minは最小値、Medianは中央値、Maxは最大値
1Qや3Qは第１第３四分位点でしたね
（箱ひげ図を思い出して）

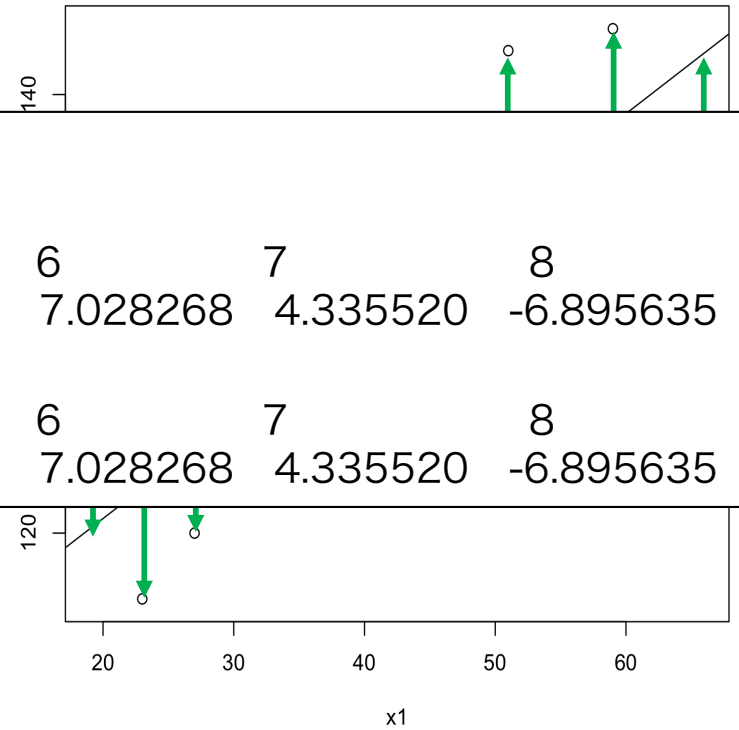

残差を確認する方法はこんな感じ

```
> residual(result)
1        2        3        4        5        6        7        8
3.799260 -5.047114 -3.893488  4.413764 -3.740577  7.028268  4.335520 -6.895635
> result$residual
1        2        3        4        5        6        7        8
3.799260 -5.047114 -3.893488  4.413764 -3.740577  7.028268  4.335520 -6.895635
```

Residual standard error: 5.855 on 6 degrees of freedom
Multiple R-squared: 0.6861,　　Adjusted R-squared: 0.6338
F-statistic: 13.12 on 1 and 6 DF, p-value: 0.01107

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
     Min      1Q  Median      3Q     Max
-6.8956 -4.1819  0.0293  4.3551  7.0283
```

最小値　第1四分位　中央値　第3四分位　最大値

Residualsは残差という意味です。図の矢印の部分の、測定データと、回帰直線上の予測値の、差を意味してます。この残差のばらつきがどんな感じかを記してくれています。Minは最小値、Medianは中央値、Maxは最大値
1Qや3Qは第１第３四分位点でしたね
（箱ひげ図を思い出して）

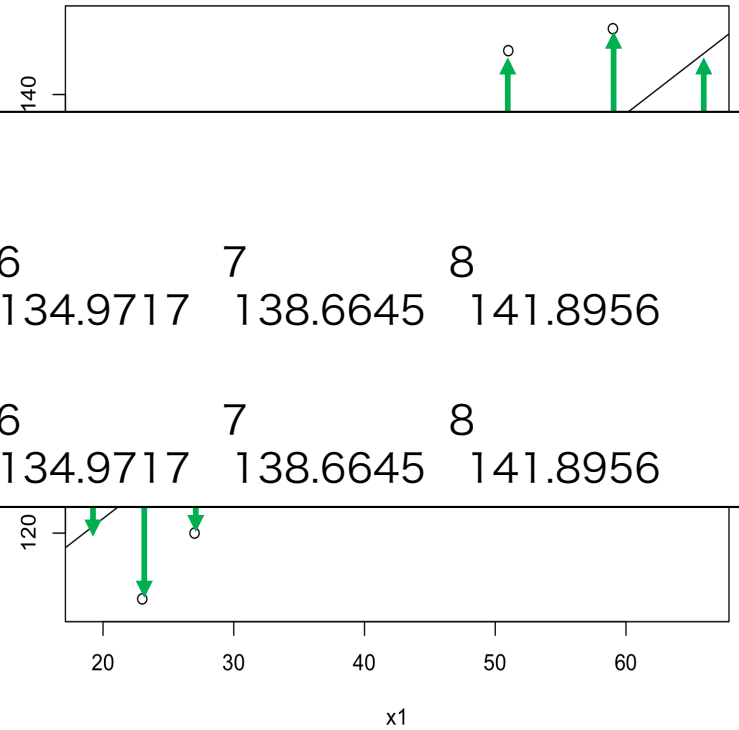

予測値を確認する方法はこんな感じ

```
> predict(result)
1        2        3        4        5        6        7        8
120.2007 122.0471 123.8935 127.5862 131.7406 134.9717 138.6645 141.8956
> result$fitted.values
1        2        3        4        5        6        7        8
120.2007 122.0471 123.8935 127.5862 131.7406 134.9717 138.6645 141.8956
```

Residual standard error: 5.855 on 6 degrees of freedom
Multiple R-squared: 0.6861,　　Adjusted R-squared: 0.6338
F-statistic: 13.12 on 1 and 6 DF, p-value: 0.01107

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
 Min      1Q      Median    3Q      Max
-6.8956  -4.1819  0.0293   4.3551   7.0283

Coefficients:
            Estimate   Std. Error  t value   Pr(>|t|)
(Intercept) 111.4305   5.5588      20.046    1e-06 ***
x1            0.4616   0.1275       3.622    0.0111 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,    Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

回帰係数（切片や傾き）の推定値　標準誤差　t値　p値

切片　傾き

Coefficientsは係数のこと。y=ax+bのaとかbね。
Interceptは切片（bのことね）, x1（aのことね）は傾き。

Estimateは推定値。つまり推定した回帰直線の、切片は111.4305で傾きは0.4616で、y=0.4616x+111.4305が推定した回帰直線だよということ。

標準誤差は推定値の標準偏差。測定値は母集団の一部だと考えた場合、データから推定した計算値は一定のばらつきを持つ。推定値±標準誤差の範囲内に真の回帰係数があるということ。

標準誤差とt値はP値を計算するためのものでもある。

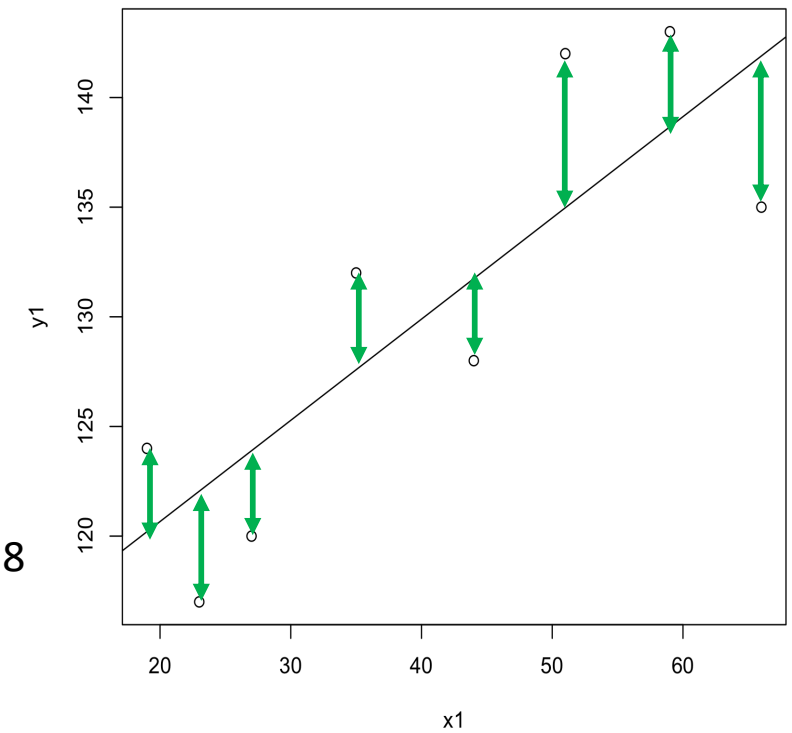

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
 Min       1Q      Median     3Q      Max
-6.8956  -4.1819  0.0293    4.3551   7.0283

Coefficients:
                Estimate   Std. Error  t value  Pr(>|t|)
(Intercept)     111.4305    5.5588     20.046   1e-06 ***
x1                0.4616    0.1275      3.622   0.0111 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,    Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

回帰係数（切片や傾き）の推定値

標準誤差

t値

p値

切片

傾き

P値は「回帰係数がゼロである」と仮定した場合に、それがどれくらいありえないか！ということの確率を検定結果として示している。

回帰係数がゼロであると仮定した時、実際に得られた値以上に回帰係数がゼロから離れる確率を示している。

つまり、回帰係数がゼロでないということが、どの程度確からしいかを示す値。そのため、この値が十分小さいと、ゼロでないという確信度が強まる。

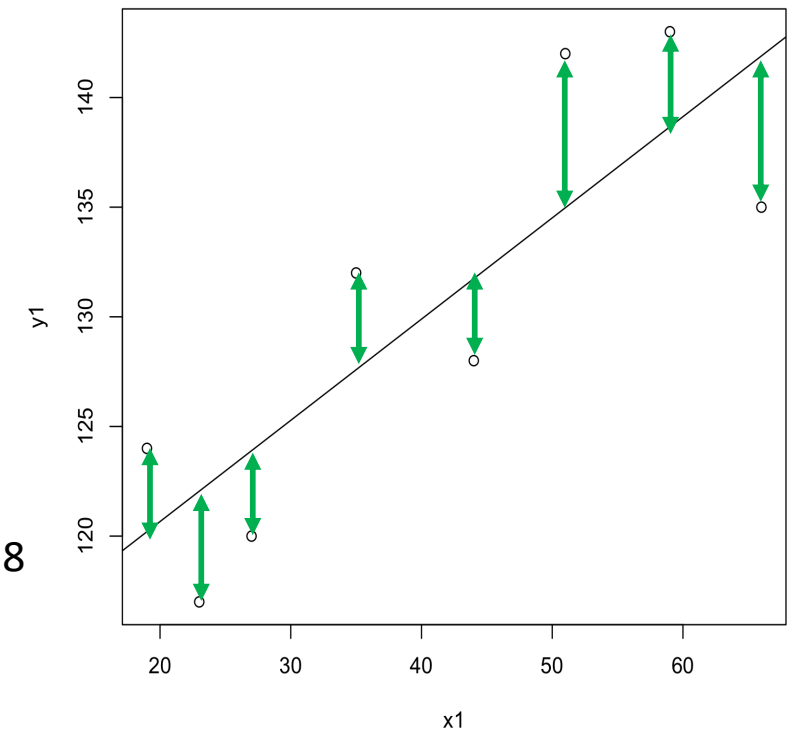

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
 Min      1Q      Median    3Q      Max
-6.8956  -4.1819  0.0293    4.3551   7.0283

Coefficients:
            Estimate   Std. Error  t value  Pr(>|t|)
(Intercept) 111.4305   5.5588      20.046   1e-06 ***
x1            0.4616   0.1275       3.622   0.0111 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,    Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

回帰係数（切片や傾き）の推定値

標準誤差

t値

p値

切片

傾き

P値のところについているアスタリスク * は
その下のところに書かれている基準を満たしている場合に
その基準にあった印がつけられているだけのこと。

この記号は有意性の判断基準を示している
0.001よりも小さい場合は***をつける＝有意水準 0.1% で有意という意味
0.01 よりも小さい場合は** をつける＝有意水準 1% で有意という意味
0.05 よりも小さい場合は* をつける＝有意水準 5% で有意という意味
0.1 よりも小さい場合は. をつける＝有意水準 10% で有意という意味

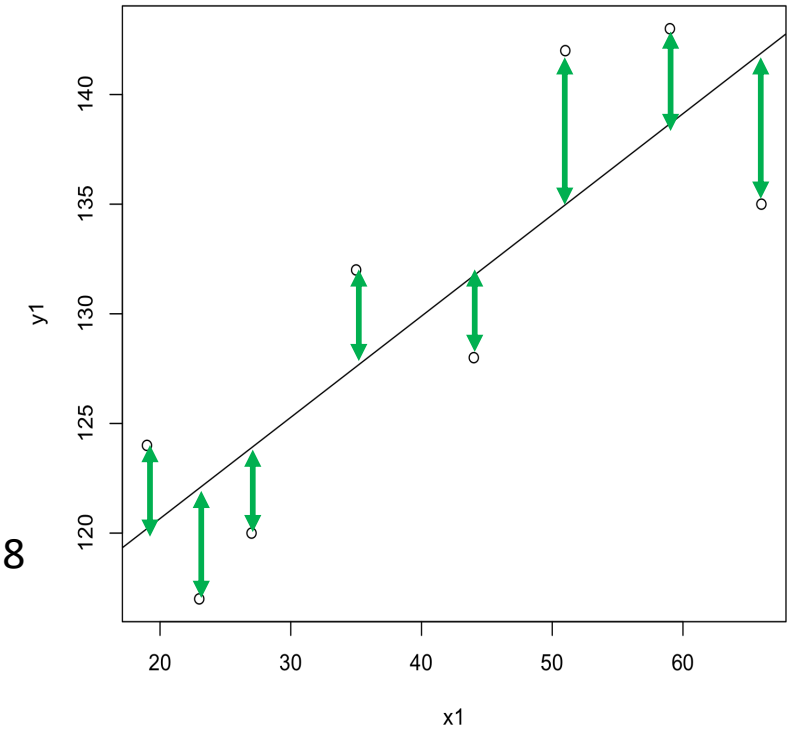

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
 Min       1Q      Median     3Q      Max
-6.8956  -4.1819  0.0293    4.3551   7.0283

Coefficients:
            Estimate    Std. Error   t value   Pr(>|t|)
(Intercept) 111.4305    5.5588       20.046    1e-06 ***
x1            0.4616    0.1275        3.622    0.0111 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

残差の標準誤差                                    自由度
Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,      Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

残差標準誤差　Residual standard error
残差標準誤差の自由度　Degrees of freedom
ここでは残差の標準誤差は5.835、
自由度は6と言っている

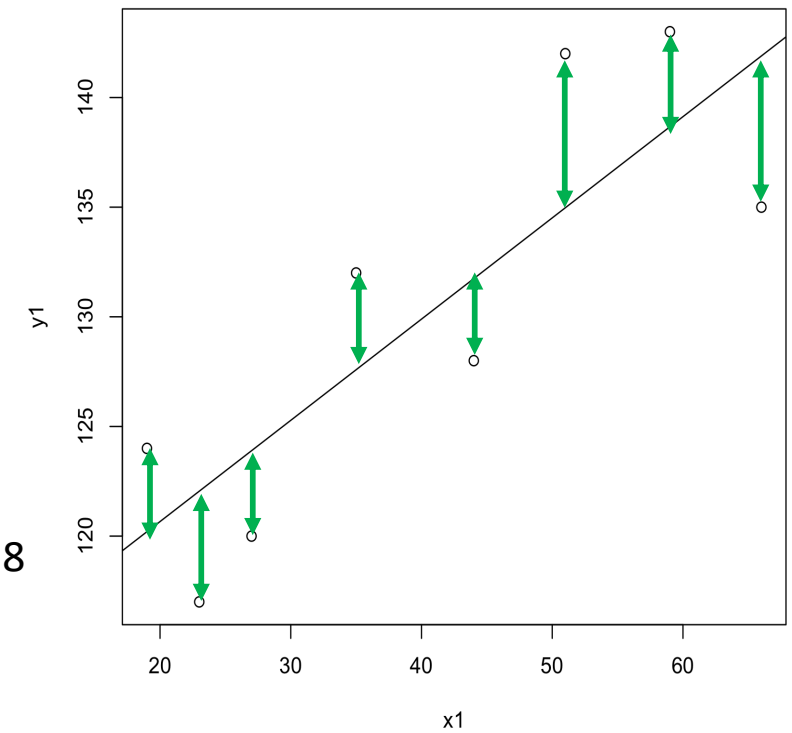

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
 Min       1Q      Median     3Q      Max
-6.8956  -4.1819  0.0293   4.3551   7.0283

Coefficients:
            Estimate    Std. Error  t value   Pr(>|t|)
(Intercept) 111.4305    5.5588      20.046    1e-06 ***
x1            0.4616    0.1275       3.622    0.0111 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,    Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

F検定

「自由度修正済み決定係数」
（また次回以降時間のある時にまわします）

R^2値という言葉でおなじみの「決定係数（寄与率）」
回帰直線がどの程度データにフィットしているかを評価する指標でしたね。回帰直線によって観測値のばらつきがどの程度説明されているかを示している。つまり、 yの変動の何％がxで説明できるかを表したもの。(0,86であればyの変動の86%をxで説明がつく、1であればyの変動の100%をxで説明がつくということ）
決定係数は0から1の間の値を取る。1に近いほど回帰直線の説明力が高く、ちょうど1になったときには全ての観測値が直線上に並ぶ（そんなことは普通の観測ではありえない）。

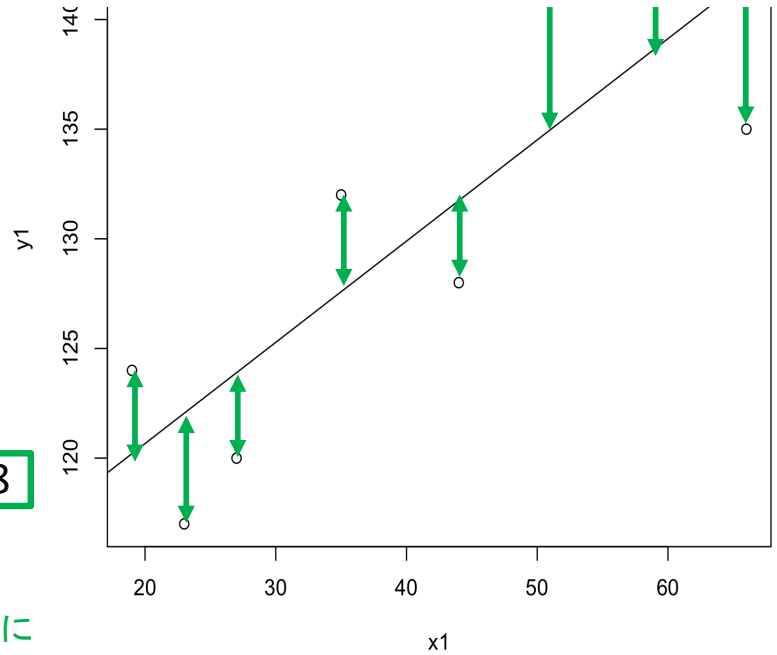

11-4.具体的な近似式とデータの要約

回帰直線を確認しよう

```
> summary(result)
Call:
lm(formula = y1 ~ x1)

Residuals:
 Min       1Q      Median     3Q      Max
-6.8956  -4.1819  0.0293   4.3551   7.028

Coefficients:
            Estimate    Std. Error   t value   Pr(>|t|)
(Intercept) 111.4305    5.5588       20.046    1e-06 ***
x1            0.4616    0.1275        3.622    0.0111 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.835 on 6 degrees of freedom
Multiple R-squared:  0.6861,      Adjusted R-squared:  0.6338
F-statistic: 13.12 on 1 and 6 DF,  p-value: 0.01107
```

F検定

回帰の分散分析のF値およびその自由度(DF)と、対応するP値が書かれている。説明変数の係数がすべて 0 であるという帰無仮説（この場合は H_0 : β = 0）に対するF検定統計量と分子・分母の自由度 DF、および p 値である。
F検定の値は、回帰直線全体の有効性に関する検定結果を示している。回帰係数がゼロでない場合に大きくなる傾向がある。 p値が十分小さいと回帰モデルを用いる必要がないという仮説を否定した事になる。

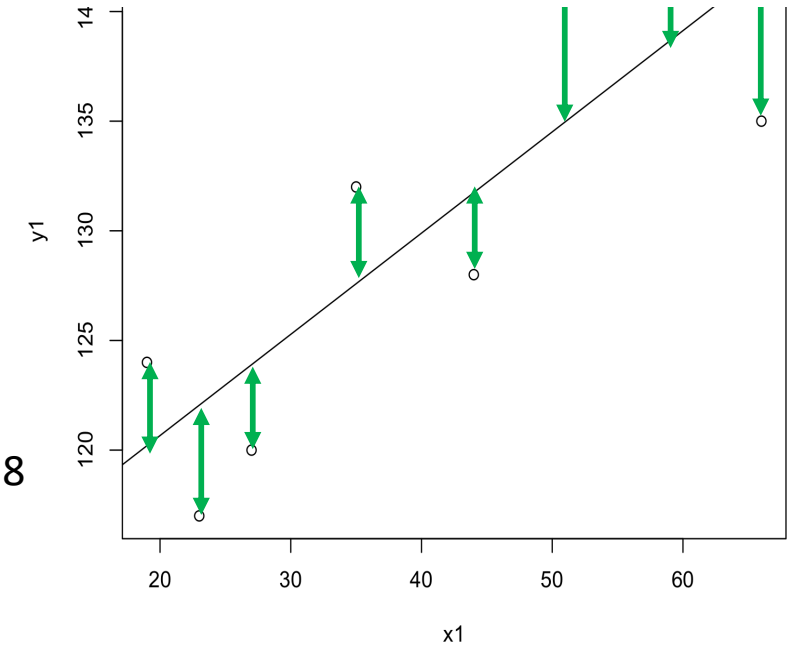

11-4. 具体的な近似式とデータの要約

【課題 11-4A】
ここまでに行った、近似直線の挿入に伴う具体的な式やデータの要約を確認する工程について実行画面（Rのコマンドを打っている画面）のスクリーンショットを提出せよ。主に、11-3から11-4の内容が、行われていることを確認できればそれで良い。

◎ ファイル名
ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事
※YYには自分の番号をふた桁の数字で入れる事
※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。
◎ 提出締切；次回の授業の前日の18:00まで

11-5. 図に具体的な近似式を記す

で、さっきのページ、もとに戻ってきて…

回帰直線を確認しよう

```
> plot(y1 ~ x1)
```
←前にもやったけどニョロはチルダと呼ばれる記号でキーボード右上の方にあるやつ

```
> result <- lm (y1~x1)
```
←lm()で回帰直線を引く

```
> abline(result, ylim=c(110,150))
```
←abline()で線を引く

```
> result
```
←オブジェクトresultのなかに回帰直線の情報が入っている

```
Call:
lm(formula = y1 ~ x1)

Coefficients:
(Intercept)          x1
  111.4305       0.4616
```

```
> result$coefficients
```
←ドルマークを使って、resultの情報成分から coefficientsの部分を選択しているということね

```
(Intercept)          x1
111.4304628   0.4615935
```

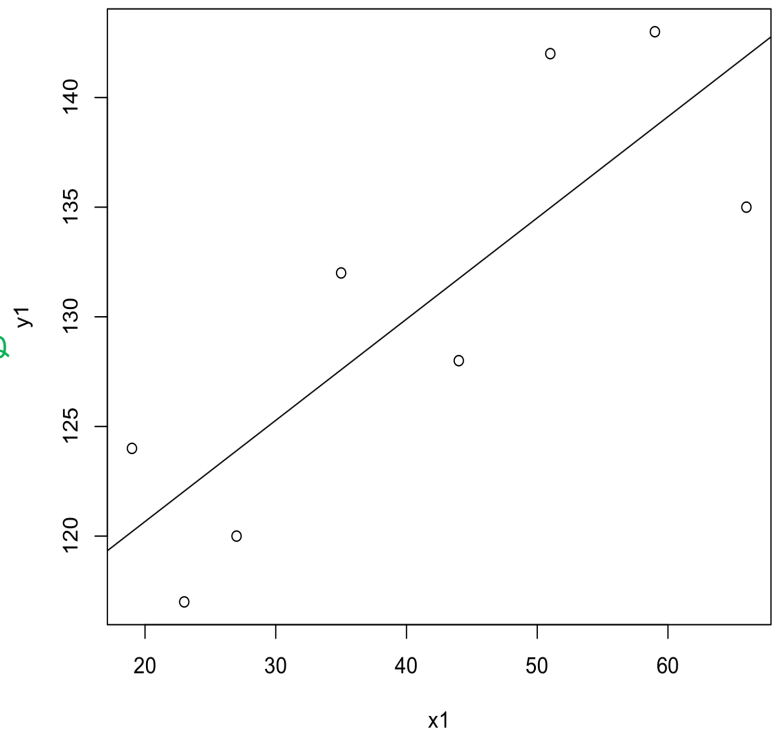

11-5. 図に具体的な近似式を記す

回帰直線を確認しよう

```
> result$coefficients
(Intercept)        x1
111.4304628  0.4615935
```

←ドルマークを使って、resultの情報成分からcoefficientsの部分を選択しているということね

```
> is.vector(result$coefficients)
[1] TRUE
```

←選択した情報はベクトルかどうかを確認、ベクトルと言っている。

```
> length(result$coefficients)
[1] 2
```

←ベクトルならば要素の数だけ長さを持つ、長さを確認すると2だから要素は2個あるということ

```
> result$coefficients[1]
(Intercept)
  111.4305
```

←ベクトルの１つ目の要素を確認　ベクトルを要素とするオブジェクト名の後ろに[]をつけてその中に何番目の要素かを表す数字をかけば良い

```
> result$coefficients[2]
      x1
0.4615935
```

←ベクトルの２つ目の要素を確認

＊ベクトルの要素の
１つ目に切片の情報、
２つ目に傾きの情報がはっていることがわかった。

11-5. 図に具体的な近似式を記す

回帰直線を確認しよう

```
> plot(y1 ~ x1)
> result <- lm (y1~x1)
> abline(result, ylim=c(110,150))
> text(20, 145, “kaiki-shiki”)
```

←前にもやったけどニョロはチルダと呼ばれる記号でキーボード右上の方にあるやつ

←abline()で線を引く

←abline()で線を引く

←text(x座標, y座標, 書きたい文字, 文字サイズ)で文字を書く

ここではkaiki-shikiという
アルファベットの文字列を
この位置に書き記してみた。

座標を変えたり文字を変えたりして試し、
上書きしながらグラフ上に文字を記入できることを
いくつか行って確認せよ。

さて、このような感じで、
回帰式　y=0.4616x+111.4305　を記したいところだね。

↑ これは result$coefficients[2] だったね。

↑ これは result$coefficients[1] だったね。

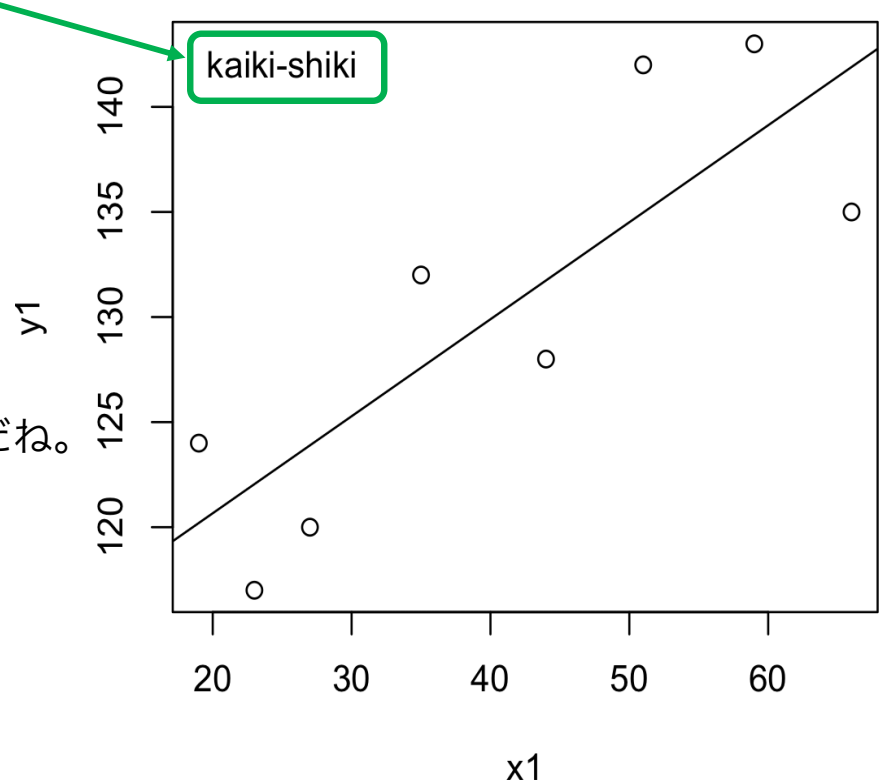

11-5. 図に具体的な近似式を記す

回帰直線を確認しよう

```
> sprintf("%f", result$coefficients[2])
[1] "0.461594"
```

←sprintf()でオブジェクトを表示できる。
書式（何桁で表示とか、も実際は可能。今回はとりあえず無視）。

```
> sprintf("%f,%f", result$coefficients[2],  result$coefficients[1])
[1] "0.461594,111.430463"
```

←sprintf()でオブジェクトを２つ並べて表示もできる。

```
> sprintf("y = %f x + %f", result$coefficients[2],  result$coefficients[1])
[1] "y = 0.461594 x + 111.430463"
```

←sprintf()でオブジェクトを使って
数式書くならこんな感じ。

11-5. 図に具体的な近似式を記す

回帰直線を確認しよう

```
> plot(y1 ~ x1)
> result <- lm (y1~x1)
> abline(result, ylim=c(110,150))
> text(35, 140, sprintf("y = %f x + %f", result$coefficients[2],  result$coefficients[1]))
```

←前にもやったけどニョロはチルダと呼ばれる記号でキーボード右上の方にあるやつ

←lm()で回帰直線を求める

←abline()で線を引く

できたー！
これでプロットしたデータに対する
回帰直線を描画し、
その直線の式をグラフ上に記すことができた。

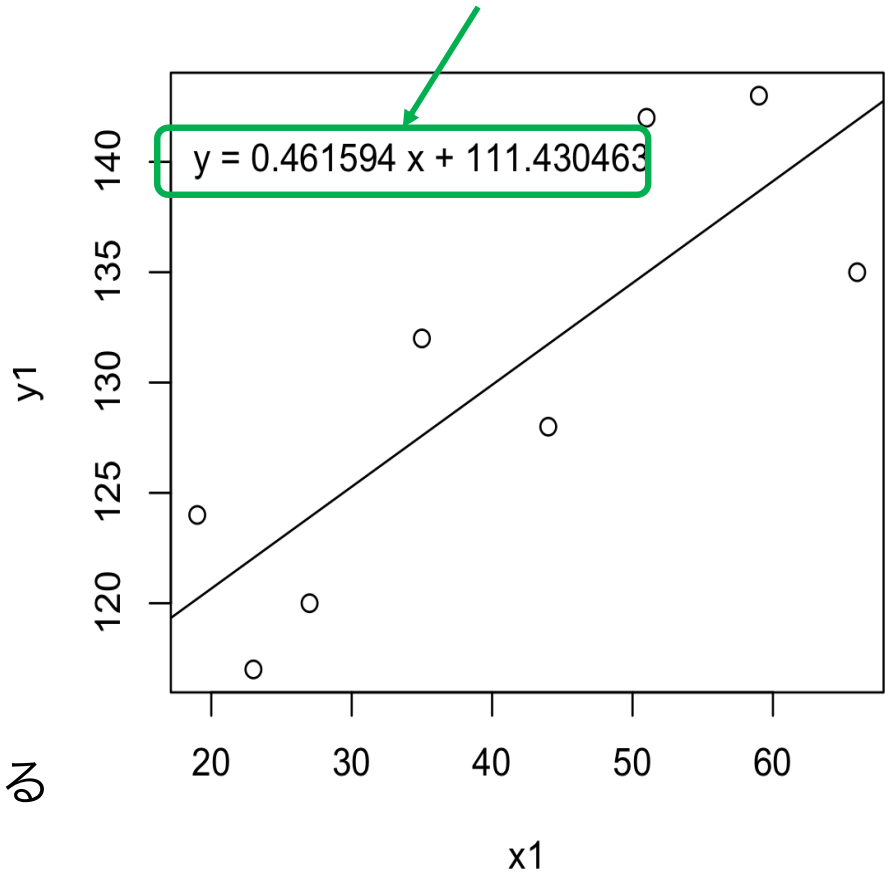

他にも方法はありますが、
Rの基本的な使い方を理解しながら
グラフを作れるようになるために
今回のようなステップを踏みました。

少しは理解できたかな？

観測値から回帰モデル（＝この式のこと）を作る
という回帰分析の目的を達成できた！

11-5. 図に具体的な近似式を記す

【課題 11-5A】
ここで作成したグラフのPDFファイルを提出せよ。

◎ ファイル名
ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事
※YYには自分の番号をふた桁の数字で入れる事
※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。
◎ 提出締切；次回の授業の前日の18:00まで

11-6. 特定の条件のデータを抜き出して解析

条件を決めて（例えば今回は性別ごと）該当部分のデータを抽出→プロットの流れ

一方の性別のデータだけを使って、身長と体重の関係を散布図にプロットし、
回帰直線を挿入してみよう。

```
> plot(Body_F[,8] ~ Body_F[,7], xlab="Weight", ylab="Height", col="red")
```

↑ ニョロはチルダというやつで、キーボードの右上の方にあるやつね。覚えているかな？

```
> result_F <- lm(Body_F[,8] ~ Body_F[,7])
```

直線回帰するよ、データをresult_Fにいれた。

```
> abline(result_F, xlab="", ylab="", col="red")
```

回帰直線を描画。
軸ラベルをからっぽにしておけば前に書いた軸ラベルの上に
上書きされる文字が空っぽとなりきれいなグラフになる

```
> text(自分で考える)
```

回帰直線の式をグラフ上に書きたいなあ。。。

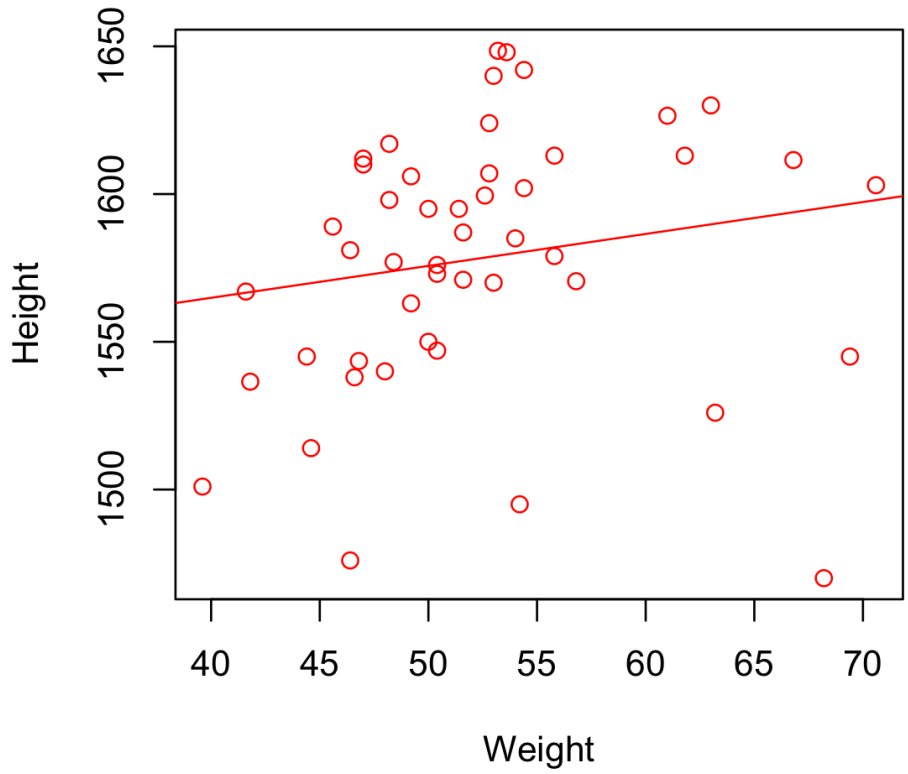

11-6. 特定の条件のデータを抜き出して解析

【課題 11-6A】
ここで作成したグラフ（性別Fのデータを使いました）に加えて、もうひとつ同じようにグラフを作成し（性別Mのデータを使って、色は赤ではなく違う色に変えよう）、出来上がった２つのグラフをひとつのPDFファイルにまとめて提出せよ。

◎ ファイル名
ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事
※YYには自分の番号をふた桁の数字で入れる事
※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。
◎ 提出締切；次回の授業の前日の18:00まで