

第08回 (2026.05.20)

データマイニング概論

※すべての授業資料について著作権を放棄していません。そのため、科目受講者が、自己の授業受講以外の目的で資料を電子的もしくは紙媒体等によって他者へ有償無償のいずれによらず譲渡することは禁止されています。授業受講者はこのことを理解したうえで受講しているとみなします。

熊本高等専門学校
生物化学システム工学科
木原 久美子 (専攻科棟3階)
kihara@kumamoto-nct.ac.jp

0-1. もくじ

0-1. 目次	15-1. 重回帰分析
0-2. 準備	15-2. データの状況確認
2-6. 最低限のコマンド一覧（復習）	15-3. 2組のデータの関係を見る
	15-4. 相関係数を見る
13-4. 単回帰分析まとめ	15-5. 重回帰モデル
	15-6. モデルの検証をするために
	15-7. 練習1-2

シラバス	←第01回
Rのインストール・準備・起動・使用練習	←第02回
ディレクトリ階層構造, 最低限のコマンド, ヘルプ, 四則演算, 代入, 行と列, 系列名, CSVファイル, データの読み込み, ヒストグラムの描画, 相対度数, 密度関数, 図の保存	←第03-04回
ソースファイルから複数の図をプロット	←第04回
散布図, 単回帰分析, マーカーの色種類, プロット重ね合わせ	←第05-07回
データ型・データ構造	←第05回
図へ文字列の書き込み, 凡例表示, 識別子	←第06回
特定のデータを抜き出して解析	←第06回
相関解析・相関係数／グループごとの解析	←第07回

0-2. 準備

特定のフォルダを作りそこに授業に関係するファイルを保存するようにしましょう。各自でいつも準備を進めておいて下さい。

- 自分で決めた場所にData_miningフォルダを作成
授業名がデータマイニング概論 (Data mining)なので。
- そのフォルダの中にclassXXフォルダを作成。
XXに01とか02とか、授業の回数を入れておけば見分けが付きやすい。
毎回、授業中に行う作業はこのフォルダの中に保存するようにせよ。

2-6. 最低限のコマンド・一覧（前回まで）

□Rを立ち上げる windowsのスタート→プログラム→R

□コマンドで居場所を確認&今日の場所に移動

getwd()	今自分がどこにいるか居場所を確認
setwd("../")	ひとつうえの階層のディレクトリに行く
getwd()	居場所を確認！

dir()	今いるディレクトリ内に何があるか見る
setwd("./class6")	ディレクトリ内のclass4に移動
getwd()	うまく移動できたかgetwdで確認


help(dir)	dirの使い方見たい時。helpで何でも分かる
q()	Rを終わりにしたいとき
	スペースを保存するか聞かれたら保存しないを選択

13-4. 単回帰分析 まとめ

単回帰分析をやってみよう

説明変数をつかって目的変数を予測しようとする手法では、説明変数がひとつの場合には**単回帰分析**とよんだ。

単回帰分析の場合には、**説明変数がひとつの場合**には、平面上に散らばる点に対してもっともらしい**直線 $y=ax+b$** を求めることが目的。




13-4. 単回帰分析 まとめ

単回帰分析をやってみよう

説明変数をつかって目的変数を予測しようとする手法では、説明変数がひとつの場合には**単回帰分析**とよんだ。

単回帰分析の場合には、**説明変数がひとつの場合**には、平面上に散らばる点に対してもっともらしい**直線** $y=ax+b$ を求めることが目的。




13-4. 単回帰分析 まとめ

単回帰分析をやってみよう

説明変数をつかって目的変数を予測しようとする手法では、説明変数がひとつの場合には**単回帰分析**とよんだ。

単回帰分析の場合には、**説明変数がひとつの場合**には、平面上に散らばる点に対してもっともらしい**直線** $y=ax+b$ を求めることが目的。回帰式があればxからyを予測できるようになるが、




13-4. 単回帰分析 まとめ

単回帰分析をやってみよう

説明変数をつかって目的変数を予測しようとする手法では、説明変数がひとつの場合には**単回帰分析**とよんだ。

単回帰分析の場合には、**説明変数がひとつの場合**には、平面上に散らばる点に対してもっともらしい**直線** $y=ax+b$ を求めることが目的。回帰式があればxからyを予測できるようになるが、実測値と予測値には差がある。




13-4. 単回帰分析 まとめ

単回帰分析をやってみよう

説明変数をつかって目的変数を予測しようとする手法では、説明変数がひとつの場合には**単回帰分析**とよんだ。

単回帰分析の場合には、**説明変数がひとつの場合**には、平面上に散らばる点に対してもっともらしい**直線** $y=ax+b$ を求めることが目的。回帰式があればxからyを予測できるようになるが、実測値と予測値には差がある。この差が最小になるような直線を求める（最小二乗法）ことで、データの散らばりを適切に代表する回帰直線を得ることができるというものであった。



残差は±両方向に存在するので、符号を考えなくても済むように、二乗して和をとって（平方和をとって）、この値が最小になるように回帰直線の傾きと切片を決めればよいということになる。

$$Y_i = a X_i + b + e_i$$


残差
residual

15-1. 重回帰分析


重回帰分析をやってみよう

説明変数をつかって目的変数を予測しようとする手法では、説明変数がひとつの場合には**単回帰分析**とよびました。説明変数がふたつ以上の場合を**重回帰分析**といいます。

単回帰分析の場合には、**説明変数がひとつの場合**には、平面上に散らばる点に対してもっともらしい**直線** $y=ax+b$ を求めました。



説明変数がふたつの場合には、3次元空間上に散らばる点に対してもっともらしい**平面** $z=ax+by+c$ を求めるのだという風に拡張できますね。



説明変数の数が増えてもn次元空間上の散布図に対するもっともらしいn-1次元平面を求めているというイメージですね。

15-1. 重回帰分析

重回帰分析をやってみよう

ではどんな時に重回帰分析を使う可能性があるでしょうか。

例えば、銭湯の利用者数は、天気、気温、湿度、曜日、などの説明変数を使って予測できる・説明できるのではないか？

例えば、温暖化の要因とされているオゾン層破壊において、オゾン濃度は、太陽の放射量、風力、気温、によって予測できる・説明できるのではないか？

例えば、コンビニの売上額は、周辺の人口、周辺の商店数、天気、弁当の種数、によって予測できる・説明できるのではないか？

といった感じに、複数の説明変数で目的変数を予測しようとする場合です。

15-1. 重回帰分析

【課題 15-1A】

前のページで例を挙げたように、複数の説明変数で目的変数を説明しようとするような例を5つ以上、考えてwordファイルに記しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

15-2. 重回帰分析：データの状況確認

重回帰分析をしよう；データを読み込む ([conveni.csv](#))

新たなコンビニの店舗を新装オープンすることになったが、
既存店のデータから新規店舗の今後の売上を予測できないだろうか？

ここでは、既に存在しているコンビニ（店番号付き）の売上額を、
周辺の人口、周辺の商店数、取り扱い弁当の種類、取り扱いお菓子種数、によって
予測することを考えよう。

	X_1	X_2	X_3	X_4	目的変数 $= Y$
店番号	人口[千人]	商店[店舗]	弁当[種類]	お菓子[種類]	売上[百万]
Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-2. 重回帰分析：データの状況確認

重回帰分析をしよう；データを読み込む（conveni.csv）


```
> Famima <- read.table("conveni.csv", header=T, sep=",")
```

```
> Famima[1:3,]
```

※csvファイルがUTF-8でエンコードされている場合には、
read.table(なんたらかんたら, fileEncoding="UTF-8")とすると
上手に読み込めるかと思います。

	Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	1	27	21	27	63	33
2	2	16	26	11	44	10
3	3	25	12	20	51	24

売上に直結している項目があるかもしれないので、
まずは、売上（Y）と、説明変数（X1～4）の関係を眺めてみよう。



店番号	X ₁ 人口[千人]	X ₂ 商店[店舗]	X ₃ 弁当[種類]	X ₄ お菓子[種類]	Y 売上[百万]
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-2. 重回帰分析：データの状況確認

【課題 15-2A】

ここで読み込んだデータについて、縦軸が売上、横軸がそれぞれの説明変数(X1～X4)となるような散布図を描け。見比べられるよう、4つのグラフをひとつのPDFファイルにして提出せよ。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。


◎ 提出締切；次回の授業の前日の18:00まで

15-3. 重回帰分析：2組のデータの間観る

重回帰分析をするまえに、まずはデータを観る

```
> x1 <- Famima[,2]
> y1 <- Famima[,6]
> plot(y1 ~ x1)
> result_1 <- lm (y1~x1)
> result_1
Call:
lm(formula = y1 ~ x1)

Coefficients:
(Intercept)      x1
      9.606      1.625
> summary(result_1)$r.squared
[1] 0.3325375
> R2_1 <- summary(result)$r.squared
> abline(result_1)
```



15-3. 重回帰分析： 2組のデータの関係を観る

重回帰分析をするまえに、まずはデータを観る

```
> x1 <- Famima[,2]
> y1 <- Famima[,6]
> plot(y1 ~ x1)
> result_1 <- lm (y1~x1)
> result_1
```

Call:
lm(formula = y1 ~ x1)

Coefficients:

(Intercept)	x1
9.606	1.625

```
> summary(result_1)$r.squared
```


```
[1] 0.3325375
```

```
> R2_1 <- summary(result)$r.squared
```

```
> abline(result_1)
```

```
> mtext(sprintf("y = %f x + %f", result_1$coefficients[2], result_1$coefficients[1]), side=3, line=1)
```

```
> mtext(sprintf("R^2 = %f", R2_1), side=3, line=0)
```



数字を変更してどの位置に文字が書かれるか
試してみよう。Sideは文字を書く位置1~4、
lineは軸から何行離れたところに文字を書くかを表す。

15-3. 重回帰分析： 2組のデータの間観る

重回帰分析をするまえに、まずはデータを観る

```
> summary(result_1)
```

Call:

```
lm(formula = y1 ~ x1)
```

Residuals:

Min	1Q	Median	3Q	Max
-30.999	-10.368	1.257	10.447	32.008

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	9.6063	15.4971	0.620	0.54311
x1	1.6255	0.5428	2.995	0.00778 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 17.27 on 18 degrees of freedom

Multiple R-squared: 0.3325, Adjusted R-squared: 0.2955

F-statistic: 8.968 on 1 and 18 DF, p-value: 0.007776



予測精度を表す残差の標準偏差は小さいほどよいが17.272

Yの変動の何%がX1で説明できるかを示す寄与率(決定係数)は0.3325→100%説明がつく時を示す1から値が離れ、説明変数x1で目的変数yを精度よく予測できそうにない。。

15-3. 重回帰分析：データを観る

【課題 15-3A】

ここでデータを観たように、説明変数X1からX4までの各々で目的変数Yを精度よく予測できそうかどうか、散布図を描き、回帰直線を入れ、回帰式と寄与率（決定係数）をグラフ上に記し、見比べられるよう、4つのグラフをひとつのPDFファイルにして提出せよ。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

15-4. 重回帰分析：データを観る（相関係数）

重回帰分析をするまえに、まずはデータを観る

データ間の相関の有無については、
cor ()を用いて相関係数行列を表示することができる。

> cor(Famima)

	Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
Store	1.0000000	0.4661357	0.6155668	0.5790868	0.3512248	0.7032044
jinkou_sennin	0.4661357	1.0000000	0.4201056	0.2909631	0.3631348	0.5766607
syouten_tenpo	0.6155668	0.4201056	1.0000000	0.4333075	0.3924596	0.5790630
bento_syurui	0.5790868	0.2909631	0.4333075	1.0000000	0.3902421	0.6648353
okashi_syurui	0.3512248	0.3631348	0.3924596	0.3902421	1.0000000	0.6384424
uriage_hyakuman	0.7032044	0.5766607	0.5790630	0.6648353	0.6384424	1.0000000

> cor(Famima[, -1])

1列目は店番号で、解析に関係がないので
1列目以外のデータを使って計算し直した。

	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
jinkou_sennin	1.0000000	0.4201056	0.2909631	0.3631348	0.5766607
syouten_tenpo	0.4201056	1.0000000	0.4333075	0.3924596	0.5790630
bento_syurui	0.2909631	0.4333075	1.0000000	0.3902421	0.6648353
okashi_syurui	0.3631348	0.3924596	0.3902421	1.0000000	0.6384424
uriage_hyakuman	0.5766607	0.5790630	0.6648353	0.6384424	1.0000000

相関行列のチェックポイント


- (1) 説明変数は目的変数と直線相関が有り、説明変数との相関係数がある程度大きいこと。
- (2) 説明変数間の相関係数はあまり大きすぎないこと。

15-4. 重回帰分析：データを観る

重回帰分析をするまえに、まずはデータを観る

得られた結果から、全ての組み合わせにおいて、寄与率（決定係数）が50%未満であることから、 y を精度よく予測できそうにない。

そこで、説明変数をひとつずつ用いたのではうまく行かないということならば、全部を一緒に使ってしまうというのが重回帰分析と呼ばれる手法である。



店番号	人口[千人]	商店[店舗]	弁当[種類]	お菓子[種類]	売上[百万]
Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう；回帰式の想定

目的変数Y（売上）を精度よく予測できるように、X1からX4までの説明変数を使って以下のような回帰式を想定します。

精度良くYを予測できるように係数abcdを決めることが、重回帰分析の目的です。

$$\varepsilon + aX_1 + bX_2 + cX_3 + dX_4 = Y$$

目的変数

店番号 人口[千人] 商店[店舗] 弁当[種類] お菓子[種類] 売上[百万]

Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう；回帰式の想定

目的変数Y（売上）を精度よく予測できるように、X1からX4までの説明変数を使って以下のような回帰式を想定します。

精度良くYを予測できるように係数abcdを決めることが、重回帰分析の目的です。

$$\varepsilon + aX_1 + bX_2 + cX_3 + dX_4 = Y$$

目的変数

店番号 人口[千人] 商店[店舗] 弁当[種類] お菓子[種類] 売上[百万]

Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう；回帰式の想定

精度良くYを予測できるように係数abcdを決めることが、重回帰分析の目的だからといって、**データを入力していきなり重回帰分析をするのは避けたほうが良い。**

これまで様々な学習してきたような方法で、散布図を描いたり、相関係数を調べたりして、変数間にどのような関係があるかを見定める、という作業に重要な意味があるからである。（すでにひとつ前の課題でこれを行い、1変数では目的変数Yを説明できないことが実感としてわかったはずである。）

$$\varepsilon + aX_1 + bX_2 + cX_3 + dX_4 = Y$$

目的変数

店番号 人口[千人] 商店[店舗] 弁当[種類] お菓子[種類] 売上[百万]

Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

```
> x1 <- Famima[,2]
```

```
> x2 <- Famima[,3]
```

```
> x3 <- Famima[,4]
```

```
> x4 <- Famima[,5]
```

```
> y1 <- Famima[,6]
```

このlmはlinear modelの意味。直線回帰を行うよということ。その結果をここではresultという名前のオブジェクトに代入しました。オブジェクトの名前は何でもいんですよ。

```
> result <- lm(y1 ~ x1+x2+x3+x4)
```

重回帰分析を行う
+記号を使って複数の説明変数を並べて指定する。

```
> result
```

重回帰分析の結果の表示

Call:

```
lm(formula = y1 ~ x1 + x2 + x3 + x4)
```

Coefficients:

(Intercept)	x1	x2	x3	x4
-53.0385	0.7797	0.5108	1.0175	0.7512

精度良くYを予測できるような係数abcdが求まった

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> `summary(result)` データの要約が欲しい場合は関数 `summary()` を用いる

Call: 重回帰分析のモデル式

`lm(formula = y1 ~ x1 + x2 + x3 + x4)`

Residuals: 残差のばらつき
 最小値 第1四分位 中央値 第3四分位 最大値
 Min 1Q Median 3Q Max
 -20.5392 -7.4603 0.9995 6.3007 26.0212

Residualsは残差という意味で、測定データと、回帰モデル上の予測値との、差を意味してます。そしてこの残差のばらつきがどんな感じかを記してくれています。

Minは最小値、Medianは中央値、Maxは最大値
 1Qや3Qは第1第3四分位点でしたね
 (箱ひげ図を思い出して!!)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-53.0385	19.1910	-2.764	0.0145 *
x1	0.7797	0.4389	1.777	0.0959 .
x2	0.5108	0.4949	1.032	0.3183
x3	1.0175	0.4169	2.441	0.0275 *
x4	0.7512	0.3697	2.032	0.0603 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> summary(result)

Call:

lm(formula = y1 ~ x1 + x2 + x3 + x4)

Residuals:

Min	1Q	Median	3Q	Max
-20.5392	-7.4603	0.9995	6.3007	26.0212

Coefficientsは係数のこと。y=ax1+bx2+ cx3+ dのaとかbとかね。
Interceptは切片, x1 (aのことね) は傾きのイメージ。

Estimateは推定値。つまり推定した回帰モデルの、
切片は-53.0385で係数は各々緑で記した部分という事。

y=-53.0385 + 0.7797x1+0.5108x2 + 1.0175x3 + 0.7512 x4
が推定した回帰モデルだよということ。

標準誤差は推定値の標準偏差。

測定値は母集団の一部だと考えた場合、データから推定した計算値
は一定のばらつきを持つ。推定値±標準誤差の範囲内に真の回帰係
数があるということ。

標準誤差とt値はP値を計算するためのものでもある。

	Coefficients: 回帰モデルの 推定値		標準誤差		t値	p値
	Estimate	Std. Error	t value	Pr(> t)		
切片 (Intercept)	-53.0385	19.1910	-2.764	0.0145	*	
傾き x1	0.7797	0.4389	1.777	0.0959	.	
x2	0.5108	0.4949	1.032	0.3183		
x3	1.0175	0.4169	2.441	0.0275	*	
x4	0.7512	0.3697	2.032	0.0603	.	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> summary(result)

Call:

```
lm(formula = y1 ~ x1 + x2 + x3 + x4)
```

Residuals:

Min	1Q	Median	3Q	Max
-20.5392	-7.4603	0.9995	6.3007	26.0211

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-53.0385	19.1910	-2.764	0.0145 *
x1	0.7797	0.4389	1.777	0.0959 .
x2	0.5108	0.4949	1.032	0.3183
x3	1.0175	0.4169	2.441	0.0275 *
x4	0.7512	0.3697	2.032	0.0603 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

「自由度修正済み決定係数」
(また次回以降時間のある時に
まわします)

決定係数（寄与率）は回帰直線がどの程度データにフィットしているかを評価する指標でしたね。回帰直線によって観測値のばらつきがどの程度説明されているかを示している、つまり、yの変動の何%がxで説明できるかを表したもの。(0.86であればyの変動の86%をxで説明がつく、1であればyの変動の100%をxで説明がつくということ) 決定係数は0から1の間の値を取る。1に近いほど回帰直線の説明力が高く、ちょうど1になったときには全ての観測値が直線上に並ぶ（そんなことは普通の観測ではありえない）。

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> summary(result)

Call:

```
lm(formula = y1 ~ x1 + x2 + x3 + x4)
```

Residuals:

	Min	1Q	Median	3Q	Max
Residuals	-20.5392	-7.4603	0.9995	6.3007	26.0212

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-53.0385	19.1910	-2.764	0.0145 *
x1	0.7797	0.4389	1.777	0.0959 .
x2	0.5108	0.4949	1.032	0.3183
x3	1.0175	0.4169	2.441	0.0275 *
x4	0.7512	0.3697	2.032	0.0603 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

回帰の分散分析のF値およびその自由度(DF)と、対応するP値が書かれている。説明変数の係数がすべて0であるという帰無仮説に対するF検定統計量と分子・分母の自由度 DF、および p 値である。F検定の値は、回帰直線全体の有効性に関する検定結果を示している。回帰係数がゼロでない場合に大きくなる傾向がある。p値が十分小さいと回帰モデルを用いる必要がないという仮説を否定した事になる。

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析の結果から予測してみよう

精度良くYを予測できるように係数abcdを重回帰分析により求めた。

$$y = -53.0385 + 0.7797x_1 + 0.5108x_2 + 1.0175x_3 + 0.7512x_4$$

$$\varepsilon + aX_1 + bX_2 + cX_3 + dX_4 = Y$$

目的変数

店番号 人口[千人] 商店[店舗] 弁当[種類] お菓子[種類] 売上[百万]

Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

【課題 15-5A】

ここで重回帰モデルを求めた。ではこのモデルを使って新しく21番目の店舗を建てるに当たり、その店舗の売上を予測せよ。この21番目の店舗の各説明変数の値は $X1=30$ 、 $X2=35$ 、 $X3=25$ 、 $X4=50$ である。
売上額Yはいくらと予想されるか？

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> `summary(result)`

Call:

```
lm(formula = y1 ~ x1 + x2 + x3 + x4)
```

Residuals:

Min	1Q	Median	3Q	Max
-20.5392	-7.4603	0.9995	6.3007	26.0212

`Pr(>|t|)`という項目では、

各変数について、係数が帰無仮説のもとで得られる確率をあらわす。

帰無仮説は「係数はゼロと同じである」です。

係数がゼロ0の場合、これと掛け合わせる変数は結局ゼロ0になるので、変数としては意味がないことになる。

Coefficients: 回帰モデルの
推定値 標準誤差 t値 p値

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-53.0385	19.1910	-2.764	0.0145 *
x1	0.7797	0.4389	1.777	0.0959 .
x2	0.5108	0.4949	1.032	0.3183
x3	1.0175	0.4169	2.441	0.0275 *
x4	0.7512	0.3697	2.032	0.0603 .

切片
傾き

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> `summary(result)`

Call:

```
lm(formula = y1 ~ x1 + x2 + x3 + x4)
```

Residuals:

Min	1Q	Median	3Q	Max
-20.5392	-7.4603	0.9995	6.3007	26.0212

Coefficients: 回帰モデルの
推定値 標準誤差 t値 p値

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-53.0385	19.1910	-2.764	0.0145 *
x1	0.7797	0.4389	1.777	0.0959 .
x2	0.5108	0.4949	1.032	0.3183
x3	1.0175	0.4169	2.441	0.0275 *
x4	0.7512	0.3697	2.032	0.0603 .

P値のところについているアスタリスク * は
その下のところ書かれている基準を満たしている場合に
その基準にあった印がつけられているだけのこと。

この記号は有意性の判断基準を示している

0.001よりも小さい場合は***をつける＝有意水準 0.1% で有意という意味
0.01 よりも小さい場合は** をつける＝有意水準 1% で有意という意味
0.05 よりも小さい場合は* をつける＝有意水準 5% で有意という意味
0.1 よりも小さい場合は. をつける＝有意水準 10% で有意という意味

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> summary(result)

Call:

```
lm(formula = y1 ~ x1 + x2 + x3 + x4)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-20.5392	-7.4603	0.9995	6.3007	26.0212

Coefficients: 回帰モデルの
推定値 標準誤差 t値 p値

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-53.0385	19.1910	-2.764	0.0145 *
x1	0.7797	0.4389	1.777	0.0959 .
x2	0.5108	0.4949	1.032	0.3183
x3	1.0175	0.4169	2.441	0.0275 *
x4	0.7512	0.3697	2.032	0.0603 .

検定結果をよく見ると、

赤い部分は0.1を超えている。（「*」や「.」がついていない）

青い部分は0.05を超えている。（「.」がついている）

それ以外は0.05を満たしている。（「*」がひとつついている）

検定結果では、有意水準5% で有意という基準がよく用いられる。0.05 よりも小さい場合は*をつけているので、それ以外の部分は、有意水準5% で有意ではないということになる。

ここでは、丸をつけた3つの変数とそのそれぞれの係数0.7797、0.5108、0.7512は、説明変数として妥当では有りません。なぜなら、「係数はゼロ0である」とする帰無仮説の統計量であるt-valueが、それぞれ1.777、1.032、2.032となり、確率もそれぞれ0.0959、0.3183、0.0603となり0.05よりも大きくなるため、帰無仮説が保留されるから。帰無仮説を棄却できない、つまり、求められた係数に意味はないということになる。すなわち、この係数を用いたモデルは適切ではないということです。

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析をしよう

> summary(result)

Call:

```
lm(formula = y1 ~ x1 + x2 + x3 + x4)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-20.5392	-7.4603	0.9995	6.3007	26.0212

Coefficients:

	推定値 Estimate	標準誤差 Std. Error	t値 t value	p値 Pr(> t)
切片 (Intercept)	-53.0385	19.1910	-2.764	0.0145 *
傾き x1	0.7797	0.4389	1.777	0.0959 .
x2	0.5108	0.4949	1.032	0.3183
x3	1.0175	0.4169	2.441	0.0275 *
x4	0.7512	0.3697	2.032	0.0603 .

残差標準誤差 Residual standard error
残差標準誤差の自由度 Degrees of freedom
ここでは残差の標準誤差は12.28、
自由度は15と言っている

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.28 on 15 degrees of freedom

Multiple R-squared: 0.719, Adjusted R-squared: 0.6441

F-statistic: 9.597 on 4 and 15 DF, p-value: 0.0004682

15-5. 重回帰分析：複数の説明変数を使った重回帰モデル

重回帰分析の結果から予測してみよう

精度良くYを予測できるように係数abcdを重回帰分析により求めた。

しかし、3つの説明変数は意味がないことから、これを省いた、次の回帰モデルが妥当とみなされる。

$$y = -53.0385 + 1.0175x_3$$



$$y = -53.0385 + 0.7797x_1 + 0.5108x_2 + 1.0175x_3 + 0.7512x_4$$

$$\varepsilon + ax_1 + bx_2 + cx_3 + dx_4 = Y$$

目的変数

店番号 人口[千人] 商店[店舗] 弁当[種類] お菓子[種類] 売上[百万]

Store	jinkou_sennin	syouten_tenpo	bento_syurui	okashi_syurui	uriage_hyakuman
1	27	21	27	63	33
2	16	26	11	44	10
3	25	12	20	51	24
4	20	27	26	59	52
5	17	26	34	49	40

15-6. 重回帰分析：説明変数の数や選び方

説明変数として何を選ぶかは重要です。

□そもそも目的変数と明らかに関係のないような説明変数を追加しても仕方がない。例えば、コンビニの売上を説明する変数として、ガソリンの輸入量を変数として追加することは適切とは思われない。

□また、説明変数の間に相関がある場合も問題。例えば、年収と年齢に相関があり、年齢と血圧に相関があると、年齢を媒介として、年収と血圧に相関があるとなります。しかし、年収の大きさを説明しているのは年齢であって、血圧では有りません。したがって、データを説明する変数として、年齢と年収の両方を入れるのは妥当ではないとわかります。

15-6. 重回帰分析：説明変数の数や選び方

説明変数の数

- 重回帰分析では、説明変数が増えれば増えるほど、モデルの適合度そのものは改善する。（そりゃそうだ。説明変数の数を増やせば、当てはめが改善するよね。）
- 単回帰分析では、モデルの良さを図る指標として決定係数が1に近いかどうかを判定の基準としていたが、この決定係数は、説明変数の数が増えると、単純に、改善してしまう。
- しかし、説明変数の間に高い相関を持っているものが存在する場合、モデルとしての妥当性は揺らいでしまう。
- そのため、統計モデルとしては、目的変数の変動に影響力のある、互いに強い相関を持たない説明変数だけを選ぶべきである。どうやって選ぶ？→効果のある説明変数を選択するという作業をする。

15-6. 重回帰分析：説明変数の数や選び方

説明変数を取捨選択することを「モデル選択」という

□モデル選択には、最初に全ての変数を投入し、判断基準(AICという情報量)をつかって説明変数を減らしていく方法と、その逆に説明変数をゼロから追加していく方法、さらには両方を折衷した方法の3通りがある。

□統計量t-valueの値の大きさを、我々が見て判断して、特定の変数を外すという方法もあるが、このような判断をRにまかせて、自動的にモデル選択を行うこともできる。Rのstep関数を使う。この関数では、デフォルトでは変数をひとつひとつ削除していき、最終的にはモデルとして意味のある変数のみを残す。

15-7. 重回帰分析：AIC

□有効な説明を選択するための基準としてAIC（赤池情報量基準；Akaike Information Criteria）がある。AICはモデルの良さを表す指標である。AICでは、変数の数を増やすことを一種のペナルティーとして科すのである。当てはめ具合が近い、似たようなモデルがあってこれを比較するとした時、AICの値を計算して、値が小さいほど適切なモデルだ！とされるわけです。

＊AICは文部省直轄の統計数理研究所の所長を務めた赤池弘次によって1970年代初頭に考案されたモデル選択の基準で、今は世界中で使われている!!! スゴイネ！

尤度=likelihood（尤^{もっと}もらしさを定量的に示すもの）は、尤度関数を用いて表現されるが、総積を繰り返すので扱いにくい関数である。そこで対数変換することによって、総和に変換し、扱いやすい関数をつくる。これを対数尤度と呼ぶ。

$$\text{AIC} = -2 * \text{最大対数尤度} + 2 * \text{最尤推定した自由パラメータの個数}$$

「逸脱度=deviance」
と呼ばれている。

自由パラメータの個数は、モデル
のパラメータの個数をあらわす。

15-7. 重回帰分析：AIC

- どのモデルが良いのかの選択はAICによって行うことが多い。
 いくつか候補となるモデルの出力するAICを比較して、相対的に小さい値を示すモデルが「よいモデル」となる。
- AICを小さくするモデルを「よいモデル」と考え、各項の理解は以下。
- ・最大対数尤度が大きければ、よりデータに当てはまり、AICの値が小さくなる。
 - ・パラメータの数が増えれば増えるほど、今得られているデータに当てはまるが、新規のデータに対する予測が悪くなることが知られている。つまり、第二項はパラメータの数が増えるとAICが大きくなるようなペナルティの役割を果たす。
- ＊データへの当てはまりがよくても、モデルを構成するパラメータが多いと、あるひとつのデータセットには過剰に適合しても、一般的な予測性（＝汎化性）が落ち、AICが大きくなってしまうので、良いモデルではない。

尤度=likelihood（尤^{もっと}もらしさを定量的に示すもの）は、尤度関数を用いて表現されるが、総積を繰り返すので扱いにくい関数である。そこで対数変換することによって、総和に変換し、扱いやすい関数をつくる。これを対数尤度と呼ぶ。

$$\text{AIC} = -2 * \text{最大対数尤度} + 2 * \text{最尤推定した自由パラメータの個数}$$

「逸脱度=deviance」
と呼ばれている。


自由パラメータの個数は、モデル
のパラメータの個数をあらわす。

15-8. 重回帰分析：モデルの検証をするために

ここでは、存在するすべてのデータを用いてモデルを計算して求めた。

しかし現実的なデータマイニングの現場では、データをすべて使ってしまわずに、検証用に一部を残しておいて後で使うということが行われる。

ここで扱ったデータは小規模なものであるが、データマイニングの現場で扱うデータは大量にあるので、データを回帰式の作成用と回帰式の検証用に分けるところが、データマイニングの特徴です。



15-9. 重回帰分析 練習A

新たな販売店（店番号G）を開くことになった。
このメーカーでは増毛薬に力を入れており、主力製品のひとつである。

すでに増毛薬を販売し、売上を伸ばしている化粧品メーカーの、
営業所ごとの状況を観てみよう（[hage.csv](#)）。

これらのデータをもとにして、新しい販売店での、売上を予想したい。

なお、新たな販売店では、広告費を13百万円、営業マンを14人動員する予定である。

	目的変数	説明変数	説明変数
	Y	X ₁	X ₂
店番号	売上[千万]	広告費[百万]	営業マン[人]
store	uriage_senman	koukokuhi_hyakumann	eigyoin_nin
A	8	5	6
B	9	5	8
C	13	7	10
D	11	5	11
E	14	8	12
F	17	12	13

15-9. 重回帰分析 練習A

【課題 15-9A】

新たな販売店（店番号G）を開くことになった。
このメーカーでは増毛薬に力を入れており、主力製品のひとつである。

すでに増毛薬を販売し、売上を伸ばしている化粧品メーカーの、
営業所ごとの状況を観てみよう（[hage.csv](#)）。

これらのデータをもとにして、新しい販売店での、売上を予想したい。

なお、新たな販売店では、
広告費を13百万円、営業マンを14人動員する予定である。

化粧品メーカーの新たな販売店の売上を、既存の販売店の重回帰分析により得られた重回帰モデルから予測しなさい。

解析や解答の行程は、パワーポイントにまとめて提出しなさい。

15-9. 重回帰分析 練習A

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

15-9. 重回帰分析 練習B

【課題 15-9B】

(1)

ある会社の部署で、新入社員(A～G)の7名に対する1年間の業績評価を行った。新入社員の出身学校(大学や高専)における成績や、就職試験の成績と、入社後1年間の業績評価の間にはどのような関係があるだろうか? 重回帰分析により得られる重回帰モデルから予測しなさい。
なお、成績や業績は10段階評価の値に換算してある ([test.csv](#))。

(2)

また、ちょうど今、次年度の新入社員の選抜を現在行っているが、定員枠の最後の1名を以下のどちらを採用とするかで、会社役員の間で議論がなされている。あなたは(1)の分析を踏まえて、どちらを採用することを勧めるか?

就職希望学生 高専太郎さん 出身学校の成績は4、就職試験の成績は8

就職希望学生 日本花子さん 出身学校の成績は8、就職試験の成績は4

解析や解答の行程は、パワーポイントにまとめて提出しなさい。

15-9. 重回帰分析 練習B

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで