

第10回 (2026.06.03)

データマイニング概論

※すべての授業資料について著作権を放棄していません。そのため、科目受講者が、自己の授業受講以外の目的で資料を電子的もしくは紙媒体等によって他者へ有償無償のいずれによらず譲渡することは禁止されています。授業受講者はこのことを理解したうえで受講しているとみなします。

熊本高等専門学校
生物化学システム工学科
木原 久美子 (専攻科棟3階)
kihara@kumamoto-nct.ac.jp

0-1. もくじ

0-1. 目次

0-2. 準備

2-6. 最低限のコマンド一覧（復習）

16-1～29. 判別分析（線形判別）

シラバス

←第01回

Rのインストール・準備・起動・使用練習

←第02回

ディレクトリ階層構造, 最低限のコマンド, ヘルプ, 四則演算,
代入, 行と列, 系列名, CSVファイル, データの読み込み,

ヒストグラムの描画, 相対度数, 密度関数, 図の保存

←第03-04回

ソースファイルから複数の図をプロット

←第04回

散布図, 単回帰分析, マーカーの色種類, プロット 重畳させ

←第05-07回

データ型・データ構造

←第05回

図へ文字列の書き込み, 凡例表示, 識別子

←第06回

特定のデータを抜き出して解析

←第06回

相関解析・相関係数／グループごとの解析

←第07回

重回帰分析

←第08回

円グラフ・ドーナツ・箱ひげ図

←第09回

0-2. 準備

特定のフォルダを作りそこに授業に関係するファイルを保存するようにしましょう。各自でいつも準備を進めておいて下さい。

- 自分で決めた場所にData_miningフォルダを作成
授業名がデータマイニング概論 (Data mining)なので。
- そのフォルダの中にclassXXフォルダを作成。
XXに01とか02とか、授業の回数を入れておけば見分けが付きやすい。
毎回、授業中に行う作業はこのフォルダの中に保存するようにせよ。

2-6. 最低限のコマンド・一覧（前回まで）

□Rを立ち上げる windowsのスタート→プログラム→R

□コマンドで居場所を確認&今日の場合に移動

getwd()	今自分がどこにいるか居場所を確認
setwd("../")	ひとつうえの階層のディレクトリに行く
getwd()	居場所を確認！

dir()	今いるディレクトリ内に何があるか見る
setwd("./class6")	ディレクトリ内のclass4に移動
getwd()	うまく移動できたかgetwdで確認

help(dir)	dirの使い方見たい時。helpで何でも分かる
-----------	-------------------------

q()	Rを終わりにしたいとき スペースを保存するか聞かれたら保存しないを選択
-----	--

16-1. 判別分析

判別分析とは

判別分析は、ある観測対象が所属するグループを予測するための手法。

グループの数は2つでもそれ以上でも構わない。

グループの数が2つの場合を **2群の判別**

グループの数が3つ以上の場合を **多群の判別** という。


判別分析では、サンプルがどのグループに属するのかが明らかな学習データを使って判別モデルを構築し、そのモデルを用いて、グループ不明のサンプルがどのグループに帰属するのかを判別する。

16-1. 判別分析

判別分析とは

グループが k 個存在していて、どのグループに属するのかがわかっている観測対象について、データが収集されているとする。


このときに、どのグループに属するのかが不明な対象が得られた場合、既に収集されているデータに基づいて、その対象が所属するグループを予測するのが**判別分析**。



16-1. 判別分析

判別分析とは


例えば、既知のサンプルのデータから製品が良品グループと不良品グループに分類されたところで（このとき製品の点検項目の点数は判明している）、あらたな製品がどちらのグループに属するかを（製品の点検項目の点数を使って）予測する、



16-1. 判別分析

判別分析とは

例えば、過去の消費者が購入者グループと非購入者グループに分類されたところで（このとき消費者の嗜好性や経済力などの着目している考慮項目の点数は判明している）、新たな消費者がどちらのグループに属するかを（消費者の着目している考慮項目の項目の点数は判明している）予測する、




16-1. 判別分析

判別分析とは

例えば、既知のデータから人が生活習慣病になるかならないかのグループに分類されたところで（このとき各人の生活習慣の項目の点数は判明している）、新たな人がどちらのグループに属するかを（生活習慣の項目の点数を使って）予測する、

といったものである。




16-1. 判別分析

判別分析とは

グループの間に境界線をいれて、新しいデータが与えられた時どちらのグループに属するのかを判別する。

(境界線の入れ方例)



線型判別関数による境界線


16-1. 判別分析

判別分析とは

グループの間に境界線をいれて、新しいデータが与えられた時どちらのグループに属するのかを判別する。

(境界線の入れ方例)

曲線で入れる場合



それぞれのグループの、ばらつき（分散）を考慮した距離。

ばらつきが大きいグループのマハラビノス1距離(仮称)と、ばらつきが小さいグループのマハラビノス1距離(仮称)は、異なっている。

マハラノビスの距離による境界線

それぞれのグループのマハラビノス距離が等しくなる場所に境界線を引く。あるサンプルは、どちらのグループに分類されるかはユークリッド距離ではなくマハラビノス距離で計算される。

16-2. 「分類」と「判別」

判別分析とは

＊注意

「**分類**」と「**判別**」は似ているように見える概念だが別の問題なので一緒にしないこと。

「**分類**」は、観測されているデータに基づいて対象をいくつかのグループに分けること。
いくつかのグループに分かれるのかは、データを見るまで不明である。
分類の問題に利用される手法に、クラスター分析がある。

「**判別**」は、存在するグループの数が既にわかっている状況の上で、
新しい対象が、その中のどのグループに属するかを決定するものである。

16-3. 判別分析の手法

判別分析の手法（2群の判別分析の場合）

2群の判別分析を行う方法は主に4種類ある。

- (1) マハラノビスの距離による方法
- (2) 線形判別関数による方法
- (3) 重回帰分析による方法
- (4) ロジスティック回帰による方法

＊ただし、線形判別でも2次判別でも、共通して、データが正規分布に従うことを前提とする。また、線形判別分析には「全群団で分散が等しい」という前提がある。一方で、2次判別分析では「群団間で分散が異なる」場合にも対応することができる。

16-4. 判別分析と重回帰分析と数量化I類&II類

判別分析と重回帰分析で用いるデータ

$$Y = a X_1 + b X_2 + \dots$$

目的変数Y 説明変数 (X₁, X₂, ...)

重回帰分析 ← 量的変数だ！

ウエスト〇〇cmと身長〇〇cmの説明変数(量的変数)で、
目的変数として体重〇〇kg(量的変数！)を予測する

判別分析 ← 質的変数だ！

ウエスト〇〇cmと身長〇〇cmの説明変数(量的変数)で、
目的変数として性別〇〇(男女; 質的変数！)を予測する

16-4. 判別分析と重回帰分析と数量化I類&II類

判別分析と重回帰分析で用いるデータ

$$Y = a X_1 + b X_2 + \dots$$

目的変数Y 説明変数 (X₁, X₂, ...)

重回帰分析 ← 量的変数だ！

ウエスト○○cmと身長○○cmの説明変数(量的変数)で、
目的変数として体重○○kg(量的変数！)を予測する

判別分析 ← 質的変数だ！

ウエスト○○cmと身長○○cmの説明変数(量的変数)で、
目的変数として性別○○(男女; 質的変数！)を予測する

数量化I類 ← 量的変数だ！

性別○○(男女; 質的変数)と血液型(質的変数)で、
目的変数として体重○○kg(量的変数！)を予測する

数量化II類 ← 質的変数だ！

性別○○(男女; 質的変数)と趣味(質的変数)で、
目的変数として好きな科目○○(質的変数！)を予測する

16-5. 4つの予測型手法とデータ変数の組み合わせ

分析に用いるデータ変数の組み合わせにより異なる予測型手法

$$Y = a X_1 + b X_2 + \dots$$

目的変数Y 説明変数 (X₁, X₂, ...)

予測型手法	目的変数	説明変数
重回帰分析	量的変数	量的変数
判別分析	質的変数	量的変数
数量化I類	量的変数	質的変数
数量化II類	質的変数	質的変数

ある変数の値を、他の変数の値を使って予測したい！！という時に使われる手法は、

どんな説明変数を使って、
どんな目的変数を予測しようとするのか、

によって、
表のような組み合わせが考えられる。


それぞれの組み合わせごとに、解析手法に名前がつけられている。

16-6. 平面と分割直線の関係 (2変量の場合)

大学や高専、または、会社でもいいですね、入学や入社するために試験を受けるとしましょう。

このとき、試験は、筆記試験と面接試験で行われるとします。

受検者はそれぞれの点数を持っているので、XY平面上にプロットすることができます。




16-6. 平面と分割直線の関係 (2変量の場合)

大学や高専、または、会社でもいいですね、入学や入社するために試験を受けるとしましょう。

このとき、試験は、筆記試験と面接試験で行われるとします。

受検者はそれぞれの点数を持っているので、XY平面上にプロットすることができます。




受検者の合否はすでに判明しているので、全受検者をプロットした後で、その合否も記してみると、、、

16-6. 平面と分割直線の関係 (2変量の場合)

大学や高専、または、会社でもいいですね、入学や入社するために試験を受けるとしましょう。

このとき、試験は、筆記試験と面接試験で行われるとします。

受検者はそれぞれの点数を持っているので、XY平面上にプロットすることができます。




受検者の合否はすでに判明しているので、全受検者をプロットした後で、その合否も記してみると、、、

16-6. 平面と分割直線の関係 (2変量の場合)

大学や高専、または、会社でもいいですね、入学や入社するために試験を受けるとしましょう。

このとき、試験は、筆記試験と面接試験で行われるとします。

受検者はそれぞれの点数を持っているので、XY平面上にプロットすることができます。



受検者の合否はすでに判明しているので、全受検者をプロットした後で、その合否も記してみると、、、


合格グループと不合格グループに分ける境界線がありそうだ、これがわかれば、新しい受検者が、合格するかどうか予想できるかも。

16-6. 平面と分割直線の関係 (2変量の場合)


2つのグループを分割する直線の式が

$$0 = ax + by + c$$

で与えられたとする。



16-6. 平面と分割直線の関係 (2変量の場合)



2つのグループを分割する直線の式が

$$0 = ax + by + c$$


で与えられたとする。

0ではなく z に置き換えれば、


$$z = ax + by + c$$

と掛けるが、これはまさに、
 x - y 平面との交わりが青い直線となる
図中の桃色の平面 α を意味している。


16-7. 平面との位置関係からの判定 (2変量の場合)




16-7. 平面との位置関係からの判定 (2変量の場合)





16-7. 平面との位置関係からの判定 (2変量の場合)



16-7. 平面との位置関係からの判定 (2変量の場合)




16-7. 平面との位置関係からの判定 (2変量の場合)





16-8. 線形判別関数

このように、その正負によって、
どちらのグループに属するかを判別できる式を線型判別関数という。





16-8. 線形判別関数

グループを分割する直線 $ax + by + c = 0$ を求めるということは、
 線型判別関数 $z = ax + by + c$ を求めるのと同義ということ！




16-9. 線形判別関数と判別得点


各サンプルについての z の値を、
判別得点という。




16-10. 分割直線平面上における分布




16-10. 分割直線平面上における分布




16-10. 分割直線平面上における分布



16-11.分割直線平面上における分布；サンプルの投影





16-11. 分割直線平面上における分布；サンプルの投影



16-12. 分割直線を求めることの意味（方向を探す）

分割直線を求めること = ふたつのグループが分離されて見える方向を探すこと




そこに分布を投影すると
青い線の左右にグループが分離されて見える

16-12. 線形判別関数による判別分析 (2変量の場合)

データのサンプルを2グループに分割する直線を見つけることが、「線形判別関数による判別分析」です。

さらにその分割直線から得られる「線形判別関数」を利用すると、値の正負によって、どちらのグループに属するのかを「判別できる」のでした。

分布を眺める方向を上手に選ぶと、適切な分割直線が見えてくるわけです。





16-13. 分割直線の両側に分布が二極化する

適切な分割直線を選び、その直線に垂直な方向にデータを投影すると、2グループの分布は2極化することになります。

実際はデータ数をもっともっと多いので、点は分布として表すほうが適切でしょう。

また、もっとも適切な分割直線を描いてもその直線を超えてそれぞれのプロットがばらついてしまうこともあるでしょう。

下の図は、適切な分割直線と、左右に二極化している分布の模式図です。



16-14. 分割直線までの距離

この分布は分割直線までの距離の分布とも言えますね。



データ点から分割直線までの距離は以下。

直線 $0 = ax + by + c$ への
点 $A(x_i, y_i)$ からの距離 d_i は

$$d_i = \frac{|ax_i + by_i + c|}{\sqrt{a^2 + b^2}}$$

これは判別得点 Z_i
そのもの！

判別得点 Z_k は分割直線とデータ点との
距離そのものではないが、
離れ具合を表しているとみなせる。



16-15. 判別得点は全体としてどのくらい散らばっているか

判別得点 z_k とその平均 $\bar{z}$ の差を偏差という。


偏差の2乗を合計したものを、判別得点の偏差平方和、という。

判別得点の全体の偏差平方和 ($= S_{Total} = S_T$) と記すことが多い。

偏差平方和は、判別得点の散らばり具合をあらわす。

$$S_T = \{(Z_i - \bar{Z})^2 \text{ の合計} \}$$

偏差平方和 S_T が大きいほど、**分割直線**からのデータ点の距離がばらつく。
全データ点の特徴を読み取ることができる量。



16-16. 2つのグループはどれだけ離れているか

判別得点 Z_k の平均 $\bar{Z}$ は、
 グループA の判別得点の平均 $\bar{Z}_{groupA}$
 グループB の判別得点の平均 $\bar{Z}_{groupB}$
 を用いれば以下のようにかける。

全体の判別得点 の合計


グループA内での
判別得点 の合計

グループB内での
判別得点 の合計

$$(n_{groupA} + n_{groupB})\bar{Z} = n_{groupA}\bar{Z}_{groupA} + n_{groupB}\bar{Z}_{groupB}$$

これを変形して、全体平均をグループ平均であらわすと、

$$\bar{Z} = \frac{n_{groupA}\bar{Z}_{groupA} + n_{groupB}\bar{Z}_{groupB}}{n_{groupA} + n_{groupB}}$$



16-17. 2つのグループはどれだけ離れているか

以下の変形によって、全変動 = 群間変動 + 群内変動

$$S_{Total} = S_{Between} + S_{Within} \quad \text{が求まる。}$$

$$S_T = \{ (Z_i - \bar{Z})^2 \text{ の合計 } \} =$$

$$\underbrace{(Z_1 - \bar{Z})^2 + (Z_2 - \bar{Z})^2 + \dots + (Z_{n_{groupA}} - \bar{Z})^2}_{\text{グループA}} + \underbrace{(Z_1 - \bar{Z})^2 + (Z_2 - \bar{Z})^2 + \dots + (Z_{n_{groupB}} - \bar{Z})^2}_{\text{グループB}}$$

$$(Z_1 - \bar{Z}_A + \bar{Z}_A - \bar{Z})^2 + \dots$$

と置き換えて整頓すると

$$(Z_1 - \bar{Z}_B + \bar{Z}_B - \bar{Z})^2 + \dots$$

と置き換えて整頓すると

$$S_B = n_A (Z_A - \bar{Z}_A)^2 + n_A (Z_A - \bar{Z}_B)^2$$

$$S_W = (Z_1 - \bar{Z}_A)^2 + (Z_2 - \bar{Z}_A)^2 + \dots + (Z_{n^A} - Z_A)^2$$

グループA

$$+ (Z_1 - \bar{Z}_B)^2 + (Z_2 - \bar{Z}_B)^2 + \dots + (Z_{n^B} - Z_B)^2$$

グループB

16-18. 変動をみる

全変動

S_{Total} =

グループ同士がどのくらい離れているか

群間変動


$S_{Between}$

+


グループ内はどのくらい密集しているか

群内変動

S_{Within}



値が大きいと離れている
値が小さいと重なっている



値が小さいほど
密集している


2つのグループを
2極化する方向を探す為に
分割直線とデータの距離を
 S_B と S_W とに分けて考えると、
 S_B を大きくするように
分割直線の方角を探せば
よいということになる。

二つの群がなるべく離れる＝群間の平均の差ができるだけ大きくなるようにする
群内のデータができるだけ密集する＝群内の分散が小さくなるようにする

16-19. 変動をみる

$$\frac{\text{群間変動 } S_{Between}}{\text{全変動 } S_{Total}} = F$$

全変動と群間変動の比を
最大にする1次元軸を求める



全変動 S_T に占める群間変動 S_B の比率を最大にしてグループを2極化することを考える。
これが求めたい場合のこと。(Fの最大値は、関数の極値条件から偏微分によって求められる。)
直線の式のうちaとbが求まる。定数cはグループの平均の中点を通るように決定する。

16-20. 判別分析（線形判別分析）

このように、2群の判別分析は、2群のデータを散布図にプロットし、2群のプロットの重なりが最小になるような判別軸を見つけて、その軸に2群のプロットを正射影して、判別スコアを求めて、それを利用して判別を行うというもの。[線形判別分析 \(LDA: Linear Discriminant Analysis\)](#)

＊多群の判別で2群ごとの判別を使って行おうとすると、これを複数回行う必要があり、結構めんどくさい（例えば、6群を判別したいとするならば、2群ごとの判別分析を、15回行わなくてはなりませんね）

多群の場合にも、同じ考え方で、データを多次元の散布図としてプロットします。一番離れている2つの群のプロットの重なりが最小になるように、判別軸を見つけて、その軸にプロットを正射影して判別スコア1を求める。次は、判別軸1では重なりが大きかったまた別の2群について、それらの重なりが最小になるような判別軸2を見つけて、その軸にプロットを正射影して判別スコア2を求める。、、、と繰り返していくと、k群ある場合にはk-1個の判別軸を見つけて、その数だけ判別スコアを計算することができる。ここまで出来たら、k-1個の判別軸を座標軸とする空間上に、判別スコアをプロットすると、群が離れてプロットの重なりが少なくなった状態ができる。新しいサンプルについてどの群に属するかを判別する場合には、図中に点をプロットして、そのプロットと各群の重心（判別スコアの平均値）との距離を計算し、最小の群に属すると判別する。この方法を、[正準判別分析 \(CDA: Canonical Discriminant Analysis\)](#) または[重判別分析 \(MDA: Multiple Discriminant Analysis\)](#) という。

16-20. 判別分析（線形判別分析）

Rで利用できるパッケージMASSの中の^{エル}lda関数をつかう

線形判別分析LDA; リニアー ディスクリミナント アナリシス linear discriminant analysis

線形判別分析を行うにあたり、
RのパッケージMASS（インストール時にデフォルトで入っている）に入っているlda関数を使う。

lda関数は、2群の判別の場合では線形判別分析を行う。
＊3群以上の判別の場合には、正準判別分析（次元の減少を伴う判別分析）を行う。

ではここでは2群の判別分析を行ってみよう。

16-21. Rのパッケージ (ライブラリ)

Rで利用できるパッケージを確認しよう

Rでは、機能別に分類したパッケージ (ライブラリ) がまとめられている。

どのようなパッケージがあるかを確認するには関数`library()`を使って確認する。

> library()

パッケージの一覧がでくる。

パッケージ (ライブラリ 'Z:/Documents/R/win-library/3.3' 中):

crayon	Colored Terminal Output
dplyr	A Grammar of Data Manipulation
fansi	ANSI Control Sequence Aware String Functions
generics	Common S3 Generics not Provided by Base R
	Methods Related to Model Fitting
glue	Interpreted String Literals
pkgconfig	Private Configuration for 'R' Packages
purrr	Functional Programming Tools
R6	Encapsulated Classes with Reference Semantics
rlang	Functions for Base Types and Core R and 'Tidyverse' Features
tibble	Simple Data Frames
tidyselect	Select from a Set of Strings
utf8	Unicode Text Processing

パッケージ (ライブラリ 'C:/Program Files/R/R-3.3.2/library' 中):

base	The R Base Package
boot	Bootstrap Functions (Originally by Angelo Canty for S)
class	Functions for Classification
cluster	"Finding Groups in Data": Cluster Analysis
	Extended Rousseeuw et al.
codetools	Code Analysis Tools for R
compiler	The R Compiler Package
datasets	The R Datasets Package
foreign	Read Data Stored by Minitab, S, SAS, SPSS, Stata, Systat, Weka, dBase, ...
graphics	The R Graphics Package
grDevices	The R Graphics Devices and Support for Colours and Fonts
grid	The Grid Graphics Package
KernSmooth	Functions for Kernel Smoothing Supporting Wand & Jones (1995)

16-21. Rのパッケージ (ライブラリ)

Rで利用できるパッケージをつかう

パッケージの詳細を知りたいときは、ヘルプを使う。

> library()

パッケージの一覧がでてくる。

> library(help=パッケージ名)

パッケージのヘルプを見たい時

> library(help=MASS)

パッケージMASSのヘルプを見たい場合の例

パッケージ 'MASS' の情報

記述:

```
Package:      MASS
Priority:     recommended
Version:      7.3-45
Date:         2015-11-10
Revision:     $Rev: 3453 $
Depends:      R (>= 3.1.0), grDevices, graphics, stats, utils
Imports:      methods
Suggests:     lattice, nlme, nnet, survival
Authors@R:    c(person("Brian", "Ripley", role = c("aut", "cre",
"    "cph"), email = "ripley@stats.ox.ac.uk"),
    person("Bill", "Venables", role = "ctb"),
    person(c("Douglas", "M."), "Bates", role = "ctb"),
    person("Kurt", "Hornik", role = "trl", comment =
"    "partial port ca 1998"), person("Albrecht",
"    Gebhardt", role = "trl", comment = "partial port ca
"    1998"), person("David", "Firth", role = "ctb"))
Description:  Functions and datasets to support Venables and
Ripley, "Modern Applied Statistics with S" (4th
edition, 2002).
Title:        Support Functions and Datasets for Venables and
Ripley's MASS
LazyData:     yes
ByteCompile:  yes
License:      GPL-2 | GPL-3
URL:          http://www.stats.ox.ac.uk/pub/MASS4/
NeedsCompilation: yes
Packaged:     2016-04-21 09:06:13 UTC; ripley
Author:       Brian Ripley [aut, cre, cph], Bill Venables [ctb],
Douglas M. Bates [ctb], Kurt Hornik [trl] (partial
port ca 1998), Albrecht Gebhardt [trl] (partial port
ca 1998), David Firth [ctb]
Maintainer:   Brian Ripley <ripley@stats.ox.ac.uk>
Repository:   CRAN
Date/Publication: 2016-04-21 11:13:45
Built:        R 3.3.1; x86_64-apple-darwin13.4.0; 2016-06-24
```

16-21. Rのパッケージ（ライブラリ）

Rで利用できるパッケージをつかう

パッケージを使うときは
そのままパッケージ名を書けば良い。

> library()

パッケージの一覧がでくる。

> library(help=パッケージ名)

パッケージのヘルプを見たい時

> library(help=MASS)

パッケージMASSのヘルプを見たい場合の例

> library(MASS)

パッケージMASSを使いたい時

* MASSパッケージとstasパッケージは
Rにはじめから同封されています。

16-21. Rのパッケージ（ライブラリ）

Rで利用できるパッケージをつかう

パッケージを使おうと思ったけれど、
そのパッケージを使うためには他のパッケージも必要なのに
それがインストールされていないという場合
必要なパッケージをまとめてインストールしてしまえばよい。

> `library(rgl)` パッケージrglを使おうとした。

`library(rgl)` でエラー: 'rgl' という名前のパッケージはありません でもエラーが表示された。
そんなパッケージは存在しないと言っている。

> `install.packages("rgl", dependencies=TRUE)` dependencies=Tで依存関係にあるパッケージも
まとめて全部インストールする事ができる

パッケージを '/Users/kosentarou/Library/R/3.3/library' 中にインストールします

参考URL

<https://www.task-notes.com/entry/20150822/1440212400>

16-22. 判別分析（線形判別分析）

Rで利用できるパッケージMASSの中のlda関数をつかう

線形判別分析を行うにあたり、
RのパッケージMASS（インストール時にデフォルトで入っている）に入っているlda関数を使う。

- > library(MASS) パッケージをロードする。パッケージMASSを使う準備。
- > gouhi <- read.table("gouhi_line_hantei.csv", header=T, sep=",") 使うデータの読み込み
- > hikki <- gouhi[,2]
- > mensetsu <- gouhi[,3]
- > gouhugou <- gouhi[,4]
- > ans <- lda(gouhugou ~ hikki + mensetsu)

関数lda()は、線形判別分析 Linear discriminant analysis の頭文字
使い方はlm()関数とほとんど同じ。
目的変数が量的変数ではなく質的変数になっただけだからね。

16-23. 判別分析（線形判別分析）

> str(ans)

いつもどおりstr()を用いて、
詳細を確認してもよい。
オブジェクトの構造を表示
することができる。

判別式の係数

観測値を判別関数に変換する行列
で、グループ内共分散行列が球系
になるように正規化されている

特異値で、線形判別変数に関するグループ間・内標準偏差
の比を与える。これらの2乗は標準的なF統計量である

データ数

実行時の呼び出し

List of 10

グループの初期構成比

```
$ prior : Named num [1:2] 0.5 0.5
.. attr(*, "names")= chr [1:2] "fugoukaku" "goukaku"
$ counts : Named int [1:2] 5 5
.. attr(*, "names")= chr [1:2] "fugoukaku" "goukaku"
グループの平均 $ means : num [1:2, 1:2] 60 54 58 82
.. attr(*, "dimnames")=List of 2
.. ..$ : chr [1:2] "fugoukaku" "goukaku"
.. ..$ : chr [1:2] "hikki" "mensetsu"
$ scaling: num [1:2, 1] -0.0334 0.1446
.. attr(*, "dimnames")=List of 2
.. ..$ : chr [1:2] "hikki" "mensetsu"
.. ..$ : chr "LD1"
$ lev : chr [1:2] "fugoukaku" "goukaku"
$ svd : num 5.8
$ N : int 10
$ call : language lda(formula = goufugou ~ hikki + mensetsu)
$ terms :Classes 'terms', 'formula' language goufugou ~ hikki + mensetsu
.. .. attr(*, "variables")= language list(goufugou, hikki, mensetsu)
.. .. attr(*, "factors")= int [1:3, 1:2] 0 1 0 0 1
.. .. .. attr(*, "dimnames")=List of 2
.. .. ..$ : chr [1:3] "goufugou" "hikki" "mensetsu"
.. .. ..$ : chr [1:2] "hikki" "mensetsu"
.. .. attr(*, "term.labels")= chr [1:2] "hikki" "mensetsu"
.. .. attr(*, "order")= int [1:2] 1 1
.. .. attr(*, "intercept")= int 1
.. .. attr(*, "response")= int 1
.. .. attr(*, ".Environment")=<environment: R_GlobalEnv>
.. .. attr(*, "predvars")= language list(goufugou, hikki, mensetsu)
.. .. attr(*, "dataClasses")= Named chr [1:3] "factor" "numeric" "numeric"
.. .. .. attr(*, "names")= chr [1:3] "goufugou" "hikki" "mensetsu"
$ xlevels: Named list()
- attr(*, "class")= chr "lda"
```

16-24. 判別分析（線形判別分析）

> ans

Call:

lda(goufugou ~ hikki + mensetsu) 判別分析に用いるモデル

Prior probabilities of groups:
fugoukaku goukaku
0.5 0.5

各グループ（合格、不合格）の事前確率（初期構成比）
各グループ（合格、不合格）に属するだろう確率は、50%ずつだ。

Group means:
 hikki mensetsu
fugoukaku 60 58
goukaku 54 82

各グループごとに、変数の平均値を求めている。
筆記の点数は、不合格のひとの平均60、合格のひとの平均54点
面接の点数は、不合格のひとの平均58、合格のひとの平均82点

Coefficients of linear discriminants:
 LD1
hikki -0.03336243
mensetsu 0.14462614

求めた判別係数（判別式の係数）
（ただし各グループに対する判別関数のグループ内分散が
1 になるように計算されている）

ここから

hikkiの判別係数aが-0.3336243、mensetsuの判別係数が0.14462614と求まった。
を使って、判別式（線型判別関数）を記せば、

$z = ax + by + c$ だったので、

$z = -0.03336243x + 0.14462614y + c$ となる。

（定数項cはここには出てきていないので

明示的に必要な場合は別途求めることになる）

16-25. 判別分析（線形判別分析）

行列の掛け算は、`%*%`で行う。

今は判別分析の計算で得られている
それぞれの行列を掛けている

```
> ans$means
```

	hikki	mensetsu	
fugoukaku	60		58
goukaku	54	82	

```
> ans$scaling
```

	LD1
hikki	-0.03336243
mensetsu	0.14462614

第1判別関数の負荷量を取得

```
> apply(ans$means, 2, function(x) {
  %*% ans$scaling, 2, mean)
})
```

```
LD1
8.222171
```

apply(データ, 1か2, やりたい計算)

↑
1だと行に対して、
2だと列に対して、
計算する

↑
sumとかmeanとか

これにより判別式は、

$$z = -0.03336243x + 0.14462614y + 8.222171$$

と求まった。

16-26. 判別分析（線形判別分析）

> ans2 <- predict(ans) 判別式を用いて、判別結果を出してみましょう。

> ans2

\$class それぞれのデータがどのグループであると判別されたか、その結果。

[1] goukaku goukaku fugoukaku fugoukaku goukaku goukaku fugoukaku fugoukaku goukaku

Levels: fugoukaku goukaku

\$posterior

	fugoukaku	goukaku
1	2.978909e-01	7.021091e-01
2	5.320601e-05	9.999468e-01
3	9.999424e-01	5.761477e-05
4	9.989950e-01	1.005002e-03
5	1.389823e-03	9.986102e-01
6	1.037193e-05	9.999896e-01
7	9.997045e-01	2.954951e-04
8	8.309314e-01	1.690686e-01
9	9.993330e-01	6.669893e-04
10	7.089139e-03	9.929109e-01

それぞれのデータがそれぞれのグループに属する、事後確率

\$x

	LD1
1	0.2335370
2	2.6806714
3	-2.6589858
4	-1.8799730
5	1.7915626
6	3.1260598
7	-2.2135973
8	-0.4337116
9	-1.9917372
10	1.3461741

求めた判別式に

データを入れて計算した値、つまり「判別値=判別得点」

16-27. 判別分析（線形判別分析）

```
> hyou <- table(gouhi$hantei, predict(ans)$class)  
> hyou
```

	fugoukaku	goukaku
fugoukaku	5	0
goukaku	0	5

読み込んだデータのグループの列（今回は判定の列）と判別分析によって判別された結果の表を描かせています。

読み込んだデータで不合格とされているものが、今回の判別分析で合格と判定された、というような誤判別率は0%だったことがわかります。

16-28. 判別分析（線形判別分析）

【課題 16-28A】

ここまで行ったR上での解析のうち、`predict(ans)`によって得られた結果の部分が表示されている画面のスクリーンショットを撮って提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

16-29. 判別分析（線形判別分析）

【課題 16-29A】

印刷屋さんではポスターの印刷を請け負っている。出来上がったポスターの品質は、検査員が目視で評価している。品質の善し悪しには、3つの変数が影響していると考えられた。インクの濃度、粘度、熱処理時間である。これらの3つの説明変数で品質を判別する式を考えたい。データはファイル（Poster.csv）にまとめてある。

判別分析を適用する前に3つの変数のうち2つの変数同士を組み合わせた散布図を描け。また、検査員の判定によって、品質の良い・悪いが判明しているのので、散布図上にその区別がつくようにプロットせよ（区別できるようにマーカーを設定すれば良い）全ての散布図は1枚のPDFにまとめて提出せよ。軸の名前と凡例も忘れずにつけよ。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

16-29. 判別分析（線形判別分析）

【課題 16-29B】

前問において、品質の善し悪しをよく分離していると分かる散布図を1枚選び、そこで用いられている2変数を説明変数として用いて判別分析を行おう。判別分析によって得られる線型判別関数を求め、これを使って、データから判別値を求めなさい。求めた結果線型判別関数による判別値の結果をパワーポイントに記しなさい。（ヒント； [ans2](#) のLD1のところを見よという事）

またこの線型判別関数の有効性は誤判別率で見ることができる。線型判別関数にデータを入れて求めた判別値をよく見なさい。判別値が正なら品質は良、判別値が負なら品質は不良と判断されたということである。もともとのデータ

（Poster.csv）では検査員による良・不良が判定されているが、それと見比べて、全部で20個のサンプルに対して何個のサンプルが誤判別されているか？誤判別率（＝誤判別個数／全体の個数）を求め、パワーポイントに記しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで