

第11回 (2026.06.10)

データマイニング概論

※すべての授業資料について著作権を放棄していません。そのため、科目受講者が、自己の授業受講以外の目的で資料を電子的もしくは紙媒体等によって他者へ有償無償のいずれによらず譲渡することは禁止されています。授業受講者はこのことを理解したうえで受講しているとみなします。

熊本高等専門学校
生物化学システム工学科
木原 久美子 (専攻科棟3階)
kihara@kumamoto-nct.ac.jp

0-1. もくじ

0-1. 目次

0-2. 準備

16-30～. 判別分析（正準判別分析）

17-1～. 主成分分析

シラバス	←第01回
Rのインストール・準備・起動・使用練習	←第02回
ディレクトリ階層構造, 最低限のコマンド, ヘルプ, 四則演算, 代入, 行と列, 系列名, CSVファイル, データの読み込み, ヒストグラムの描画, 相対度数, 密度関数, 図の保存	←第03-04回
ソースファイルから複数の図をプロット	←第04回
散布図, 単回帰分析, マーカーの色種類, プロット重合わせ	←第05-07回
データ型・データ構造	←第05回
図へ文字列の書き込み, 凡例表示, 識別子	←第06回
特定のデータを抜き出して解析	←第06回
相関解析・相関係数／グループごとの解析	←第07回
重回帰分析	←第08回
円グラフ・ドーナツ・箱ひげ図	←第09回
判別分析（線形判別）	←第10回

0-2. 準備

特定のフォルダを作りそこに授業に関係するファイルを保存するようにしましょう。各自でいつも準備を進めておいて下さい。

- 自分で決めた場所にData_miningフォルダを作成
授業名がデータマイニング概論 (Data mining)なので。
- そのフォルダの中にclassXXフォルダを作成。
XXに01とか02とか、授業の回数を入れておけば見分けが付きやすい。
毎回、授業中に行う作業はこのフォルダの中に保存するようにせよ。

2-6. 最低限のコマンド・一覧（前回まで）

□Rを立ち上げる windowsのスタート→プログラム→R

□コマンドで居場所を確認&今日の場所に移動

getwd()	今自分がどこにいるか居場所を確認
setwd("../")	ひとつうえの階層のディレクトリに行く
getwd()	居場所を確認！

dir()	今いるディレクトリ内に何があるか見る
setwd("./class6")	ディレクトリ内のclass4に移動
getwd()	うまく移動できたかgetwdで確認

help(dir)	dirの使い方見たい時。helpで何でも分かる
q()	Rを終わりにしたいとき
	スペースを保存するか聞かれたら保存しないを選択

16-30. 判別分析（正準判別分析）

判別分析（正準判別分析）

線形判別分析では、判別する群が k 個ある場合、一般的には $k-1$ 個の判別関数が必要になる。（前回の授業では、群の数が2個の時、 $2-1=1$ 個の判別関数を用いた。）

母集団が多変量の場合、判別の様子を視覚化することは難しい。

そこで、主成分分析（後に行う）と似たような考え方で次元を縮約して、判別を少数の次元で行おうとするものである。

判別に必要な「次元の減少」を行う判別分析として、正準判別分析が行われる。

例えばデータの項目が4次元以上になった場合に、図示することが出来ないので視覚的な理解が難しくなる。これを、2次元や3次元に射影して、データの特徴を捉えることが役に立つ。

その次元圧縮をできる判別分析が


「正準判別分析」(canonical discriminant analysis)。

正準変量(canonical variance)と呼ばれる変量を用いて判別する。

16-30. 判別分析（正準判別分析）

判別分析（正準判別分析）

ここでは3群の判別分析を考えてみよう。図が複雑に見えるが前回と同じ考え方で、 p 個の要因（変量）の観測データがあって、 p 変量の p 次元の空間上に、データが散らばっているとする。



まず3群（一般的には k 群）の重なりが最小になるような判別軸を見つける。

この軸を第1正準軸という。


この軸に、各群のプロットを正射影して、判別得点1を求める。

次元が増えて図は見にくくてすみませんがイメージしてください。

16-30. 判別分析（正準判別分析）

判別分析（正準判別分析）

ここでは3群の判別分析を考えてみよう。図が複雑に見えるが前回と同じ考え方で、 p 個の要因（変量）の観測データがあって、 p 変量の p 次元の空間上に、データが散らばっているとする。



次にその第1正準軸上で、多少の重なりがあり、判別が弱かった残りの2群（一般的には $k-1$ 群）に着目して、その重なりが最小になるような別の判別軸2を見つける。

この軸を第2正準軸という。


この軸にプロットを正射影して判別得点2とする。

次元が増えて図は見にくくてすみませんがイメージしてください。

16-30. 判別分析（正準判別分析）

判別分析（正準判別分析）

ここでは3群の判別分析を考えてみよう。図が複雑に見えるが前回と同じ考え方で、 p 個の要因（変量）の観測データがあって、 p 変量の p 次元の空間上に、データが散らばっているとす。



4群以上の場合にはこれを繰り返すことで、 k 群の場合には $k-1$ 群の判別軸を見つけ出すことができる。

次元が増えて図は見にくくてすみませんがイメージしてください。


16-30. 判別分析（正準判別分析）

判別分析（正準判別分析）

ここでは3群の判別分析を行ってみよう。

アップロードしてあるデータ（[Tochi_kakaku.csv](#)）を使ってやってみよう。

このデータは、この30–40年の間に目的別に開発が行われてきた、ある国のある地域（ここではCityとしてある）における土地の価格を、わかりやすく日本の地価単位である百万円／坪 $=3.3\text{m}^2$ となるように変換した値の変動（1999年、2010年、2020年）と、その地域における人口密度を、人／ km^2 となるように換算して表したものである。



16-30. 判別分析（正準判別分析）

Rで利用できるパッケージMASSの中のlda関数をつかう

線形判別分析を行うにあたり用いたlda関数は、3群以上の判別の場合には、実際は正準判別分析を行っている。（2群の場合には線形判別分析と正準判別分析はおなじだが、3群以上だと異なる。）

> library(MASS) パッケージMASSを使う準備。

> Tochi <- read.table("Tochi_kakaku.csv", header=T, sep=",") 使うデータの読み込み

> Tochi1999 <- Tochi[,1]

> Tochi2010 <- Tochi[,2]

> Tochi2020 <- Tochi[,3]

> Mitsudo <- Tochi[,4]

> City <- Tochi[,5]

> Tochi_ans <- lda(City~Tochi1999+Tochi2010+Tochi2020+Mitsudo)
関数lda(説明変数のデータ行列, 群をあらわす変数)

> Tochi_ans

16-30. 判別分析（正準判別分析）

Rで利用できるパッケージMASSの中のlda関数をつかう

前のページに記した形でもわかりやすくてよいが、
毎回名前をつけて各列のデータを1列ずつ入れたオブジェクトを用意するのは面倒。

> library(MASS) パッケージMASSを使う準備。

> Tochi <- read.table("Tochi_kakaku.csv", header=T, sep=",") 使うデータの読み込み

> Tochi_ans <- lda(Tochi[,1:4], Tochi[,5]) 関数lda(説明変数のデータ行列, 群をあらわす変数)

とすれば、より短く記せて楽ちん。

16-30. 判別分析（正準判別分析）

> str(Tochi_ans)

いつでもおりstr()
を用いて、詳細を
確認してもよい。

オブジェクトの構
造を表示すること
ができる。

```
List of 10
 $ prior : Named num [1:3] 0.333 0.333 0.333
 ..- attr(*, "names")= chr [1:3] "City_A" "City_B" "City_C"
 $ counts : Named int [1:3] 50 50 50
 ..- attr(*, "names")= chr [1:3] "City_A" "City_B" "City_C"
 $ means : num [1:3, 1:15] 5.01 5.94 6.59 3.43 2.77 ...
 ..- attr(*, "dimnames")=List of 2
 .. ..$ : chr [1:3] "City_A" "City_B" "City_C"
 .. ..$ : chr [1:15] "Tochi1999" "Tochi2010" "Tochi2020" "Mitsudo" ...
 $ scaling: num [1:15, 1:2] 9.53 27.87 62.13 173.18 -3.63 ...
 ..- attr(*, "dimnames")=List of 2
 .. ..$ : chr [1:15] "Tochi1999" "Tochi2010" "Tochi2020" "Mitsudo" ...
 .. ..$ : chr [1:2] "LD1" "LD2"
 $ lev : chr [1:3] "City_A" "City_B" "City_C"
 $ svd : num [1:2] 97.7 15.5
 $ N : int 150
 $ call : language lda(formula = City ~ Tochi1999 * Tochi2010 * Tochi2020 * Mitsudo)
 $ terms :Classes 'terms', 'formula' language City ~ Tochi1999 * Tochi2010 * Tochi2020 * Mitsudo
 ..- attr(*, "variables")= language list(City, Tochi1999, Tochi2010, Tochi2020, Mitsudo)
 ..- attr(*, "factors")= int [1:5, 1:15] 0 1 0 0 0 0 0 1 0 0 ...
 .. ..- attr(*, "dimnames")=List of 2
 .. .. ..$ : chr [1:5] "City" "Tochi1999" "Tochi2010" "Tochi2020" ...
 .. .. ..$ : chr [1:15] "Tochi1999" "Tochi2010" "Tochi2020" "Mitsudo" ...
 ..- attr(*, "term.labels")= chr [1:15] "Tochi1999" "Tochi2010" "Tochi2020" "Mitsudo" ...
 ..- attr(*, "order")= int [1:15] 1 1 1 1 2 2 2 2 2 2 ...
 ..- attr(*, "intercept")= int 1
 ..- attr(*, "response")= int 1
 ..- attr(*, ".Environment")=<environment: R_GlobalEnv>
 ..- attr(*, "predvars")= language list(City, Tochi1999, Tochi2010, Tochi2020, Mitsudo)
 ..- attr(*, "dataClasses")= Named chr [1:5] "factor" "numeric" "numeric" "numeric" ...
 .. ..- attr(*, "names")= chr [1:5] "City" "Tochi1999" "Tochi2010" "Tochi2020" ...
 $ xlevels: Named list()
 - attr(*, "class")= chr "lda"
```

16-30. 判別分析（正準判別分析）

> Tochi_ans

Call:

lda(Tochi[, 1:4], Tochi[, 5]) 判別分析に用いるモデル

Prior probabilities of groups:

City_A	City_B	City_C
0.3333333	0.3333333	0.3333333

各グループ (City_A, City_B, City_C) の事前確率

各グループ (City_A, City_B, City_C) に属するだろう確率は、33%ずつだ。

Group means:

	Tochi_1999_HyakuMan_per_Tsubo	Tochi_2010_HyakuMan_per_Tsubo	Tochi_2020_HyakuMan_per_Tsubo	JinkouMitsudo_SenNin_per_km2
City_A	5.006	3.428	1.462	0.246
City_B	5.936	2.770	4.260	1.326
City_C	6.588	2.974	5.552	2.026

各グループごとの平均値

Coefficients of linear discriminants:

	LD1	LD2
Tochi_1999_HyakuMan_per_Tsubo	0.8293776	0.02410215
Tochi_2010_HyakuMan_per_Tsubo	1.5344731	2.16452123
Tochi_2020_HyakuMan_per_Tsubo	-2.2012117	-0.93192121
JinkouMitsudo_SenNin_per_km2	-2.8104603	2.83918785

正準判別係数

Proportion of trace:

LD1	LD2
0.9912	0.0088

求めた判別係数はLD1とLD2の2つが得られた。

判別関数は、この判別係数と変数の線形結合となる。

(ただし各グループに対する判別関数のグループ内分散が1になるように計算されている)

16-30. 判別分析（正準判別分析）

判別式の定数項は以下で求められる。

```
> Tochi_ans$means
```

	Tochi1999	Tochi2010	Tochi2020
City_A	5.006	3.428	1.462
City_B	5.936	2.770	4.260
City_C	6.588	2.974	5.552

行列の掛け算は、`%*%`で行う。
今は判別分析の計算で得られている
それぞれの行列を掛けている

第1・2判別関数の負荷量を取得

```
> Tochi_ans$scaling
```

	LD1	LD2
Tochi1999	9.533327	-4.0839150
Tochi2010	27.873168	-5.5224689
Tochi2020	62.126373	-14.8692610
Mitsudo	173.177789	-39.1641855

```
> apply(Tochi_ans$means, 2, function(x) { apply(x, 1, function(y) { sum(y * Tochi_ans$scaling[, 2]) }) })
```

LD1	LD2
105.56881	-29.94547

第1判別関数の定数項 第2判別関数の定数項

`apply(データ, 1か2, やりたい計算)`

↑ ↑
1だと行に対して、 2だと列に対して、
計算する

各グループ(品種)に対する判別関数の
グループ内分散が1になるように計算さ
れている。

この尺度変換は、`lda()` 関数が返す変数
の“scaling”という要素に保存されている。

この要素は、第1列が第1判別関数の
負荷量、第2列が第2判別分析の負荷
量という形の行列。

これにより判別式の定数項が求まった。

判別式は以下

$$y = 0.8293776 x_1 + 1.5344731 x_2 + 2.2012117 x_3 + (-2.8104603) x_4 + 105.56881$$

$$y = 0.02410215x_1 + 2.16452123 x_2 + (-0.93192121) x_3 + 2.83918785 x_4 + (-29.94547)$$

16-30. 判別分析（正準判別分析）

> `Tochi_ans2 <- predict(Tochi_ans)` 判別式を用いて判別結果を出してみましょう。
 > `Tochi_ans2` 判別結果の表示 学習データについて判別を行った判別結果は`predict()`関数で得られる。

`$class` 分類された群。それぞれのデータがどのグループであると判別されたか、その結果。
 [1] City_C City_C City_C City_C City_C City_C City_C City_C City_C City_C City_C City_C City_B City_B City_C City_C City_C City_B
 [19] City_C City_C City_B City_B City_B City_C City_C City_C City_C City_C City_C City_B City_B City_B City_C City_C City_C City_B
 ... (略) ...
 Levels: City_A City_B City_C

`$posterior`

	City_A	City_B	City_C
1	1.817436e-139	1.109699e-07	9.999999e-01
2	6.870141e-130	1.049580e-07	9.999999e-01
3	6.769571e-130	1.438860e-10	1.000000e+00
4	3.793904e-137	1.816245e-07	9.999998e-01
...	(略)	...	...

各ケースのデータが、どのグループ・それぞれの群に所属すると判別されているかの事後確率(0~1)

`$x`

	LD1	LD2
1	9.254416	2.893639869
2	8.334520	3.381646849
3	8.217260	4.953963761
4	9.040672	2.891082193
5	8.831622	2.601636672
...	(略)	...

求めた判別式にデータを入れて計算した値、つまり「判別値(判別関数得点)」

16-30. 判別分析（正準判別分析）

Tochi_ansのprecidt関数が返す
↓オブジェクトのclass要素

```
> hyou <- table(Tochi[,5], Tochi_ans2$class)
```

```
> hyou
```

	City_A	City_B	City_C
City_A	50	0	0
City_B	0	49	1
City_C	0	1	49

読み込んだデータのグループの列（今回は判定の列）と
判別分析で判別された結果の集計の表を描かせています。

例えば、実際にCity_Cであったもののうち
正しくCity_Cと判別されたものが49個、
誤ってCity_Bと判別されたものが1個あったということ。

16-30. 判別分析（正準判別分析）

【課題 16-30A】

ここまで行ったR上での解析のうち、最後の、`table()`によって得られた結果の部分が表示されている画面のスクリーンショットを撮って提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

16-30. 判別分析（正準判別分析）

ちなみに

```
> plot(Tochi_ans, dimen=1)
```




読み込んだデータをもちいてlda()によって計算した結果はTochi_ansに入っているのをこれをプロットしてみる。

ただし、**dimen=1**とすることで、ヒストグラムを表示する。

第1判別関数得点のグループごとのヒストグラム(分布)が表示される。

重なる領域が多いほどお互いに間違って判別される確率(誤判別率)が高い。

City_Aは容易に判別できそうですね。



16-30. 判別分析（正準判別分析）

【課題 16-30B】

ここまで行ったR上での解析のうち、ここで得られたヒストグラムの図をPDF形式で提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで


16-30. 判別分析（正準判別分析）

ちなみに

```
> plot(Tochi_ans, dimen=2, cex=0.5)
```

読み込んだデータを用いて、lda()によって計算した結果はTochi_ansに入っているのでこれをプロットしてみる。ただし、**dimen=2**とすることで、散布図を表示する。横軸に第一判別関数、縦軸に第二判別関数としたときの図（見にくかったのがcexをつかってマーカーサイズを小さくしている）を描く。

City_Aは容易に判別できそう、City_BとCity_Cは分布に重なりがないことが見て取れますね。



16-30. 判別分析（正準判別分析）

【課題 16-30C】

ここまで行ったR上での解析のうち、ここで得られた散布図をPDF形式で提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで


16-30. 判別分析（正準判別分析）

ちなみに

アズインテジャーで整数にh寝棺してマーカーの形にした

```
> plot(Tochi_ans2$x[,1], Tochi_ans2$x[,2], pch=as.integer(Tochi[,5]), asp=1)
```

前のページのようにplot関数による散布図でもう少し見やすくしたい場合には、predict()関数が返すオブジェクト（ここではTochi_ans2の）class要素とx要素を使って、このようなプロットを行ったほうが良いかもしれない。描いた散布図は、前のページと同じ、横軸に第一判別関数、縦軸に第二判別関数としたときの図ではあるものの、マーカーをpchで指定する時に、グループ（Tochi[,5]）にかかっている）の種類をas.integer()によって整数に変換することで、その整数値によって示されるマーカーの形で区別しているの、見やすくなっているだろう。最後のaspは縦横比（x軸方向とy軸方向のメモリ）幅を同じにすることを意味する。



16-30. 判別分析（正準判別分析）

【課題 16-30D】

ここまで行ったR上での解析のうち、ここで得られた散布図をPDF形式で提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

16-3. 判別分析の手法

判別分析の手法

判別分析を行う方法は主に 4 種類ある。

(1) マハラノビスの距離による方法

qda()関数

(2) 線形判別関数、正準判別関数による方法

lda()関数

(3) 重回帰分析による方法

(4) ロジスティック回帰による方法

＊ただし、線形判別でも 2 次判別でも、共通して、データが正規分布に従うことを前提とする。また、線形判別分析には「全群団で分散が等しい」という前提がある。一方で、2 次判別分析(qdaを使う場合など)では「群団間で分散が異なる」場合にも対応することができる。

17-1. 主成分分析

重回帰分析や判別分析では、目的変数を別の変数を使って説明しようとする分析モデルでした。


ここでは、目的変数そのものは観測されておらず、あるひとつのサンプルについて複数の変数が観測されていて、これらの変数から特徴を抽出しようとする分析モデルを扱います。

主成分分析とは量的変数からなる外的基準を持たないデータに対する分析手法の一つです。多次元の量的変数を結合して、低次元の総合指標を作ることを目的とします。

3次元まではデータの散布図によってイメージができる様子でも、4変数以上になると4次元以上の空間への散布図をイメージすることが難しく、データの様子を理解するのは困難です。

考え方のイメージとしては、相関の強い変数に対して、軸を回転することによって、より少ない軸の変数だけで説明しようとする変換です（数学的には変数の分散共分散行列の固有値問題）。

17-1. 主成分分析



エッセンスとしては、データの散布図をイメージした時に（ここでは2次元にしているが3次元・・・n次元までイメージ）、データの分布を表現しやすい新たな軸（オレンジの軸； l と m は直交している）を導入し、その軸を使ってデータを表現しようとするものです。


この図ではxy平面上に描かれた二次元の分布ですが、新たに作った軸 l の成分だけを読み取っても分布の傾向を掴むことが出来ます。つまり、xyの2変量で表されていたデータを、 l の1変量でほぼあらわすことも出来る、というわけです。

また、 l 成分でデータを要約できるかどうかを判断する基準となるのが**寄与率**という指標です。データ全体に対して求めた各成分方向の二乗和を使って、ここでは例えば、

$$\left(l \text{ 成分の 2 乗和} \right) / \left\{ \left(l \text{ 成分の 2 乗和} \right) + \left(m \text{ 成分の 2 乗和} \right) \right\}$$

として求めたものが「 l 成分の寄与率」です。つまり、 m 成分の2乗和が占める割合が小さくなると、 l 成分だけであらわすというデータの要約が有効であると考えられます。 l 成分の寄与率が最大となるような、 l の方向を**第1主成分**、このときの m の方向を**第2主成分**と言います。

17-1. 主成分分析



1成分の寄与率が最大となるということは、寄与率の分母の値は一定であることを思えば、結局、1成分の平方和が最大になるということになります。

そして、平方和をサイズで割ったものが分散なので、1成分の平方和が最大になるということは、1成分の分散が最大になると言い換えることができます。

第1主成分は、分散が最大になる方向とも言えます。

また[ここでは省略していますが]、第1主成分の平方和は、第1主成分の固有値（1成分の2乗和）であり、線形代数を使った計算をすれば、固有値固有ベクトルの問題似すぎないことがわかります（次回以降）。

今回はまずとりあえず、R上で操作をしてみるによって、どのような流れで計算をして何がデータとして出てくるのかを実感してみることにしましょう。

17-1. 主成分分析

主成分分析をやってみよう

ある金融系の企業において、ランダムに選ばれた30の部署における35人の事務職員に対して行われたアンケートの結果を解析しよう。それぞれの部署において、管理者に対する態度の7つのアンケート質問を行い、これに対して「好意的な」解答をした人の割合を示している。

データは、[hyouka.csv](#) ファイルとして置いてある。
これをまず眺めて、次に読み込もう。

17-1. 主成分分析

```
> hyouka_ <- read.table("hyouka.csv", header=T, sep=", ")
```

```
> hyouka_
```

```
      rating complaints privileges learning raises critical advance
1      43      51          30          39      61      92      45
2      63      64          51          54      63      73      47
3      71      70          68          69      76      86      48
4      61      63          45          47      54      84      35
5      81      78          56          66      71      83      47
6      43      55          49          44      54      49      34
... (略) ...
```

```
> hyouka <- hyouka_[,-1]
```

```
> hyouka
```

```
      complaints privileges learning raises critical advance
1          51          30          39      61      92      45
2          64          51          54      63      73      47
3          70          68          69      76      86      48
4          63          45          47      54      84      35
5          78          56          66      71      83      47
6          55      49      44      54      49      34
... (略) ...
```

ここでは管理者に対する態度に対して、
7つの変数でアンケート調査データが取得されている。

rating 全体的な格付け
complaints 雇用者の苦情の処理
privileges 特別な特権の付与
learning 学習の機会
raises 能力に基づいた昇給
critical 批判的すぎるかどうか
advance 昇進


また、1つ目のデータ rating については、
会社の総合評価であり、今から行う主成分分析で
得ようとする指標なので、このデータ解析では
省いて利用しないこととします。

17-1. 主成分分析

> `summary(hyouka)` データの要約を見てみましょう。基本統計量を見て、分布を確認しましょう。

complaints	privileges	learning	raises	critical	advance
Min. :37.0	Min. :30.00	Min. :34.00	Min. :43.00	Min. :49.00	Min. :25.00
1st Qu.:58.5	1st Qu.:45.00	1st Qu.:47.00	1st Qu.:58.25	1st Qu.:69.25	1st Qu.:35.00
Median :65.0	Median :51.50	Median :56.50	Median :63.50	Median :77.50	Median :41.00
Mean :66.6	Mean :53.13	Mean :56.37	Mean :64.63	Mean :74.77	Mean :42.93
3rd Qu.:77.0	3rd Qu.:62.50	3rd Qu.:66.75	3rd Qu.:71.00	3rd Qu.:80.00	3rd Qu.:47.75
Max. :90.0	Max. :83.00	Max. :75.00	Max. :88.00	Max. :92.00	Max. :72.00

> `boxplot(hyouka)` 箱ひげ図でそれぞれの分布を比較します。



データの単位はすべて%
オーダーは同じで大きな違いはない
はず、と思いきや、分布を比較してみ
ると、advanceの平均が比較的小さい
ことがわかる。

そこで、標準化したデータで、主成分
分析を行うこととする。

17-1. 主成分分析

【課題 17-1A】

ここまで行ったR上での解析で得られた箱ひげ図をPDFファイルとして提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-1. 主成分分析

Rで主成分分析を行う関数には `princomp()` と `prcomp()` の2種類ある。

ここで用いた `princomp()` にはサンプルサイズと変数の数に制限があるので、その点を意識せずに済む `prcomp()` を使ってもよい。



最初の引数はモデル式を指定している。
チルダより左を空欄として、
右はすべての変数を利用するのでドット(.)とする。
今回は標準化したデータで分析を行うので
ここは `cor = TRUE` とする。

```
> hyouka_pca <- princomp(~., cor = TRUE, data=hyouka)
```

> `loadings(hyouka_pca)` `loadings()`関数を用いると、結果の主成分負荷量を見ることができる。
それぞれの主成分が元の変数に対してどれくらいの影響を与えているかを示している。

Loadings:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6
complaints	-0.439	0.313	-0.445	-0.316	0.192	-0.612
privileges	-0.395	0.309	-0.217	0.815		0.190
learning	-0.461	0.217	0.272	-0.225	-0.776	0.118
raises	-0.493	-0.116		-0.365	0.460	0.631
critical	-0.225	-0.802	-0.457		-0.289	
advance	-0.381	-0.321	0.687	0.206	0.255	-0.416

第3主成分は学習の機会や昇進などポジティブなことに対する項目が正となり、批判約定などネガティブな項目がふとなっている

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6
SS loadings	1.000	1.000	1.000	1.000	1.000	1.000
Proportion Var	0.167	0.167	0.167	0.167	0.167	0.167
Cumulative Var	0.167	0.333	0.500	0.667	0.833	1.000

第1主成分はすべて負になっているので、全体的な影響を表している総合指標となっている。

第2主成分は学習の機会や、雇用者の苦情の処理、特別な特権の付与などの、雇用者の機会に関する項目が正となり、昇進や能力に基づいた昇給など雇用者の待遇に対する項目が負となっている。

17-1. 主成分分析

【課題 17-1B】

ここまで行ったR上での解析で得られたローディングの結果のスクリーンショットを提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-1. 主成分分析

> `str(hyouka_pca)` いつもどおり`str()`を用いて、詳細を確認してもよい。
 オブジェクトの構造を表示することができる。

```
List of 7
 $ sdev      : Named num [1:6] 1.78 1.003 0.873 0.743 0.563 ...
  ..- attr(*, "names")= chr [1:6] "Comp.1" "Comp.2" "Comp.3" "Comp.4" ...
 $ loadings: loadings [1:6, 1:6] -0.439 -0.395 -0.461 -0.493 -0.225 ...
  ..- attr(*, "dimnames")=List of 2
   .. ..$ : chr [1:6] "complaints" "privileges" "learning" "raises" ...
   .. ..$ : chr [1:6] "Comp.1" "Comp.2" "Comp.3" "Comp.4" ...
 $ center   : Named num [1:6] 66.6 53.1 56.4 64.6 74.8 ...
  ..- attr(*, "names")= chr [1:6] "complaints" "privileges" "learning" "raises" ...
 $ scale     : Named num [1:6] 13.09 12.03 11.54 10.22 9.73 ...
  ..- attr(*, "names")= chr [1:6] "complaints" "privileges" "learning" "raises" ...
 $ n.obs     : int 30
 $ scores    : num [1:30, 1:6] 1.676 0.218 -2.105 1.36 -1.512 ...
  ..- attr(*, "dimnames")=List of 2
   .. ..$ : chr [1:30] "1" "2" "3" "4" ...
   .. ..$ : chr [1:6] "Comp.1" "Comp.2" "Comp.3" "Comp.4" ...
 $ call      : language princomp(formula = ~., data = hyouka, cor = TRUE)
 - attr(*, "class")= chr "princomp"
```

17-1. 主成分分析

> `hyouka_pca$sd^2` ← `sdev^2`を`sd^2`と書いている、同じ。
`princomp()`関数の結果の、標準偏差を用いて、固有値を求める。

```
Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6
3.1692232 1.0063467 0.7629087 0.5525165 0.3172465 0.1917584
```

> `hyouka_pca$sd^2/6`

```
Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6
0.52820387 0.16772446 0.12715145 0.09208608 0.05287441 0.03195973
```

> `summary(hyouka_pca)` 順に、寄与率、累積寄与率と求めることもできるが、`summary()`関数を用いれば一括で表示することもできる。

Importance of components:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6
Standard deviation	1.7802312	1.0031684	0.8734465	0.74331451	0.56324638	0.43790225
Proportion of Variance	0.5282039	0.1677245	0.1271515	0.09208608	0.05287441	0.03195973
Cumulative Proportion	0.5282039	0.6959283	0.8230798	0.91516586	0.96804027	1.00000000

寄与率

累積寄与率

Standard deviation


分散の割合ということなので
 それぞれの固有値のルート
 を取ったものです $\sqrt{\lambda}$
 ()。λはばらつきに相
 当する値。

17-1. 主成分分析

> `screeplot(hyouka_pca)`

スクリープロットによって視覚化することも出来る。

スクリープロットとは固有値を大きな順に並べたグラフのこと



主成分としては、累積寄与率が高い部分（例えば0.8以上など）を主成分として採用する。

主成分分析によって、寄与率の高い成分だけを採用すると考えれば、寄与率の1個あたりの平均値（今回の場合は $1/6=0.1667$ ）よりも大きい主成分だけを採用するという考え方もある（固有値が1以上を採用する場合と同じ）。

今回の場合は、前者の方法で考えれば主成分は3、後者の方法で考えれば主成分は2となる。

スクリープロットを見て、第1主成分が大きく、それ以降はなだらかに下がっていると判断する場合には、第1主成分だけを採用するという考え方もある。

17-1. 主成分分析

【課題 17-1C】

ここまで行ったR上での解析で得られたスクリープロットの結果をPDFファイルとして提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。


◎ 提出締切；次回の授業の前日の18:00まで

17-1. 主成分分析

ここでは主成分として第3主成分までを見ていくこととする。

変数ごとの主成分負荷量のプロットを描く。

```
> plot(hyouka_pca$loadings[,1:2], xlim=c(-0.5,0.5), ylim=c(-1,1))
```



17-1. 主成分分析

【課題 17-1D】

ここまで行ったR上での解析で得られた散布図の結果をPDFファイルとして提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-1. 主成分分析




ここでは主成分として第3主成分までを見ていくこととする。

部署ごとの主成分得点のプロットを描く 主成分得点は主成分分析の結果の内scoreによって得られる。

> `plot(hyouka_pca$scores[,1:2])` プロットできることを確認

> `plot(hyouka_pca$scores[,1:2], type="n")` プロット点を書かない

> `text(hyouka_pca$scores[,1:2], labels=1:30)` プロット点を数字で上書き



17-1. 主成分分析

【課題 17-1E】

ここまで行ったR上での解析で得られた3枚の散布図の結果をひとつのPDFファイルとして提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで



17-1. 主成分分析

変数ごとの主成分負荷量のプロットと部署ごとの主成分得点のプロットを重ね合わせる。

> `biplot(hyouka_pca, cex=0.4)` 2つの図は`biplot()`関数によってひとつの図に重ね合わせることができる。特にオプションとして変数を指定しなければ、横軸に第1主成分、縦軸に第2主成分を撮って重ね合わせる。



> `biplot(hyouka_pca, cex=0.4, choices=c(2,3))`

オプションとして`choices`引数に表示する主成分を指定することもできる。横軸に第2主成分、縦軸に第3主成分を表示させた。





17-1. 主成分分析

バイプロットは、ふたつのプロットを強引に重ね合わせていて、ここでは数字で部署を、文字で変数を表している。図を解釈するためには、主成分負荷量から軸の意味付けを行い、そこから主成分得点のプロットを解釈する。





17-1. 主成分分析

この場合では、右側の図から、横軸が右ほど雇用者の機会に関する項目、左ほど雇用者の待遇に関する項目をあらわすので、部署16は、雇用者の機会に関する項目が、部署1は、雇用者の待遇が特徴的だと言える。



17-1. 主成分分析

また、縦軸は上ほどポジティブな項目、下程ネガティブな項目となり、部署24はポジティブな解答項目が特徴的である。部署9や、部署14は、雇用者の機会の内ポジティブな解答項目が特徴的であると言える。



17-1. 主成分分析

【課題 17-1F】

ここまで行ったR上での解析で得られた結果をひとつのPDFファイルとして提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで