

第12回 (2026.06.17)

データマイニング概論

※すべての授業資料について著作権を放棄していません。そのため、科目受講者が、自己の授業受講以外の目的で資料を電子的もしくは紙媒体等によって他者へ有償無償のいずれによらず譲渡することは禁止されています。授業受講者はこのことを理解したうえで受講しているとみなします。

熊本高等専門学校
生物化学システム工学科
木原 久美子 (専攻科棟3階)
kihara@kumamoto-nct.ac.jp

0-1. もくじ

0-1. 目次

0-2. 準備

17-1～. 主成分分析

シラバス

← 第01回

Rのインストール・準備・起動・使用練習

← 第02回

ディレクトリ階層構造, 最低限のコマンド, ヘルプ, 四則演算,
代入, 行と列, 系列名, CSVファイル, データの読み込み,

ヒストグラムの描画, 相対度数, 密度関数, 図の保存

← 第03-04回

ソースファイルから複数の図をプロット

← 第04回

散布図, 単回帰分析, マーカーの色種類, プロット重合わせ

← 第05-07回

データ型・データ構造

← 第05回

円グラフ・ドーナツ・箱ひげ図

← 第06回

図へ文字列の書き込み, 凡例表示, 識別子

← 第07回

特定のデータを抜き出して解析

← 第07回

相関解析・相関係数／グループごとの解析

← 第08回

重回帰分析

← 第09回

判別分析（線形判別・正準判別分析）

← 第10-11回

0-2. 準備

特定のフォルダを作りそこに授業に関係するファイルを保存するようにしましょう。各自でいつも準備を進めておいて下さい。

- 自分で決めた場所にData_miningフォルダを作成
授業名がデータマイニング概論 (Data mining)なので。
- そのフォルダの中にclassXXフォルダを作成。
XXに01とか02とか、授業の回数を入れておけば見分けが付きやすい。
毎回、授業中に行う作業はこのフォルダの中に保存するようにせよ。

2-6. 最低限のコマンド・一覧（前回まで）

□Rを立ち上げる windowsのスタート→プログラム→R

□コマンドで居場所を確認&今日の場所へ移動

getwd()	今自分がどこにいるか居場所を確認
setwd("../")	ひとつうえの階層のディレクトリに行く
getwd()	居場所を確認！

dir()	今いるディレクトリ内に何があるか見る
setwd("./class6")	ディレクトリ内のclass4へ移動
getwd()	うまく移動できたかgetwdで確認

help(dir)	dirの使い方見たい時。helpで何でも分かる
q()	Rを終わりにしたいとき
	スペースを保存するか聞かれたら保存しないを選択

17-2. 主成分分析


前回までに、主成分分析をとりあえずやってみるということで、Rの上でコマンドを打ちながら計算を行いグラフを描いてみるということを行いました。

ここではもう一度、主成分分析について振り返りながら、練習を行っていきましょう。

17-3. 主成分分析；分布のばらつきと主成分・主成分得点

主成分分析の意味は「総合力がトップの選出」をするための分析手法とも言えます。

例えば映画のデータをもとに考えてみることにしましょう。




ある年に公開された全映画の
「観客動員数」と「DVD売上枚数」
をプロットして示したものとします。

このうち、総合人気度がトップの映画は
どれだと思いますか？

17-3. 主成分分析；分布のばらつきと主成分・主成分得点

主成分分析の意味は「総合力がトップの選出」をするための分析手法とも言えます。

例えば映画のデータをもとに考えてみることにしましょう。



ある年に公開された全映画の
「観客動員数」と「DVD売上枚数」
をプロットして示したものとします。


このうち、総合人気度がトップの映画は
どれだと思いますか？

なんとなく、どちらも高い、
ピンクで丸をつけたあたりかな？と
思いますよね。

17-3. 主成分分析；分布のばらつきと主成分・主成分得点

主成分分析では、まず、データの分散が最も大きなところに、軸を作る、でしたね。その線が、新しい座標空間の軸になるということでした。


では次に、その軸における、各個体の座標を求めてみましょう。



17-3. 主成分分析；分布のばらつきと主成分・主成分得点

主成分分析では、まず、データの分散が最も大きなところに、軸を作る、でしたね。その線が、新しい座標空間の軸になるということでした。


では次に、その軸における、各個体の座標を求めてみましょう。座標は、各点から、新しい軸へ、垂直に垂線を下ろせば求まりますね。



17-3. 主成分分析；分布のばらつきと主成分・主成分得点


軸に垂直におろした垂線が、軸と交わるところが、その個体のその軸での値です。

拡大図に記した青色の矢印が示す値は、軸の中で最大の値を取っていることになります。すなわち、青丸の映画が、総合人気度トップの映画ということになります。




17-3. 主成分分析；分布のばらつきと主成分

この時引いた、ピンク色の軸のことを、「主成分」と呼び、主成分における各個体の座標（軸におろした垂線が示す値）を「主成分得点」という。



17-3. 主成分分析；分布のばらつきと主成分・主成分得点

プロットした点の散らばり具合が異なれば、主成分（分散が最も大きな所＝散らばりが最大の所に作る軸）の取り方も様々に変わる。
2次元空間だけでなく3次元以上の空間でも構わない。




17-3. 主成分分析；分布のばらつきと主成分・主成分得点

この例はどうだろうか？

あるチェーン店が「クレーム件数」と「売上高」を調べた記録があった。

この例の場合の、総合実績トップのお店と、ワースト1のお店はどこになる？




17-3. 主成分分析；分布のばらつきと主成分・主成分得点

この例はどうだろうか？

あるチェーン店が「クレーム件数」と「売上高」を調べた記録があった。

この例の場合の、総合実績トップのお店と、ワースト1のお店はどこになる？




17-3. 主成分分析；分布のばらつきと主成分・主成分得点

この例はどうだろうか？

あるチェーン店が「クレーム件数」と「売上高」を調べた記録があった。

この例の場合の、総合実績トップのお店と、ワースト1のお店はどこになる？



ばらつきが一番大きい方向に軸をとって（ピンクの線）、これが主成分。


この主成分に各店から垂線をおろせば、主成分得点が求まる。

17-3. 主成分分析；分布のばらつきと主成分・主成分得点

この例はどうだろうか？

あるチェーン店が「クレーム件数」と「売上高」を調べた記録があった。

この例の場合の、総合実績トップのお店と、ワースト1のお店はどこになる？




17-4. 主成分分析；1つ目の注意点

主成分分析の概念を図であらわすとこのような感じ。

映画の例で言えば、「顧客動員数」と「DVD売上枚数」が説明変数、「総合人気度」が目的変数ですね。

＊主成分分析における目的変数は、実在する変数ではなくて想像の産物です。




(どちらかというと基準化して分析する方法を選ぶ人が多い。)

	観客動員数 (万人)	DVD売上枚数 (万枚)
映画1	980	90
⋮	⋮	⋮
映画742	770	110
平均	660	90
標準偏差	120	17


	観客動員数の基準値 U_1	DVD売上枚数の基準値 U_2
映画1	2.7	0
⋮	⋮	⋮
映画742	0.9	1.2
平均	0	0
標準偏差	1	1

17-4. 主成分分析；2つ目の注意点



基準化しないで分析

	観客動員数 (万人)	DVD売上枚数 (万枚)
映画1	980	90
⋮	⋮	⋮
映画742	770	110
平均	660	90
標準偏差	120	17




基準化して分析

	観客動員数の基準値 U_1	DVD売上枚数の基準値 U_2
映画1	2.7	0
⋮	⋮	⋮
映画742	0.9	1.2
平均	0	0
標準偏差	1	1

17-4. 主成分分析；3つ目の注意点

主成分分析の構造を式と図であらわすと、こうなる。


$$\begin{array}{ccccccc}
 Z & = & a_1 U_1 & + & a_2 U_2 & + \cdots + & a_p U_p \\
 \uparrow & & \uparrow & & \uparrow & & \uparrow \\
 \text{主成分} & & \text{説明変数1} & & \text{説明変数2} & & \text{説明変数p} \\
 & & \text{の基準値} & & \text{の基準値} & & \text{の基準値}
 \end{array}$$



17-4. 主成分分析；4つ目の注意点

主成分は、説明変数の個数分だけ求まる！1個じゃないよ。
説明変数がp個なら、主成分もp個求まる。

$$\left\{ \begin{array}{l} Z_1 = a_{11}U_1 + a_{12}U_2 + \cdots + a_{1p}U_p \\ Z_2 = a_{21}U_1 + a_{22}U_2 + \cdots + a_{2p}U_p \\ \vdots \\ Z_p = a_{p1}U_1 + a_{p2}U_2 + \cdots + a_{pp}U_p \end{array} \right.$$



17-4. 主成分分析；4つ目の注意点

主成分は、説明変数の個数分だけ求まる！1個じゃないよ。
説明変数がp個なら、主成分もp個求まる。

$$\left\{ \begin{array}{l} Z_1 = a_{11}U_1 + a_{12}U_2 + \cdots + a_{1p}U_p \\ Z_2 = a_{21}U_1 + a_{22}U_2 + \cdots + a_{2p}U_p \\ \vdots \\ Z_p = a_{p1}U_1 + a_{p2}U_2 + \cdots + a_{pp}U_p \end{array} \right.$$

主成分は説明変数の個数だけ数学的に自動的に求められてしまうもの。
(各主成分は互いに直交している。)

第1主成分が「総合力」というイメージ、
第2主成分以下は、結果を見てから分析者が自分で意味づけ解釈していくイメージ。

特に、第1主成分と第2主成分を二次元のグラフであらわすのは一般的。

17-5. 主成分分析；解析の流れ

主成分分析は、以下の3つの流れに従って行う。

- (1) 主成分と主成分得点を求める
- (2) 分析結果の精度を確認する
- (3) 分析結果を検討する

17-5. 主成分分析；（１）主成分と主成分得点を求める

例を使って追ってみよう。

表は、人気ラーメン店の徹底レビュー特集からデータを切り取ったものである。

ラーメン店10店舗について、麺、具、スープに対する5段階評価値が掲載されていた。

	麺	具	スープ
二楽	2	4	5
夢田屋	1	5	1
地回	5	3	4
なのはな	2	2	3
花ぶし	3	5	5
昇辰軒	4	3	2
丸蔵らあめん	4	4	3
海楽亭	1	2	1
なるみ家	3	3	2
奏月	5	5	3
平均	3.0	3.6	2.9
標準偏差	1.5	1.2	1.4

$$\sqrt{\frac{(2-3.0)^2 + \dots + (5-3.0)^2}{10-1}} = 1.5$$

主成分分析における基準化で用いられる
標準偏差の分母は、一般的には、
「データの個数 ひく 1」です。

17-5. 主成分分析；（１）主成分と主成分得点を求める

(1)-Step1; 変数ごとに基準化する

変数ごとに基準化したものが右の表。

	麺	具	スープ
二楽	2	4	5
夢田屋	1	5	1
地回	5	3	4
なのはな	2	2	3
花ぶし	3	5	5
昇辰軒	4	3	2
丸蔵らあめん	4	4	3
海楽亭	1	2	1
なるみ家	3	3	2
奏月	5	5	3
平均	3.0	3.6	2.9
標準偏差	1.5	1.2	1.4

	$\frac{3 - 2.9}{1.4} = 0.1$	麺の 基準値 U1	具の 基準値 U2	スープの 基準値 U3
二楽		-0.7	0.3	1.4
夢田屋		-1.3	1.2	-1.3
地回		1.3	-0.5	0.8
なのはな		-0.7	-1.4	0.1
花ぶし		0.0	1.2	1.4
昇辰軒		0.7	-0.5	-0.6
丸蔵らあめん		0.7	0.3	0.1
海楽亭		-1.3	-1.4	-1.3
なるみ家		0.0	-0.5	-0.6
奏月		1.3	1.2	0.1
平均		0	0	0
標準偏差		1	1	1

17-5. 主成分分析；（１）主成分と主成分得点を求める

(1)-Step2; 相関行列を求める

	具	麺	スープ
具	1	0.19	0.36
麺	0.19	1	0.30
スープ	0.36	0.30	1

17-5. 主成分分析；（１）主成分と主成分得点を求める

(1)-Step3; 固有値固有ベクトルを求める

$$\begin{bmatrix} 1 & 0.19 & 0.36 \\ 0.19 & 1 & 0.30 \\ 0.36 & 0.30 & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \lambda \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} \text{ を満たす}$$

固有値 λ と固有ベクトル $\begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix}$ を求める。

ただし、固有ベクトルは

$$a_1^2 + a_2^2 + a_3^2 = 1$$


が成立するようにする。

固有値 λ	固有ベクトル
1.6	$\begin{bmatrix} 0.57 \\ 0.52 \\ 0.63 \end{bmatrix}$
0.8	$\begin{bmatrix} -0.60 \\ 0.79 \\ -0.11 \end{bmatrix}$
0.6	$\begin{bmatrix} -0.55 \\ -0.32 \\ 0.77 \end{bmatrix}$

17-5. 主成分分析；（１）主成分と主成分得点を求める

(1)-Step4; 固有値固有ベクトルを基にグラフを描く

1 番目に大きい固有値 に対する 固有ベクトル
2 番目に大きい固有値 に対する 固有ベクトル
をもとにプロットする。



	座標
麺	(0.57, -0.60)
具	(0.52, 0.79)
スープ	(0.63, -0.11)

固有値 λ	固有ベクトル
1.6	$\begin{bmatrix} 0.57 \\ 0.52 \\ 0.63 \end{bmatrix}$
0.8	$\begin{bmatrix} -0.60 \\ 0.79 \\ -0.11 \end{bmatrix}$
0.6	$\begin{bmatrix} -0.55 \\ -0.32 \\ 0.77 \end{bmatrix}$

17-5. 主成分分析；（1）主成分と主成分得点を求める

(1)-Step5; 確認

求めた固有値固有ベクトルから、主成分分析の構造を式で表すと…

$$Z_1 = a_{11}U_1 + a_{12}U_2 + \cdots + a_{1p}U_p$$

$$Z_2 = a_{21}U_1 + a_{22}U_2 + \cdots + a_{2p}U_p$$

$$Z_1 = 0.57U_1 + 0.52U_2 + 0.63U_3$$

$$Z_2 = -0.60U_1 + 0.79U_2 - 0.11U_3$$

↑
麺の
基準値

↑
具の
基準値

↑
スープ
の基準値

固有値λ	固有ベクトル
1.6	$\begin{bmatrix} 0.57 \\ 0.52 \\ 0.63 \end{bmatrix}$
0.8	$\begin{bmatrix} -0.60 \\ 0.79 \\ -0.11 \end{bmatrix}$
0.6	$\begin{bmatrix} -0.55 \\ -0.32 \\ 0.77 \end{bmatrix}$

最大の固有値に対応する固有ベクトルが第1主成分の係数
最大からp番目の固有値に対応する固有ベクトルが第p主成分の係数

17-5. 主成分分析；（１）主成分と主成分得点を求める

(1)-Step6; 各個体の第1第2主成分の座標＝各個体の主成分得点を求める

基準化したものが右表であった。

主成分分析の構造を式で表したものが下記であった。

U_1 U_2 U_3 の値を代入して
第1主成分得点と、第2主成分得点の値を求める。

$$Z_1 = 0.57U_1 + 0.52U_2 + 0.63U_3$$

$$Z_2 = -0.60U_1 + 0.79U_2 - 0.11U_3$$

次のページへ

	麺の 基準値 U_1	具の 基準値 U_2	スープの 基準値 U_3
二楽	-0.7	0.3	1.4
夢田屋	-1.3	1.2	-1.3
地回	1.3	-0.5	0.8
なのはな	-0.7	-1.4	0.1
花ぶし	0.0	1.2	1.4
昇辰軒	0.7	-0.5	-0.6
丸蔵らあめん	0.7	0.3	0.1
海楽亭	-1.3	-1.4	-1.3
なるみ家	0.0	-0.5	-0.6
奏月	1.3	1.2	0.1
平均	0	0	0
標準偏差	1	1	1

17-5. 主成分分析；（1）主成分と主成分得点を求める




	第1主成分 z_1	第2主成分 z_2
二楽	0.7	0.5
夢田屋	-0.1	1.9
地回	1.0	-1.3
なのはな	-1.1	-0.7
花ぶし	1.5	0.8
昇辰軒	-0.3	-0.7
丸蔵らあめん	0.6	-0.1
海楽亭	-2.3	-0.1
なるみ家	-0.7	-0.3
奏月	1.4	0.1
平均	0	0
標準偏差	$\sqrt{1.6}$	$\sqrt{0.8}$

ルート固有値

17-5. 主成分分析；（1）主成分と主成分得点を求める

(1)-Step7; 各個体の第1第2主成分得点を基にグラフにプロットする

	第1主成分 Z_1	第2主成分 Z_2
二楽	0.7	0.5
夢田屋	-1.0	1.9
地回	1.0	-1.3
なのはな	-1.1	-0.7
花ぶし	1.5	0.8
昇辰軒	-0.3	-0.7
丸蔵らあめん	0.6	-0.1
海楽亭	-2.3	-0.1
なるみ家	-0.7	-0.3
奏月	1.4	0.1
平均	0	0
標準偏差	$\sqrt{1.6}$	$\sqrt{0.8}$



17-5. 主成分分析；分析の流れ

主成分分析は、以下の3つの流れに従って行う。

(1) 主成分と主成分得点を求める

Step1～7までを行った。

(2) 分析結果の精度を確認する

(3) 分析結果を検討する

17-5. 主成分分析；（２）分析結果の確認

主成分分析がうまく言ったかどうかは、**累積寄与率**の大きさに判断する。

先に示したようにp個の変数からなる相関行列では固有値はp個求まる。また、求まった固有値全部の値の合計はpとなる。（p行p列の相関行列の固有値の個数はp個、固有値全部の合計はp）

ここでは3行3列の行列なので、固有値全部の合計は3となる。
つまり、1変数あたりの固有値の取り分は1ということ。

第 i 主成分の寄与率とは以下

$$\text{第 } i \text{ 主成分の寄与率} = \frac{\lambda_i}{\text{変数の個数}} \times 100$$

累積寄与率は、寄与率を第1主成分から順に足したもの。

	固有値 λ	寄与率 [%]	累積寄与率 [%]
第1主成分	1.6	$(1.6/3) \times 100 = 52.4$	52.4
第2主成分	0.8	$(0.8/3) \times 100 = 27.1$	79.6
第3主成分	0.6	$(0.6/3) \times 100 = 20.4$	100

「第 i 成分の寄与率」は「分析対象のデータが有していた情報がその主成分にはどのくらい集約されているか」の目安になる。つまり大きいほど集約されているということ。

17-5. 主成分分析；（２）分析結果の確認

累積寄与率は、寄与率を第1主成分から順に足したもの。

	固有値 λ	寄与率 [%]	累積寄与率 [%]
第1主成分	1.6	$(1.6/3) \times 100 = 52.4$	52.4
第2主成分	0.8	$(0.8/3) \times 100 = 27.1$	79.6
第3主成分	0.6	$(0.6/3) \times 100 = 20.4$	100

「第 i 成分の寄与率」は「分析対象のデータが有していた情報がその主成分にはどのくらい集約されているか」の目安になる。つまり大きいほど集約されているということ。

主成分分析では主に第2主成分までを求めてグラフにすることが多い（もちろんそれ以下の主成分についても分析する場合もある）。この場合、第2主成分までの累積寄与率が高いほどよいということになる。

どのくらいの値だったら分析がうまく言っていると思ってよいのかという明確な基準はない。（しかし、第2主成分までで50%以上はあってほしいという感じではある。）

今回の場合は、79.6%となっているので、分析は十分うまく言っていると言える。

17-5. 主成分分析；分析の流れ

主成分分析は、以下の3つの流れに従って行う。

(1) 主成分と主成分得点を求める

Step1～7までを行った。


(2) 分析結果の精度を確認する

確認した。

(3) 分析結果を検討する

17-5. 主成分分析；（3）分析結果の検討


分析結果の検討



主成分分析では分析で求めたこの2つのグラフを見て分析結果を検討する。左は変数のグラフ、右は個体のグラフ。それぞれ（1）のステップ4とステップ7で求めた。

17-5. 主成分分析；（3）分析結果の検討


分析結果の検討



横軸は第1主成分、つまり「ラーメンの総合評価」
1位が花ぶし、2位が奏月、、、ということになる。

17-5. 主成分分析；（3）分析結果の検討

分析結果の検討




変数のグラフの横軸に着目してみる。
各プロットから垂直に Z_1 軸へ垂線をおろして
 Z_1 の値を読み取れば、スープの値が最大になる。

つまり、「ラーメンの総合評価」に最も影響を及ぼしている変数は「スープ」であるということ。

17-5. 主成分分析；（3）分析結果の検討

分析結果の検討



両方のグラフを比較してみる。例えば上の方に夢田屋がある。あまりラーメンの総合評価は良くないようではあるが、第2主成分が高いことから、具が評価されていると判断できる。

下の方にある地回についても、麺で評価されていると判断できる。

（もとにした雑誌のデータとコメントを見ると、コメントでは其のと通りの評価が書かれている）

17-5. 主成分分析；分析の流れ

主成分分析は、以下の3つの流れに従って行う。

(1) 主成分と主成分得点を求める

Step1～7までを行った。

(2) 分析結果の精度を確認する

確認した。

(3) 分析結果を検討する

検討した。

ここではラーメンの総合評価を求めた。ラーメンの総合ヒュ丘としては、例えば値段や量なども加味したほうが良いのではないかと考えられる。それ以外にも立地や、混雑度といった、もっと別の変数も考慮した上で主成分分析をやったほうが良いのではないか。。。

主成分分析は、主成分分析の対象とする変数の選定と、第1主成分の定義は、分析者の判断に委ねられている分析である。ここでは、麺、具、スープの3変数から導いた第1主成分を、ラーメンの総合評価、と定義したのは、あくまでも分析者である私達の主観。

つまり、なぜそれらの変数で分析しようとしたのかをしっかりと説明しないと、結局は其の解析内容を聞いた人に納得してもらえないので、分析者の責任が強く問われる分析手法であることを認識しよう。

17-6. 主成分分析

主成分分析を再びやってみよう

ある学校におけるテストの結果を個人別の成績としてまとめたデータがある。これを分析してみよう。

データは、[seiseki.csv](#) ファイルとして置いてある。
これをまず眺めて、次に読み込もう。

17-6. 主成分分析

```
> seiseki <- read.table("seiseki.csv", header=T, sep=", ")
```

```
> seiseki
```

	ID	kokugo	suugaku	eigo	butsure
1	A	98	71	96	70
2	B	89	77	78	41
3	C	68	29	57	20
4	D	90	78	75	53
...	(略)	...			

```
> seieki_prn <- prcomp(seiseki[,-1], scale=TRUE)
```


 主成分分析を行う関数 `prcomp()`

1列目のデータは個人番号IDなので主成分分析の計算に入れないため[,-1]と指定して省いている。

データの標準化をしている(scale=TRUE)ことで、各変数の平均がゼロで標準偏差が1に統一される。
*標準化された変数間の共分散は相関係数に等しくなる

17-6. 主成分分析

> `biplot(seiseki_prn, xlab=seiseki[,1])` 1列目のデータは個人番号ID、この文字を使ってプロットさせるためxlabでこれを指定している。



このようなプロットはバイプロットと呼ぶ（前回もやった）。このプロットには2つの情報が含まれている。

アルファベット大文字は個々の学生の位置を表している。赤い矢印と科目名を見ると、理系科目が上方向に、文系科目が下方向を向いている。

学生の成績データ(csvファイル)を見ながらこのプロットを確認すると、左側には成績が全体として良好な学生の番号が、右側には成績のあまり良くない学生の番号がプロットされている事がわかる。

17-6. 主成分分析

【課題 17-6A】

ここでR上のbiplot()によって描いた図をPDF形式のファイルで提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事


※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-6. 主成分分析

> biplot(seiseki_prn, xlab=seiseki[,1]) 1列目のデータは個人番号ID、この文字を使ってプロットさせるためxlabでこれを指定している。




学生の成績データ(csvファイル)を見ながらこのプロットを確認すると、

左側には成績が全体として良好な学生の番号が、

右側には成績のあまり良くない学生の番号がプロットされている事がわかる。

17-6. 主成分分析

> biplot(seiseki_prn, xlabs=seiseki[,1])



学生の成績データ(csvファイル)を見ながらこのプロットを確認すると、左側の成績が良好と思われる学生をみると、上側にはIとKが、下側にはABDGがプロットされている。


これらの学生の成績をcsvファイルから抽出したものが以下

	国	数	英	物
A	98	71	96	70
B	89	77	78	41
D	90	78	75	53
G	99	82	89	71
I	68	82	42	75
K	79	98	68	88

ABDGは文系科目が優れており、IKは理系科目が得意の様子。Iは文系科目の得点が悪いので、英語や国語の赤い矢印とは逆の方向にプロットされているようである。

17-6. 主成分分析

> biplot(seiseki_prn, xlabs=seiseki[,1])



散布図の横軸と縦軸はデータのある側面を表現しているとみなせる。

ここでは何を表現しているのかを解釈してみると、横軸は総合能力を分けたいと解釈することもできる。また、縦軸は理系と文系を分けたいと考えられる。

この横軸と縦軸は、4種類の試験結果を統合し、4次元の情報を2次元に圧縮した（次元圧縮）人工的な数値。

つまり、先に説明した、4つの変数を組み合わせた合成変数 Z_i により表現される主成分である。

17-6. 主成分分析

主成分分析では関数prcomp()において固有値固有ベクトルを求めている。関数eigen()を用いて出力される固有値固有ベクトルと一致するかどうかを確認してみよう。

まず関数eigen()を用いた出力結果を見る。次に関数prcomp()による出力結果を見る。

関数eigen()を用いると、固有値と固有ベクトルを求めることができる。固有値は英語でeigenvalue, 固有ベクトルはeigenvectorという。

```
> seiseki_eig <- eigen(cor(seiseki[, -1]))
```

```
$values 固有値
[1] 2.80497015 1.10324871 0.07087890 0.02090224
```

```
$vectors 固有ベクトル
```

	[,1]	[,2]	[,3]	[,4]
[1,]	-0.5320597	-0.4161893	-0.2641004	0.6884402
[2,]	-0.5085837	0.4700267	-0.6303952	-0.3507413
[3,]	-0.4688980	-0.5791114	0.2825987	-0.6040717
[4,]	-0.4882518	0.5200878	0.6730460	0.1952639

```
> seiseki_prn
```

```
Standard deviations:
```

```
[1] 1.6748045 1.0503565 0.2662309 0.1445761
```

```
Rotation:
```

	PC1	PC2	PC3	PC4
kokugo	-0.5320597	-0.4161893	0.2641004	-0.6884402
suugaku	-0.5085837	0.4700267	0.6303952	0.3507413
eigo	-0.4688980	-0.5791114	-0.2825987	0.6040717
butsure	-0.4882518	0.5200878	-0.6730460	-0.1952639

```
> seiseki_prn$sdev^2
```

```
[1] 2.80497015 1.10324871 0.07087890 0.02090224
```

関数prcomp()ではsdevが主成分の標準偏差に対応している。これを2乗すると固有値に一致する。

*なお、固有値の合計は変数の数と一致する

17-6. 主成分分析

主成分分析では関数prcomp()において固有値固有ベクトルを求めている。関数eigen()を用いて出力される固有値固有ベクトルと一致するかどうかを確認してみよう。

まず関数eigen()を用いた出力結果を見る。 次に関数prcomp()による出力結果を見る。

関数eigen()を用いると、固有値と固有ベクトルを求めることができる。固有値は英語でeigenvalue, 固有ベクトルはeigenvectorという。

```
> seiseki_eig <- eigen(cor(seiseki[, -1]))
$values 固有値
[1] 2.80497015 1.10324871 0.07087890 0.02090224
```

```
$vectors 固有ベクトル
      [,1]      [,2]      [,3]      [,4]
[1,] -0.5320597 -0.4161893 -0.2641004 0.6884402
[2,] -0.5085837 0.4700267 -0.6303952 -0.3507413
[3,] -0.4688980 -0.5791114 0.2825987 -0.6040717
[4,] -0.4882518 0.5200878 0.6730460 0.1952639
```

固有ベクトルも一致していることがわかる
 * ただし符号は異なることがある。
 主成分分析では相対的な関係が重要であり、
 数値の正負は問題となりません。

```
> seiseki_prn
Standard deviations:
[1] 1.6748045 1.0503565 0.2662309 0.1445761
```

```
Rotation:
      PC1      PC2      PC3      PC4
kokugo -0.5320597 -0.4161893 0.2641004 -0.6884402
suugaku -0.5085837 0.4700267 0.6303952 0.3507413
eigo    -0.4688980 -0.5791114 -0.2825987 0.6040717
butsuri -0.4882518 0.5200878 -0.6730460 -0.1952639
```

```
> seiseki_prn$sdev^2
[1] 2.80497015 1.10324871 0.07087890 0.02090224
```

関数prcomp()ではsdevが主成分の標準偏差に対応している。
 これを2乗すると固有値に一致する。
 * なお、固有値の合計は変数の数と一致する

17-6. 主成分分析

【課題 17-6B】

ここで2つの方法によって固有値固有ベクトルが一致していることを確認できたはずである。R上での解析の様子がわかるスクリーンショットを提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-6. 主成分分析

主成分分析により得られた合成変数 Z_i がどれだけ元データの情報を再現しているのかを表す指標を確認しておこう。

> `summary(seiseki_prn)`

Importance of components:

	PC1	PC2	PC3	PC4
Standard deviation	1.6748	1.0504	0.26623	0.14458
Proportion of Variance	0.7012	0.2758	0.01772	0.00523
Cumulative Proportion	0.7012	0.9770	0.99477	1.00000

Proportion of Varianceは、データ全体の分散(標準偏差)のうち、各合成変数(PCと書いてある)が何割を再現しているかを意味する。

Cumulative ProportionはProportion of Varianceの累積

ここでは、PC1とPC2がそれぞれ、70%と28%を再現しており、この2つの合成関数だけで、元のデータの情報のうち98%を再現しているということになる。

17-6. 主成分分析

実際の主成分そのものは、prcomp()関数を用いた場合には、そのx要素に含まれている

```
> seiseki_prn$x
```


	PC1	PC2	PC3	PC4
[1,]	-2.19903541	-0.708239395	-0.44049887	0.04794729
[2,]	-0.92253185	-0.327308814	0.60308111	0.16945905
[3,]	1.79260697	-0.296752461	-0.05223197	-0.01012176
[4,]	-1.13149492	0.009073101	0.37462204	-0.06426474
[5,]	1.38705062	-0.396382240	-0.13807008	0.01794481
[6,]	2.30657088	0.227019830	-0.13512736	0.18222376
[7,]	-2.28158609	-0.284611806	-0.06770652	-0.10556459
[8,]	2.11134021	0.198801715	0.06489478	-0.09421363
[9,]	0.09846476	2.297308757	0.00588783	-0.24672357
[10,]	0.96780945	-0.817731812	0.01401216	0.02968366
[11,]	-1.59065476	1.655412604	-0.17061662	0.23260175
[12,]	-0.53853984	-1.556589478	-0.05824650	-0.15897200

17-6. 主成分分析

さきほど描いた散布図では、各学生をPC1とPC2の二次元平面上にプロットした。学生の値（x軸, y軸の値）は、どのように計算されているか、確認しよう。

学生のプロットは、**主成分得点**に基づいている。

これを求めるには次のようにすれば良い。



17-6. 主成分分析


主成分得点の計算

```
> tokuten <- t(t(seiseki_prn$x)/(seiseki_prn$sdev * sqrt(nrow(seiseki_prn$x))))  
> tokuten
```

	PC1	PC2	PC3	PC4
[1,]	-0.37903340	-0.194649253	-0.477634505	0.09573638
[2,]	-0.15901080	-0.089956047	0.653923021	0.33835899
[3,]	0.30897998	-0.081558080	-0.056635312	-0.02021013
[4,]	-0.19502840	0.002493609	0.406204022	-0.12831746
[5,]	0.23907687	-0.108939869	-0.149709884	0.03583042
[6,]	0.39756859	0.062393084	-0.146519077	0.36384629
[7,]	-0.39326212	-0.078221398	-0.073414425	-0.21078089
[8,]	0.36391795	0.054637748	0.070365644	-0.18811643
[9,]	0.01697173	0.631381758	0.006384195	-0.49263313
[10,]	0.16681500	-0.224741645	0.015193435	0.05926938
[11,]	-0.27417079	0.454965975	-0.185000220	0.46443608
[12,]	-0.09282460	-0.427805883	-0.063156894	-0.31741950

```
> plot(tokuten[,1], tokuten[,2],asp=1)
```

PC1の値とPC2の値を使って
プロットしたものが右図



17-6. 主成分分析

【課題 17-6C】

ここでR上での解析で得られた散布図をPDFファイルとして提出しなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事


◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-6. 主成分分析

関数biplot()によって描いたこの図は、主成分得点を計算した結果を基にして各学生をプロットしたものであり、

さらに主成分負荷量の情報も合わせてひとつの散布図上に表現するために数値を調整して描かれたものである。



17-7. 主成分分析

【課題 17-7A】

会社の入社試験の成績を記した記録がある。あなたはその会社の人事担当として働いており、入社試験の結果についての分析を頼まれた。今年度は少数精鋭の5名が試験を受験した。主成分分析（やその他の解析）を用いて、分析を行い、データを解釈した結果をパワーポイントファイルにまとめて提出しなさい。入社試験の成績は、ファイル [nyusya_shiken.csv](#) にまとめてあるのでこれを用いなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-7. 主成分分析

【課題 17-7B】

同一の値段の7台の車種について、その動力性能、居住性、デザインに関して、100人にアンケートをおこなった。その結果、よいと評価した人の数を記したデータがまとめたある資料を受け取った。あなたはそのデータ分析担当として働いており、そのデータの分析を頼まれた。主成分分析（やその他の解析）を用いて、分析を行い、データを会社した結果をパワーポイントファイルにまとめて提出しなさい。データは、ファイル `kuruma.csv` にまとめたあるのでこれを用いなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで

17-7. 主成分分析

【課題 17-7C】

あるメーカーでは車の販売を促進するため、車のイメージ調査を行った。あなたは今、販売促進のためのデータ分析をするように命ぜられている。イメージ調査はアンケートにより行い、A～Jの車種に対して、イメージ（プロ的、格好が良い、好き、かわいい、一般的、ミーハー的、初心者の、ダサい、嫌い、欲しい）という項目に対する数値が書かれているとのことである。主成分分析（やその他の解析）を用いて、分析を行い、データを会社した結果をパワーポイントファイルにまとめて提出しなさい。データは、ファイル [image_tyousa.csv](#) にまとめてあるのでこれを用いなさい。

◎ ファイル名

ClassXX_rp課題番号名_YY. 拡張子

※XXには今日の授業回（第XX回）をふた桁の数字で入れる事

※YYには自分の番号をふた桁の数字で入れる事

※課題番号名には、この課題の番号を入れる事

◎ WebClassの該当場所に提出せよ。

◎ 提出締切；次回の授業の前日の18:00まで